

Modelos Lineares Generalizados

Estimação por mínimos quadrados generalizados

Terezinha K. A. Ribeiro

terezinha.ribeiro@unb.br

Instituto de Ciências Exatas
Departamento de Estatística
Universidade de Brasília

O modelo de regressão linear múltiplo normal considera que $\mathbf{Y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ com $\boldsymbol{\varepsilon} \sim N_n(0, \sigma^2 I_n)$ em que I_n é matriz identidade de ordem n , e $r(X) = k + 1$.

Segue que $\mathbf{Y} \sim N_n(X\boldsymbol{\beta}, \sigma^2 I_n)$.

O que acontece se trocarmos a matriz I_n por uma matriz V positiva definida cujo formato é conhecido?

Modelo linear com $\varepsilon \sim N_n(0, \sigma^2 V)$, V conhecida

Considere o modelo linear $\mathbf{Y} = X\boldsymbol{\beta} + \varepsilon$ com $\varepsilon \sim N_n(0, \sigma^2 V)$ em que $V \neq I_n$ é matriz positiva definida, e $r(X) = k + 1$.

Segue que $\mathbf{Y} \sim N_n(X\boldsymbol{\beta}, \sigma^2 V)$.

Note que

- ▶ se pelo menos dois elementos da diagonal principal de V são distintos, então o modelo linear é heteroscedástico;
- ▶ se V é uma matriz diagonal, então as respostas Y_i e Y_j são não correlacionadas (independentes);
- ▶ se V não é uma matriz diagonal, então as respostas Y_i e Y_j são correlacionadas (dependentes).

Modelo linear com $\varepsilon \sim N_n(0, \sigma^2 V)$, V conhecida

Como estamos supondo que V é uma matriz positiva definida, pela decomposição de Cholesky, existe uma matriz $P_{n \times n}$ não singular tal que

$$V = PP^\top.$$

Considere a transformação $\mathbf{Z} = P^{-1}\mathbf{Y}$. Veja que

$$E(\mathbf{Z}) = P^{-1} E(\mathbf{Y}) = P^{-1} X\beta,$$

$$\begin{aligned} \text{Var}(\mathbf{Z}) &= P^{-1} \text{Var}(\mathbf{Y}) P^{-1\top} \\ &= P^{-1} \sigma^2 V P^{-1\top} \\ &= \sigma^2 (P^{-1} P) (P^\top P^{-1\top}) \\ &= \sigma^2 (P^{-1} P) (P^\top P^\top)^{-1} \\ &= \sigma^2 I_n. \end{aligned}$$

Modelo linear com $\varepsilon \sim N_n(0, \sigma^2 V)$, V conhecida

Como P é de posto completo (pois P é não singular), segue que

$$\mathbf{Z} = P^{-1} \mathbf{Y} \sim N_n(P^{-1} X \beta, \sigma^2 I_n).$$

Assim, o modelo linear transformado é dado por

$$\mathbf{Z} = Q\beta + \eta, \quad \eta \sim N_n(\mathbf{0}, \sigma^2 I_n), \quad (1)$$

em que $Q_{n \times (k+1)} = P^{-1}X$ é a matriz do modelo de posto completo pois $r(Q) = r(P^{-1}X) = r(X) = k+1$, e $\eta = P^{-1}\varepsilon$ é o vetor de erros aleatórios.

O modelo linear definido em (1) é homoscedástico e satisfaz todas as condições da regressão linear múltipla normal.

Ainda, veja que os parâmetros de interesse β e σ^2 do modelo linear original são os mesmos do modelo transformado.

Modelo linear com $\varepsilon \sim N_n(0, \sigma^2 V)$, V conhecida

Sendo assim, generalizaremos os resultados inferenciais obtidos sob a regressão linear normal.

Assim, o estimador de mínimos quadrados para β sob o modelo transformado (1) é

$$\hat{\beta} = (Q^T Q)^{-1} Q^T Z.$$

Voltando, ao modelo linear original temos que o estimador para β fica dado por

$$\begin{aligned}\hat{\beta}_G &= [(P^{-1}X)^T P^{-1}X]^{-1} (P^{-1}X)^T P^{-1}Y \\ &= [X^T (P^{-1})^T P^{-1}X]^{-1} X^T (P^{-1})^T P^{-1}Y.\end{aligned}$$

De $V = PP^T$ tem-se que $V^{-1} = P^T^{-1}P^{-1} = P^{-1^T}P^{-1}$.

Modelo linear com $\varepsilon \sim N_n(0, \sigma^2 V)$, V conhecida

Assim, obtemos que

$$\hat{\beta}_G = (X^\top V^{-1} X)^{-1} X^\top V^{-1} \mathbf{Y}.$$

Note que $\hat{\beta}_G \neq \hat{\beta} = (X^\top X)^{-1} X^\top \mathbf{Y}$.

Sob o modelo linear original $\mathbf{Y} = X\beta + \varepsilon$ com $\varepsilon \sim N_n(0, \sigma^2 V)$, o estimador $\hat{\beta}_G$ é chamado de estimador de mínimos quadrados generalizados de β .

Sob o modelo linear transformado $\mathbf{Z} = Q\beta + \eta$ com $\eta \sim N_n(0, \sigma^2 I_n)$, o estimador $\hat{\beta}_G$ é usual estimador de mínimos quadrados de β .

Modelo linear com $\varepsilon \sim N_n(0, \sigma^2 V)$, V conhecida

A soma de quadrados dos desvios sob o modelo linear transformado é

$$S(\beta) = \sum_{i=1}^n \eta_i^2 = \boldsymbol{\eta}^\top \boldsymbol{\eta} = (\mathbf{Z} - Q\beta)^\top (\mathbf{Z} - Q\beta).$$

Voltando o modelo linear original, temos que

$$\begin{aligned} S_G(\beta) &= (P^{-1}\mathbf{Y} - P^{-1}X\beta)^\top (P^{-1}\mathbf{Y} - P^{-1}X\beta) \\ &= [P^{-1}(\mathbf{Y} - X\beta)]^\top [P^{-1}(\mathbf{Y} - X\beta)] \\ &= (\mathbf{Y} - X\beta)^\top P^{-1\top} P^{-1}(\mathbf{Y} - X\beta) \\ &= (\mathbf{Y} - X\beta)^\top V^{-1}(\mathbf{Y} - X\beta) \\ &= \varepsilon^\top V^{-1}\varepsilon. \end{aligned}$$

Assim, sob o modelo linear original, $S_G(\beta)$ é a soma de quadrados dos desvios generalizados.

Modelo linear com $\varepsilon \sim N_n(0, \sigma^2 V)$, V conhecida

O estimador de mínimos quadrados para σ^2 sob o modelo linear transformado é

$$\hat{\sigma}^2 = \frac{1}{n-k-1} \sum_{i=1}^n \hat{\eta}_i^2 = \frac{1}{n-k-1} \hat{\eta}^\top \hat{\eta}.$$

em que $\hat{\eta} = P^{-1}\hat{\varepsilon}$.

Voltando ao modelo linear original, temos que

$$\begin{aligned}\hat{\sigma}_G^2 &= \frac{1}{n-k-1} (P^{-1}\hat{\varepsilon})^\top P^{-1}\hat{\varepsilon} \\ &= \frac{1}{n-k-1} \hat{\varepsilon}^\top (P^{-1})^\top P^{-1}\hat{\varepsilon} \\ &= \frac{1}{n-k-1} \hat{\varepsilon}^\top V^{-1}\hat{\varepsilon}.\end{aligned}$$

Assim, $\hat{\sigma}_G^2$ é o estimador de mínimos quadrados generalizados para σ^2 sob o modelo linear original.

Caso 2: Propriedades de $\hat{\beta}_G$

P_1 . $\hat{\beta}_G = B\mathbf{Y}$ com $B = (X^\top V^{-1}X)^{-1}X^\top V^{-1}$. Assim, $\hat{\beta}_G$ é linear em \mathbf{Y} .

P_2 . $\hat{\beta}_G$ é um estimador não viciado para β .

De fato, veja que

$$\begin{aligned} E(\hat{\beta}_G) &= E\left[(X^\top V^{-1}X)^{-1}X^\top V^{-1}\mathbf{Y}\right] \\ &= (X^\top V^{-1}X)^{-1}X^\top V^{-1}E(\mathbf{Y}) \\ &= (X^\top V^{-1}X)^{-1}X^\top V^{-1}X\beta \\ &= \beta. \end{aligned}$$

Caso 2: Propriedades de $\hat{\beta}_G$

P₃. A variância de $\hat{\beta}_G$ possui forma fechada:

$$\begin{aligned}\text{Var}(\hat{\beta}_G) &= \text{Var} \left[(X^\top V^{-1} X)^{-1} X^\top V^{-1} \mathbf{Y} \right] \\&= (X^\top V^{-1} X)^{-1} X^\top V^{-1} \text{Var}(\mathbf{Y}) \left[(X^\top V^{-1} X)^{-1} X^\top V^{-1} \right]^\top \\&= (X^\top V^{-1} X)^{-1} X^\top V^{-1} \sigma^2 V V^{-1} X (X^\top V^{-1} X)^{-1} \\&= \sigma^2 (X^\top V^{-1} X)^{-1} X^\top V^{-1} X (X^\top V^{-1} X)^{-1} \\&= \sigma^2 (X^\top V^{-1} X)^{-1}.\end{aligned}$$

Lembre-se que V é uma matriz simétrica.

P₄. $\hat{\beta}_G \sim N_{k+1}(\beta, \sigma^2 (X^\top V^{-1} X)^{-1})$.

Caso 2: Propriedades de $\hat{\beta}_G$

P₅. Cada componente de $\hat{\beta}_G$ segue uma distribuição normal univariada. Mais especificamente, se $\hat{\beta}_G^j$ é a $(j+1)$ -ésima entrada de $\hat{\beta}_G$, segue que

$$\hat{\beta}_G^j \sim N(\beta_j, \sigma^2 b_{(j+1)(j+1)}),$$

em que $b_{(j+1)(j+1)}$ é o elemento $(j+1, j+1)$ da matriz $(X^\top V^{-1} X)^{-1}$.

P₆. $\text{Cov}(\hat{\beta}_G^j, \hat{\beta}_G^l) = \sigma^2 b_{(j+1)(l+1)}$, com $j, l = 0, 1, 2, \dots, k$.

Da propriedade *P₄*, para $j \neq l$, segue que $\hat{\beta}_G^j$ e $\hat{\beta}_G^l$ são independentes se $b_{(j+1)(l+1)} = 0$.

P₇. O estimador $\hat{\beta}_G$ obtido por mínimos quadrados generalizados coincide com o estimador $\hat{\beta}_{MV}$ obtido por máxima verossimilhança.

Estimadores ótimos para funções de β e σ^2

Resultado. o estimador $\hat{\beta}$ é um estimador não viciado para β sob o modelo $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$, com $\varepsilon \sim N_n(\mathbf{0}, \sigma^2 V)$.

Entretanto, $\hat{\beta}$ **não é** um estimador ótimo para β (não é função de uma estatística suficiente e completa para β). Logo, $\hat{\beta}$ não é o ENVVUM de β .

Resultado. Sejam $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$, com $\varepsilon \sim N_n(\mathbf{0}, \sigma^2 V)$, e $t(\theta)$ uma função qualquer de $\theta = (\beta^\top \sigma^2)^\top$. Se $q(\hat{\theta}_G)$, com $\hat{\theta}_G = (\hat{\beta}_G^\top \hat{\sigma}_G^2)^\top$, é um estimador não viciado para $t(\theta)$, então $q(\hat{\theta}_G)$ é o ENVVUM para $t(\theta)$.

Estimadores ótimos para funções de β e σ^2

Assim, temos os seguintes resultados:

- (i) $\hat{\beta}_G = (X^\top V^{-1} X)^{-1} X^\top V^{-1} Y$ é o ENVVUM para β ;
- (ii) $\hat{\beta}_G^j$ é o ENVVUM para β_j com $j = 0, 1, \dots, k$;
- (iii) $\mathbf{a}^\top \hat{\beta}_G = \mathbf{a}^\top (X^\top V^{-1} X)^{-1} X^\top V^{-1} Y$ é o ENVVUM para $\mathbf{a}^\top \beta$ com $\mathbf{a}^\top = (a_0 \ a_1 \ \dots \ a_k) \in \mathbb{R}^{k+1}$ um vetor de constantes;
- (iv) $\widehat{E(Y_i)} = \mathbf{X}_i^\top \hat{\beta}_G$ é o ENVVUM para $E(Y_i) = \mathbf{X}_i^\top \beta$.
- (v) $\hat{\sigma}_G^2$ é o ENVVUM para σ^2

Testes de hipóteses via TRV

Queremos testar $H_0: C\beta = \mathbf{m}$ contra $H_1: C\beta \neq \mathbf{m}$, com $C_{p \times (k+1)}$ de constantes tal que $r(C) = p \leq k+1$ (posto completo), \mathbf{m} vetor de constantes $p \times 1$.

Sob o modelo linear transformado $\mathbf{Z} = Q\beta + \eta$ com $\eta \sim N_n(0, \sigma^2 I_n)$, a estatística do TRV é

$$W_0 = \frac{(C\hat{\beta} - \mathbf{m})^\top [C(Q^\top Q)^{-1}C^\top]^{-1} (C\hat{\beta} - \mathbf{m})}{p\hat{\sigma}^2}.$$

Testes de hipóteses via TRV

Sob o modelo linear original $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ com $\boldsymbol{\varepsilon} \sim N_n(0, \sigma^2 \mathbf{V})$, a estatística do TRV é

$$\begin{aligned} W_0 &= \frac{(\mathbf{C}\hat{\boldsymbol{\beta}}_G - \mathbf{m})^\top \{ \mathbf{C}[(\mathbf{P}^{-1}\mathbf{X})^\top \mathbf{P}^{-1}\mathbf{X}]^{-1} \mathbf{C}^\top \}^{-1} (\mathbf{C}\hat{\boldsymbol{\beta}}_G - \mathbf{m})}{p\hat{\sigma}_G^2} \\ &= \frac{(\mathbf{C}\hat{\boldsymbol{\beta}}_G - \mathbf{m})^\top \{ \mathbf{C}[\mathbf{X}^\top \mathbf{P}^{-1\top} \mathbf{P}^{-1}\mathbf{X}]^{-1} \mathbf{C}^\top \}^{-1} (\mathbf{C}\hat{\boldsymbol{\beta}}_G - \mathbf{m})}{p\hat{\sigma}_G^2} \\ &= \frac{(\mathbf{C}\hat{\boldsymbol{\beta}}_G - \mathbf{m})^\top \{ \mathbf{C}[\mathbf{X}^\top \mathbf{V}^{-1}\mathbf{X}]^{-1} \mathbf{C}^\top \}^{-1} (\mathbf{C}\hat{\boldsymbol{\beta}}_G - \mathbf{m})}{p\hat{\sigma}_G^2}. \end{aligned}$$

Rejeita-se $H_0: \mathbf{C}\boldsymbol{\beta} = \mathbf{m}$ ao nível de significância $\alpha \cdot 100\%$ se $W_0 \geq w_0$ com w_0 obtido tal que

$$P(F_{p, n-k-1} \geq w_0) = \alpha.$$

Exemplo

Antes de definirmos as somas de quadrados, considere o exemplo a seguir.

Considere o modelo linear

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, 2, \dots, n$$

em que $\varepsilon_i \stackrel{\text{ind}}{\sim} N(0, \sigma^2 w_i)$ com $w_i > 0$.

Daí, temos que $\varepsilon \sim N_n(\mathbf{0}, \sigma^2 V)$ com $V = \text{diag}\{w_1, w_2, \dots, w_n\}$.

Pela decomposição de Cholesky, sabemos que $V = PP^\top$, e portanto,

$$P = V^{1/2} = \text{diag}\{\sqrt{w_1}, \sqrt{w_2}, \dots, \sqrt{w_n}\}.$$

Exemplo

Segue que

$$P^{-1} = V^{-1/2} = \text{diag} \left\{ \frac{1}{\sqrt{w_1}}, \frac{1}{\sqrt{w_2}}, \dots, \frac{1}{\sqrt{w_n}} \right\}.$$

Então, o modelo linear transformado é $\mathbf{Z} = Q\boldsymbol{\beta} + \boldsymbol{\eta}$ com

$$\mathbf{Z} = P^{-1}\mathbf{Y} = \begin{bmatrix} \frac{Y_1}{\sqrt{w_1}} \\ \frac{Y_2}{\sqrt{w_2}} \\ \vdots \\ \frac{Y_n}{\sqrt{w_n}} \end{bmatrix}, \quad Q = P^{-1}X = \begin{bmatrix} \frac{1}{\sqrt{w_1}} & \frac{x_1}{\sqrt{w_1}} \\ \frac{1}{\sqrt{w_2}} & \frac{x_2}{\sqrt{w_2}} \\ \vdots & \vdots \\ \frac{1}{\sqrt{w_n}} & \frac{x_n}{\sqrt{w_n}} \end{bmatrix}, \quad \boldsymbol{\eta} = P^{-1}\boldsymbol{\varepsilon} = \begin{bmatrix} \frac{\varepsilon_1}{\sqrt{w_1}} \\ \frac{\varepsilon_2}{\sqrt{w_2}} \\ \vdots \\ \frac{\varepsilon_n}{\sqrt{w_n}} \end{bmatrix}$$

Exemplo

Então, o modelo linear transformado é dado por

$$\frac{Y_i}{\sqrt{w_i}} = \beta_0 \frac{1}{\sqrt{w_i}} + \beta_1 \frac{x_i}{\sqrt{w_i}} + \frac{\varepsilon_i}{\sqrt{w_i}}, \quad i = 1, 2, \dots, n.$$

Este modelo linear não possui intercepto. Perceba que β_0 é coeficiente da covariável $1 / \sqrt{w_i}$.

Muitas vezes a transformação $\mathbf{Z} = P^{-1} \mathbf{Y}$ resulta em um modelo linear sem intercepto, mesmo que o modelo linear original tenha intercepto.

Sendo assim, devemos ter o cuidado de identificar se o modelo linear transformado possui intercepto para que possamos definir as somas de quadrados do modelo linear original.

Somas de quadrados com intercepto

Se o modelo linear transformado possuir intercepto, usamos as somas de quadrados SQT, SQReg, e SQRes definidas, respectivamente, por

$$\text{SQT} = \sum_{i=1}^n (Z_i - \bar{Z})^2;$$

$$\text{SQReg} = \sum_{i=1}^n (\hat{Z}_i - \bar{Z})^2;$$

$$\text{SQRes} = \sum_{i=1}^n \hat{\eta}_i^2 = \sum_{i=1}^n (Z_i - \hat{Z}_i)^2.$$

Somas de quadrados com intercepto

Agora, usando resultado do modelo de regressão linear normal,

$$\begin{aligned}\text{SQT} &= \sum_{i=1}^n (Z_i - \bar{Z})^2 \\&= \mathbf{Z}^\top \left[I_n - \frac{1}{n} \mathbf{1} \mathbf{1}^\top \right] \mathbf{Z} \\&= [\mathbf{P}^{-1} \mathbf{Y}]^\top \left[I_n - \frac{1}{n} \mathbf{1} \mathbf{1}^\top \right] \mathbf{P}^{-1} \mathbf{Y} \\&= \mathbf{Y}^\top \left[\mathbf{P}^{-1\top} \mathbf{P}^{-1} - \frac{1}{n} \mathbf{P}^{-1\top} \mathbf{1} \mathbf{1}^\top \mathbf{P}^{-1} \right] \mathbf{Y} \\&= \mathbf{Y}^\top \left[\mathbf{V}^{-1} - \frac{1}{n} \mathbf{P}^{-1\top} \mathbf{1} \mathbf{1}^\top \mathbf{P}^{-1} \right] \mathbf{Y}.\end{aligned}$$

Somas de quadrados com intercepto

Ainda, temos que

$$\begin{aligned}\text{SQReg} &= \sum_{i=1}^n (\hat{Z}_i - \bar{Z})^2 \\&= \mathbf{Z}^\top \left[Q(Q^\top Q)^{-1} Q^\top - \frac{1}{n} \mathbf{1}\mathbf{1}^\top \right] \mathbf{Z} \\&= [\mathbf{P}^{-1} \mathbf{Y}]^\top \left\{ \mathbf{P}^{-1} X [(\mathbf{P}^{-1} X)^\top \mathbf{P}^{-1} X]^{-1} (\mathbf{P}^{-1} X)^\top - \frac{1}{n} \mathbf{1}\mathbf{1}^\top \right\} \mathbf{P}^{-1} \mathbf{Y} \\&= \mathbf{Y}^\top \mathbf{P}^{-1\top} \left\{ \mathbf{P}^{-1} X [X^\top \mathbf{P}^{-1\top} \mathbf{P}^{-1} X]^{-1} X^\top \mathbf{P}^{-1\top} - \frac{1}{n} \mathbf{1}\mathbf{1}^\top \right\} \mathbf{P}^{-1} \mathbf{Y} \\&= \mathbf{Y}^\top \left\{ \mathbf{V}^{-1} X [X^\top \mathbf{V}^{-1} X]^{-1} X^\top \mathbf{V}^{-1} - \frac{1}{n} \mathbf{P}^{-1\top} \mathbf{1}\mathbf{1}^\top \mathbf{P}^{-1} \right\} \mathbf{Y}.\end{aligned}$$

Somas de quadrados com intercepto

Por fim,

$$\begin{aligned}\text{SQRes} &= \sum_{i=1}^n \hat{\eta}_i^2 \\&= \mathbf{Z}^\top \left[I_n - Q(Q^\top Q)^{-1} Q^\top \right] \mathbf{Z} \\&= [\mathbf{P}^{-1} \mathbf{Y}]^\top \left\{ I_n - \mathbf{P}^{-1} X [X^\top \mathbf{P}^{-1 \top} \mathbf{P}^{-1} X]^{-1} X^\top \mathbf{P}^{-1 \top} \right\} \mathbf{P}^{-1} \mathbf{Y} \\&= \mathbf{Y}^\top \left\{ V^{-1} - V^{-1} X [X^\top V^{-1} X]^{-1} X^\top V^{-1} \right\} \mathbf{Y}.\end{aligned}$$

Ainda, $\text{SQRes} = (n - k - 1) \hat{\sigma}_G^2$.

Somas de quadrados com intercepto

Sob o modelo linear transformado, sabemos que

$$\frac{\text{SQRes}}{\sigma^2} \sim \chi_{n-k-1}^2;$$

$$\frac{\text{SQReg}}{\sigma^2} \sim \chi_{k,\lambda}^2,$$

com

$$\lambda = \frac{1}{2\sigma^2} \boldsymbol{\beta}^{*\top} \mathbf{Q}_1^\top \left[\mathbf{I}_n - \frac{1}{n} \mathbf{1}\mathbf{1}^\top \right] \mathbf{Q}_1 \boldsymbol{\beta}^*,$$

em que \mathbf{Q}_1 é obtida de $\mathbf{Q} = [\mathbf{1} \ \mathbf{Q}_1]$.

Sob $H_0: \boldsymbol{\beta}^* = \mathbf{0}$, temos que

$$\frac{\text{SQReg}}{\sigma^2} \sim \chi_k^2.$$

A partir disto, pode-se montar a tabela de análise de variância.

Somas de quadrados sem intercepto

Se o modelo linear transformado **NÃO** possuir intercepto, usamos as somas de quadrados SQT_{nc} , $SQReg_{nc}$, e $SQRes$ definidas, respectivamente, por

$$SQT_{nc} = \sum_{i=1}^n Z_i^2;$$

$$SQReg_{nc} = \sum_{i=1}^n \hat{Z}_i^2;$$

$$SQRes = \sum_{i=1}^n \hat{\eta}_i^2 = \sum_{i=1}^n (Z_i - \hat{Z}_i)^2.$$

Note que $SQRes$ é definida da mesma forma.

Somas de quadrados sem intercepto

Veja que

$$\begin{aligned}\text{SQT}_{nc} &= \sum_{i=1}^n Z_i^2 \\ &= \mathbf{Z}^\top \mathbf{Z} \\ &= [\mathbf{P}^{-1} \mathbf{Y}]^\top \mathbf{P}^{-1} \mathbf{Y} \\ &= \mathbf{Y}^\top \mathbf{V}^{-1} \mathbf{Y};\end{aligned}$$

$$\begin{aligned}\text{SQReg}_{nc} &= \sum_{i=1}^n \hat{Z}_i^2 \\ &= \mathbf{Z}^\top \mathbf{Q} (\mathbf{Q}^\top \mathbf{Q})^{-1} \mathbf{Q}^\top \mathbf{Z} \\ &= \mathbf{Y}^\top \mathbf{V}^{-1} \mathbf{X} [\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X}]^{-1} \mathbf{X}^\top \mathbf{V}^{-1} \mathbf{Y}.\end{aligned}$$

Somas de quadrados sem intercepto

Sob o modelo linear transformado, sabemos que

$$\frac{\text{SQRes}}{\sigma^2} \sim \chi_{n-k}^2;$$

$$\frac{\text{SQReg}_{nc}}{\sigma^2} \sim \chi_{k,\lambda}^2,$$

com

$$\lambda = \frac{1}{2\sigma^2} \boldsymbol{\beta}^\top \mathbf{Q}^\top \mathbf{Q} \boldsymbol{\beta}.$$

Sob $H_0: \boldsymbol{\beta} = \mathbf{0}$, temos que

$$\frac{\text{SQReg}_{nc}}{\sigma^2} \sim \chi_k^2.$$

A partir disto, pode-se montar a tabela de análise de variância.

No arquivo **supervisores.txt** estão apresentados dados referentes a 27 estabelecimentos industriais. Neste estudo, o objetivo é explicar o número de supervisores em função do número de trabalhadores destes estabelecimentos.

Inicialmente foi ajustado um modelo de regressão linear normal simples.

Aplicação prática





Gráfico dos resíduos studentizados versus valores ajustados



Em seguida, ajustou-se um modelo de regressão linear sob mínimos quadrados ponderados supondo que $\text{Var}(Y) = \sigma^2 V$ com

$$V = \text{diag}\{x_1^2, x_2^2, \dots, x_n^2\}.$$

Dada a matriz V , obtemos que os pesos do procedimento de estimação por mínimos quadrados ponderados são dados por $w_i = 1/x_i^2$.

Gráfico dos resíduos studentizados versus valores ajustados

