

1) Seja  $Y \sim \text{Pascal}(r, \pi)$ . A função densidade de  $Y$  é

$$f(y; r, \pi) = \binom{y-r}{r-1} \pi^r (1-\pi)^{y-r}, \quad y = r, r+1, r+2, \dots$$

$0 < \pi < 1.$

a) Seja  $y^* = Y/r \Leftrightarrow Y = ry^*$ . Assim, temos que

$$\begin{aligned} f(y^*; r, \pi) &= \binom{ry^*-1}{r-1} \pi^{ry^*} (1-\pi)^{ry^*-r} \\ &= \exp \left\{ \log \left( \frac{ry^*-1}{r-1} \right) + r \log(\pi) + (ry^*-r) \log(1-\pi) \right\} \\ &= \exp \left\{ r \left[ y^* \log(1-\pi) + \log \left( \frac{\pi}{1-\pi} \right) \right] + \log \left( \frac{ry^*-1}{r-1} \right) \right\}. \end{aligned}$$

Tome  $\phi = r$ ,  $\theta = \log(1-\pi) \Leftrightarrow \pi = 1 - e^\theta$ ,  $\theta < 0$ ,  
 $b(\theta) = -\log \left( \frac{\pi}{1-\pi} \right) = -\log \left( \frac{1-e^\theta}{e^\theta} \right) = \theta - \log(1-e^\theta)$ ,

$$e \ c(y^*; \phi) = \log \left( \frac{ry^*-1}{r-1} \right) = \log \left( \frac{\phi y^*-1}{\phi - 1} \right).$$

Logo,

$y^* = \frac{Y}{r} \in \text{FE uniparamétrica canônica.}$

b) Segue que

$$E(Y) = \mu = b'(\theta) = 1 - \frac{1}{1-e^\theta} \cdot -e^\theta = \frac{1}{1-e^\theta}.$$

Vai, como  $\pi = 1 - e^\theta$ , temos que  $\mu = E(Y) = \frac{1}{\pi} \cdot \pi = 1$ .  
 $\text{e } V(Y) = \frac{1}{\pi^2} \left[ (1 - e^\theta)^{-2} \right] = \frac{(1 - e^\theta)^{-2}}{\pi^2} = \frac{1}{\pi^2} \cdot \frac{1}{(1 - e^\theta)^2}$

A função de variância é obtida de

$$V(\mu) = b''(\theta) = \frac{d}{d\theta} \left[ (1 - e^\theta)^{-2} \right] = \frac{2e^\theta}{(1 - e^\theta)^3} = \frac{2}{\pi^2} \cdot \frac{e^\theta}{(1 - e^\theta)^3} = \frac{2}{\pi^2} \cdot \frac{e^\theta}{(1 - \pi)^3}$$

$$= \frac{2e^\theta}{(1 - e^\theta)^2} = \frac{2}{\pi^2} \cdot \frac{1 - \pi}{\pi^2} = \frac{2}{\pi^2} \cdot \frac{1}{\pi} - \frac{2}{\pi^2} \cdot \frac{1}{1 - \pi} = \left( \frac{1}{\pi} \right)^2 - \frac{1}{\pi}$$

$$= \mu^2 - \mu = \mu(\mu - 1).$$

Finalmente,

$$\text{Var}(Y^*) = \phi^{-1} V(\mu) = \frac{\mu(\mu - 1)}{\mu}.$$

c) Fazendo  $\mu = 1$ , temos  $Y^* = Y \sim \text{Pascal}(1, \pi) = \text{geo}(\pi)$ .

A densidade fica dada por

$$f(y^*; \pi) = \exp \left\{ y^* \log(1 - \pi) + \log \left( \frac{\pi}{1 - \pi} \right) + \log \left( \frac{1}{y^*!} \right) \right\}$$

$$= \exp \left\{ y^* \log(1 - \pi) + \log \left( \frac{\pi}{1 - \pi} \right) \right\}.$$

Tome  $\phi = 1$ ,  $\theta = \log(1 - \pi) \Leftrightarrow \pi = 1 - e^\theta$ ,  $b(\theta) = -\log \left( \frac{\pi}{1 - \pi} \right)$   
 $= \theta - \log(1 - e^\theta)$ , e  $c(y; \phi) = 0$ . Portanto,  $Y \sim \text{FE uniparamétrica canônica}$ . Em outras palavras, a distribuição  
geométrica de parâmetro  $\pi$  ( $0 < \pi < 1$ ) é FF.

Analogamente,  $\mu = E(Y) = b'(\theta) = \frac{1}{\pi}$ ,  $V(\mu) = \mu(\mu - 1)$ ,  
e  $\text{Var}(Y) = \mu(\mu - 1)$ .

- 2) Temos que  $\gamma \sim ES(\mu, \phi)$ . A função densidade de  $\gamma$  é
- $$f(y; \theta, \phi) = a(y, \phi) \exp\left\{ \phi[\theta(y+1) - \theta \log(\theta)] \right\}, \quad \theta > 0,$$
- $$\{(\theta)d - (\hat{\theta})d + (\theta - \hat{\theta})\}_{\theta} \quad y \in \mathbb{R},$$
- $$\phi > 0.$$
- a) Vou que  $f(y; \theta, \phi) = \exp\left\{ \phi[\theta y + \theta(1 - \log(\theta))] + \log[a(y, \phi)] \right\}$ .
- $$f(y; \theta, \phi) = \exp\left\{ \phi[\theta y + \theta(1 - \log(\theta))] + \log[a(y, \phi)] \right\}$$
- Tome  $\phi = \theta$ ,  $\theta = \theta$ ,  $b(\theta) = -\theta[1 - \log(\theta)]$ , e
- $$c(y, \phi) = \log[a(y, \phi)].$$
- Assim,  $\gamma \in FE$  uniparamétrica canônica.
- b) Segue que
- $$\mu = E(Y) = b'(\theta) = -[1 - \log(\theta)] - \theta \cdot -\frac{1}{\theta} = \log(\theta), \quad \theta > 0.$$
- $$\Rightarrow \theta = e^{\mu}$$
- A função de variância é obtida de
- $$V(\mu) = b''(\theta) = \frac{1}{\theta}, \quad \theta > 0. \Rightarrow V(\mu) = e^{-\mu}.$$
- Por fim,  $\text{Var}(Y) = \phi^{-1} V(\mu) = \frac{e^{-\mu}}{\phi}$ .

3) Suponha que  $y_i \stackrel{\text{ind}}{\sim} NI(\mu_i, \phi)$ ,  $\mu_i = g^{-1}(\eta_i)$ ,  
 $i = 1, 2, \dots, n$ .

Sabemos que  $\hat{\phi}$  é obtido tal que

$$\sum_{i=1}^n c'(y_i, \hat{\phi}) = \frac{1}{2} D(\tilde{y}; \tilde{x}) - \sum_{i=1}^n \{y_i \tilde{\theta}_i - b(\tilde{\theta}_i)\}.$$

como  $y_i \stackrel{\text{ind}}{\sim} NI(\mu_i, \phi)$ , então

$$C(y_i; \phi) = \frac{1}{2} \log\left(\frac{\phi}{2\pi y_i^3}\right) - \frac{\phi}{2y_i}$$

$$\Rightarrow c(y_i; \phi) = \frac{1}{2\phi} - \frac{1}{2y_i}$$

Também,  $\theta_i = -\frac{1}{2\hat{\mu}_i^2} \Rightarrow \tilde{\theta}_i = -\frac{1}{2y_i^2}, b(\theta_i) = -\frac{1}{y_i}$

$$\Rightarrow b(\tilde{\theta}_i) = -\frac{1}{y_i}$$

$$\sum_{i=1}^m \left\{ \frac{1}{2\hat{\phi}} - \frac{1}{2y_i} \right\} = \frac{1}{2} D(\underline{y}; \hat{\alpha}) - \sum_{i=1}^m \left\{ y_i \cdot -\frac{1}{2y_i^2} + \frac{1}{y_i} \right\} \iff$$

$$\frac{m}{2\hat{\phi}} - \sum_{i=1}^m \frac{1}{2y_i} = \frac{1}{2} D(\underline{y}; \hat{\alpha}) - \sum_{i=1}^m \frac{1}{2y_i} \iff$$

$$\hat{\phi} = \frac{m}{D(\underline{y}; \hat{\alpha})}, \text{ com } D(\underline{y}; \hat{\alpha}) = \sum_{i=1}^m \frac{(y_i - \hat{\mu}_i)^2}{y_i \hat{\mu}_i^2}$$

Agora, note que o logaritmo da função de verossimilhança avaliada em  $\hat{\alpha} = (\hat{\beta}^+, \hat{\phi})^T$  é

$$\begin{aligned} l(\hat{\alpha}) &= \hat{\phi} \sum_{i=1}^m [y_i \hat{\mu}_i - b(\hat{\theta}_i)] + \sum_{i=1}^m c(y_i; \hat{\phi}) \\ &= \hat{\phi} \sum_{i=1}^m \left[ y_i \cdot -\frac{1}{2\hat{\mu}_i^2} + \frac{1}{\hat{\mu}_i} \right] + \sum_{i=1}^m \left[ \frac{1}{2} \log\left(\frac{\hat{\phi}}{2\pi y_i^3}\right) - \frac{\hat{\phi}}{2y_i} \right] \\ &= -\hat{\phi} \sum_{i=1}^m \frac{(y_i - \hat{\mu}_i)^2}{2\hat{\mu}_i^2 y_i} + \frac{m}{2} \log(\hat{\phi}) - \frac{1}{2} \sum_{i=1}^m \log(2\pi y_i^3) \\ &= -\frac{m}{D(\underline{y}; \hat{\alpha})} \frac{1}{2} D(\underline{y}; \hat{\alpha}) + \frac{m}{2} \log\left(\frac{m}{D(\underline{y}; \hat{\alpha})}\right) - \frac{1}{2} \sum_{i=1}^m \log(2\pi y_i^3) \end{aligned}$$

$$= -\frac{m}{2} - \frac{m}{2} \log\left(\frac{D(y; \hat{\theta})}{n}\right) + C,$$

em que  $C = -\frac{1}{2} \sum_{i=1}^m \log(2\pi y_i^3)$  não depende de  $\hat{\theta}$ .

Não, obtemos que

$$AIC = -2\ell(\hat{\theta}) + 2p$$

$$= m + m \log\left(\frac{D(y; \hat{\theta})}{n}\right) - 2C + 2p.$$

Portanto, o método de Akaike é equivalente a relacionar o modelo (NI) com menor valor para

$$m \log\left(\frac{D(y; \hat{\theta})}{n}\right) + 2p.$$

4) Suponha que  $y_i \stackrel{\text{ind}}{\sim} \text{Pascal}(r_i, \pi_i)$ ,  $i=1, 2, \dots, n$ , com componente sistemático dado por

$$\log\left(\frac{\pi_i}{1-\pi_i}\right) = \alpha.$$

a) Primeiro, note que

$$e^\alpha = \frac{\pi_i}{1-\pi_i} \iff \pi_i = \frac{e^\alpha}{1+e^\alpha}, \quad i=1, 2, \dots, n.$$

$$1-\pi_i = \frac{1}{1+e^\alpha}$$

O logaritmo da função de verossimilhança é

$$\begin{aligned}
 \ell(\alpha) &= \sum_{i=1}^m \log [f(y_i; \alpha, \pi_i)] \\
 &= \sum_{i=1}^m \log \left[ \binom{y_i-1}{n-1} \pi_i^{y_i} (1-\pi_i)^{n-y_i} \right] \\
 &= \sum_{i=1}^m \log \left( \frac{y_i-1}{n-1} \right) + n \sum_{i=1}^m \log \left( \frac{\pi_i}{1-\pi_i} \right) + \sum_{i=1}^m \log (1-\pi_i) y_i \\
 &= \sum_{i=1}^m \log \left( \frac{y_i-1}{n-1} \right) + n \sum_{i=1}^m \alpha + \sum_{i=1}^m y_i \log \left( \frac{1}{1+e^\alpha} \right) \\
 &= \sum_{i=1}^m \log \left( \frac{y_i-1}{n-1} \right) + n \alpha - \sum_{i=1}^m y_i \log (1+e^\alpha) \\
 &= \sum_{i=1}^m \log \left( \frac{y_i-1}{n-1} \right) + n \alpha - n \bar{y} \log (1+e^\alpha).
 \end{aligned}$$

A função escorre  $\pi_1 \alpha e^{-\alpha}$

$$U_\alpha = \frac{d \ell(\alpha)}{d \alpha} = nr = \frac{n \bar{y} e^\alpha}{1+e^\alpha}.$$

O FNV de  $\alpha, \hat{\alpha}$ , é obtido de  $U_\alpha = 0$ . Então,

$$U_\alpha = 0 \iff r = \frac{\bar{y} e^{\hat{\alpha}}}{1+e^{\hat{\alpha}}} \iff r + r e^{\hat{\alpha}} = \bar{y} e^{\hat{\alpha}}$$

$$\iff e^{\hat{\alpha}} (r - \bar{y}) = -r \Rightarrow \hat{\alpha} = \log \left( \frac{r}{\bar{y}-r} \right),$$

desde que  $\bar{y} > r$ .

Para obter a variância assintótica  $\text{var}(\hat{\alpha})$ , calcularemos a 2ª derivada de  $\ell(\alpha)$ :

$$U_2 = \frac{d}{d\alpha} U_2 = -n\bar{Y} \frac{e^\alpha(1+e^\alpha) - e^\alpha e^\alpha}{(1+e^\alpha)^2}$$

$$= -\frac{n\bar{Y} e^\alpha}{(1+e^\alpha)^2}.$$

Como as condições de regularidade são satisfeitas pela F.E., temos que a informação de Fisher para  $\alpha$  é

$$K_{\alpha\alpha} = E\{d - U_2'\} = E\left\{\frac{n\bar{Y} e^\alpha}{(1+e^\alpha)^2}\right\} = \frac{n e^\alpha}{(1+e^\alpha)^2} - E(\bar{Y}).$$

Já vimos que  $E(Y_i^*) = E\left(\frac{Y_i}{n}\right) = \frac{1}{n\bar{Y}}$ . Então,

$$E(Y_i) = nE(Y_i^*) = n/n\bar{Y}. \text{ Assim,}$$

$$E(Y_i) = \frac{n}{\frac{e^\alpha}{1+e^\alpha}} = \frac{n(1+e^\alpha)}{e^\alpha} \Rightarrow$$

$$E(\bar{Y}) = E\left(\frac{1}{n} \sum_{i=1}^n Y_i\right) = \frac{1}{n} \sum_{i=1}^n E(Y_i) = \frac{1}{n} \sum_{i=1}^n \frac{n(1+e^\alpha)}{e^\alpha}$$

$$= \frac{n(1+e^\alpha)}{e^\alpha}.$$

Portanto,

$$K_{\alpha\alpha} = \frac{n e^\alpha}{(1+e^\alpha)^2} \cdot \frac{n(1+e^\alpha)}{e^\alpha} = \frac{n^2}{1+e^\alpha}.$$

Implicando que  $\text{Var}(\hat{\alpha}) = \frac{1+e^\alpha}{n^2}$ .

2) Suponha que  $y_i \stackrel{\text{ind}}{\sim} \text{Poisson}(\lambda_i)$ , em que  $\sqrt{\lambda_i} = \eta_i$  com  $\eta_i = \alpha + \beta(x_i - \bar{x})$ ,  $i = 1, 2, \dots, n$ . Queremos testar  $H_0: \beta = 0$  contra  $H_1: \beta \neq 0$ .

a) Queremos escrever a matriz  $X$  do modelo tal que  $X\beta = \eta$ , com  $\eta = (\eta_1 \ \eta_2 \ \dots \ \eta_n)^T$ ,

$$\beta = (\alpha \ \beta)^T$$

$$X = \begin{bmatrix} 1 & x_1 - \bar{x} \\ 1 & x_2 - \bar{x} \\ \vdots & \vdots \\ 1 & x_n - \bar{x} \end{bmatrix} \xrightarrow{\text{matriz do modelo}}$$

b) Queremos obter a matriz de covariâncias assintóticas  $\text{Var}(\hat{\beta})$ . (4)

Para os MLEs vimos que a matriz de informação  $\mathbf{I}(\mathbf{P})$  é

$$K_{\mathbf{P}\mathbf{P}} = \phi \mathbf{X}^T \mathbf{W} \mathbf{X} \Rightarrow \text{Var}(\hat{\beta}) = \phi^{-1} (\mathbf{X}^T \mathbf{W} \mathbf{X})^{-1}$$

Como  $y_i \stackrel{\text{iid}}{\sim} \text{Poisson}(w_i)$ , temos que  $\phi = 1$ . Ainda, como  $\sqrt{w_i} = n_i$  (função de ligação raiz quadrada), sabemos que  $w_i = 4$ ,  $\forall i = 1, 2, \dots, n$ . Assim, obtemos que

$$\mathbf{W} = \text{diag}\{4, 4, \dots, 4\} = 4 \mathbf{I}_n \Rightarrow \text{Var}(\hat{\beta}) = \frac{1}{4} (\mathbf{X}^T \mathbf{X})^{-1}$$

Ainda

$$\mathbf{X}^T \mathbf{X} = \begin{bmatrix} 1 & 1 & \dots & 1 \\ \bar{x}_1 - \bar{x} & \bar{x}_2 - \bar{x} & \dots & \bar{x}_n - \bar{x} \end{bmatrix} \begin{bmatrix} 1 & \bar{x}_1 - \bar{x} \\ 1 & \bar{x}_2 - \bar{x} \\ \vdots & \vdots \\ 1 & \bar{x}_n - \bar{x} \end{bmatrix}$$

$$= \begin{bmatrix} m & \sum_{i=1}^m (x_i - \bar{x}) \\ \sum_{i=1}^m (x_i - \bar{x}) & \sum_{i=1}^m (x_i - \bar{x})^2 \end{bmatrix} = \begin{bmatrix} m & 0 \\ 0 & \sum_{i=1}^m (x_i - \bar{x})^2 \end{bmatrix},$$

pois  $\sum_{i=1}^m (x_i - \bar{x}) = 0$ . A inversa de  $\mathbf{X}^T \mathbf{X}$  é

$$(\mathbf{X}^T \mathbf{X})^{-1} = \begin{bmatrix} 1/m & 0 \\ 0 & 1 / \sum_{i=1}^m (x_i - \bar{x})^2 \end{bmatrix}.$$

Portanto, a matriz de covariâncias assintótica<sup>5</sup>  
fica dada por

$$\text{Var}(\hat{\beta}) = \begin{bmatrix} \frac{1}{4n} & 0 \\ 0 & \frac{1}{4 \sum_{i=1}^n (x_i - \bar{x})^2} \end{bmatrix} \Rightarrow \text{Var}(\hat{\alpha}) = \frac{1}{4n}$$