

d) Suponha que $Y_i \stackrel{\text{ind}}{\sim} \text{Pascal}(r, \pi_i)$, $i=1, 2, \dots, n$.

Sabemos que $\theta_i = \log(1-\pi_i) = \log\left(1 - \frac{1}{y_i}\right)$, e

$$b(\theta_i) = -\log\left(\frac{\pi_i}{1-\pi_i}\right) = -\log\left(\frac{y_i/r}{1-y_i/r}\right) = \log(y_i - r).$$

Aqui, $r_i = E(Y_i^*) = E\left(\frac{Y_i}{n}\right)$. Daí, $\hat{\pi}_i = Y_i^* = Y_i/n$.

Então,

$$\tilde{\theta}_i = \log\left(1 - \frac{1}{y_i}\right) = \log\left(1 - \frac{1}{Y_i^*}\right) = \log\left(1 - \frac{r}{Y_i}\right).$$

Veja que $\tilde{\theta}_i$ somente estará bem definido se

$$1 - \frac{r}{Y_i} > 0 \Rightarrow Y_i > r.$$

Também, $\hat{\theta}_i = \log(1-\hat{\pi}_i)$ e $b(\hat{\theta}_i) = -\log\left(\frac{\hat{\pi}_i}{1-\hat{\pi}_i}\right)$.

Para $Y_i > r$, o componente da função devio não escalonado é obtido de

$$d^2(Y_i; \hat{\pi}_i) = 2 \left\{ Y_i^* (\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right\}$$

$$= 2 \left\{ \frac{Y_i}{n} \left[\log\left(1 - \frac{r}{Y_i}\right) - \log(1 - \hat{\pi}_i) \right] \right.$$

$$\left. + \log\left(\frac{1 - \hat{\pi}_i}{\hat{\pi}_i}\right) - \log\left(\frac{Y_i}{n} - 1\right) \right\}$$

$$= 2 \left\{ \frac{Y_i}{n} \left[\log\left(\frac{Y_i - r}{Y_i}\right) - \log(1 - \hat{\pi}_i) \right] \right.$$

$$\left. + \log\left(\frac{1 - \hat{\pi}_i}{\hat{\pi}_i}\right) - \log\left(\frac{Y_i - r}{r}\right) \right\}.$$

Dai, o componente da função de verossimilhança escalonada é ④

$$d^{*2}(y_i; \hat{\pi}_i) = \phi d^2(y_i; \hat{\pi}_i)$$

$$= 2 \left\{ y_i \left[\log \left(\frac{y_i - n}{y_i} \right) - \log (1 - \hat{\pi}_i) \right] + n \left[\log \left(\frac{1 - \hat{\pi}_i}{\hat{\pi}_i} \right) - \log \left(\frac{y_i - n}{n} \right) \right] \right\}, \quad \underline{y_i > n}$$

Quando $y_i = n$, temos que
 $(y_i^* = 1)$

$$f_{Y^*}(1; \pi, \hat{\pi}_i) = \binom{n-1}{n-1} \hat{\pi}_i^n (1 - \hat{\pi}_i)^{n-n} = \hat{\pi}_i^n.$$

$$= \left(\frac{1}{\hat{\mu}} \right)^{\hat{\pi}_i}.$$

$$\hat{\mu} = y_i^* = y_i/n$$

$$\Rightarrow f_{Y^*}(1; n, \hat{\pi}_i) = \hat{\pi}_i^n = \left(\frac{1}{\hat{\mu}} \right)^n = \left(\frac{1}{1} \right)^n = 1;$$

$$\Rightarrow f_{Y^*}(n; n, \hat{\pi}_i) = \hat{\pi}_i^n = \left(\frac{1}{\hat{\mu}} \right)^n.$$

Assim,

$$d^{*2}(n; \hat{\pi}_i) = 2 \left\{ \log(1) - n \log(\hat{\pi}_i) \right\} = -2n \log(\hat{\pi}_i),$$

$$y_i = n.$$

Logo,

$$d^{*2}(y_i; \hat{\pi}_i) = \begin{cases} 2 \left\{ y_i \left[\log \left(\frac{y_i - n}{y_i} \right) - \log (1 - \hat{\pi}_i) \right] + n \left[\log \left(\frac{1 - \hat{\pi}_i}{\hat{\pi}_i} \right) - \log \left(\frac{y_i - n}{n} \right) \right] \right\}, & \text{se } y_i > n, \\ -2n \log(\hat{\pi}_i), & \text{se } y_i = n. \end{cases}$$

Se $n=2$, temos que

$$d^{\star 2}(y_i; \hat{\pi}_i) = \begin{cases} 2 \left\{ y_i \left[\log \left(\frac{y_i - 1}{y_i} \right) - \log (1 - \hat{\pi}_i) \right] \right. \\ \left. + \log \left(\frac{1 - \hat{\pi}_i}{\hat{\pi}_i} \right) - \log (y_i - 1), \quad y_i > 1, \right. \\ \left. - 2 \log (\hat{\pi}_i), \quad y_i = 1. \right. \end{cases}$$

c) Suponha que $y_i \stackrel{\text{ind}}{\sim} ES(x_i, \phi)$. ⑥

Sabemos que $\theta_i = e^{\mu_i}$ e $b(\theta_i) = -\theta_i[1 - \log(\theta_i)]$
 $= -e^{\mu_i}[1 - \log(e^{\mu_i})] = e^{\mu_i}(\mu_i - 1)$.

Assim,
 $\tilde{\theta}_i = e^{\tilde{\mu}_i} = e^{y_i}$ e $b(\tilde{\theta}_i) = e^{y_i}(y_i - 1)$. Também,
 $\hat{\theta}_i = e^{\hat{\mu}_i} = e^{\tilde{\mu}_i}(\hat{\mu}_i - 1)$.

Assim, o componente da função de vio escalonado é

$$\begin{aligned}
 d^{+2}(y_i; \hat{\mu}_i) &= \phi d^2(y_i; \hat{\mu}_i) \\
 &= 2\phi \{ y_i(\hat{\theta}_i - \tilde{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \} \\
 &= 2\phi \{ y_i [e^{y_i} - e^{\tilde{\mu}_i}] + e^{\tilde{\mu}_i}(\hat{\mu}_i - 1) \\
 &\quad - e^{y_i}(y_i - 1) \} \\
 &= 2\phi \{ e^{\tilde{\mu}_i}(\hat{\mu}_i - y_i - 1) + e^{y_i} \}.
 \end{aligned}$$

b) Queremos testar $H_0: \alpha = 0$ contra $H_1: \alpha \neq 0$

Via razões de verossimilhanças. Vemos que a estatística da RV e⁻ $\rightarrow \phi$ conhecido

$$\begin{aligned}\xi_{RV} &= 2 \{ \ell(\hat{\alpha}) - \ell(\alpha^0) \} \\ &= 2 \{ \ell(\hat{\alpha}) - \ell(0) \} \\ &= 2 \left\{ nr\hat{\alpha} - n\bar{y} \log(1 + e^{\hat{\alpha}}) + \sum_{i=1}^n \log \left(\frac{y_i-1}{r-1} \right) \right. \\ &\quad \left. - nr \cdot 0 + n\bar{y} \log(1 + e^0) - \sum_{i=1}^n \log \left(\frac{y_i-1}{n-1} \right) \right\} \\ &= 2 \left\{ nr\hat{\alpha} - n\bar{y} \log(1 + e^{\hat{\alpha}}) + n\bar{y} \log(2) \right\}. \\ &= 2 \left\{ nr\hat{\alpha} + n\bar{y} \log \left(\frac{2}{1+e^{\hat{\alpha}}} \right) \right\}.\end{aligned}$$

Substituindo $\hat{\alpha} = \log(r/(y-r))$ ficamos

com

$$\xi_{RV} = 2n \left\{ r \log \left(\frac{r}{y-r} \right) + \bar{y} \log \left(\frac{2}{1+r/(y-r)} \right) \right\}.$$

c) Sobre $H_0: \alpha = 0$, sabemos que $\xi_{RV} \xrightarrow{n \rightarrow \infty} \chi_{1,\alpha}^2$.

q: dimensão de \mathbb{R} .

Regra de decisão: Rejetamos $H_0: \alpha = 0$ ao nível de significância $\alpha \cdot 100\%$, se $\xi_{RV} \geq \chi_{1,\alpha}^2$ em que $\chi_{1,\alpha}^2$ é o quantil da distribuição χ_1^2 tal que $P(\chi_1^2 \geq \chi_{1,\alpha}^2) = \alpha$.

a) Vimos que a estatística de Wald para testar $H_0: \beta = \beta^0$ contra $H_1: \beta \neq \beta^0 \in \mathbb{R}^p$ é dada por

$$\xi_W = (\hat{\beta} - \beta^0)^+ [\hat{\text{Var}}(\hat{\beta})]^{-1} (\hat{\beta} - \beta^0) \xrightarrow[n \rightarrow \infty]{H_0} \chi_p^2$$

Aqui, temos que $\beta = \alpha$ (apenas o intercepto), $\beta^0 = 0$ (pois $H_0: \alpha = 0$). Além disso, vimos na

distância que o EMV de α , e a respectiva variância assintótica são dados por

$$\hat{\alpha} = \log\left(\frac{n}{\bar{y}-n}\right), \quad \bar{y} > n, \quad \text{e} \quad \text{Var}(\hat{\alpha}) = \frac{1 + e^{\hat{\alpha}}}{nr}.$$

$$\begin{aligned} \text{Então,} \quad \hat{\text{Var}}(\hat{\alpha}) &= \frac{1 + e^{\hat{\alpha}}}{nr} = \frac{1 + e^{\log\left(\frac{n}{\bar{y}-n}\right)}}{nr} \\ &= \frac{1 + \frac{n}{\bar{y}-n}}{nr} = \frac{\bar{y}}{nr(\bar{y}-n)}, \quad \bar{y} > n. \end{aligned}$$

Não, a estatística de Wald só testar

$H_0: \alpha = 0$ contra $H_1: \alpha \neq 0$ e

$$\xi_W = \frac{\hat{\alpha}^2}{\text{Var}(\hat{\alpha})} = \frac{\left[\log\left(\frac{n}{\bar{y}-\alpha}\right) \right]^2}{\frac{n}{\bar{y}}} = \frac{n\bar{y}(\bar{y}-\alpha) \log^2\left(\frac{n}{\bar{y}-\alpha}\right)}{\bar{y}}$$

Sob $H_0: \alpha = 0$, $\xi_W \xrightarrow[n \rightarrow \infty]{H_0} \chi_1^2$ pois $p=1$ (dimensão de β).
Logo distribuição nula assintótica de ξ_W .

Sendo assim, fixado nível α de significância, $0 < \alpha < 1$,
rejeita-se $H_0: \alpha = 0$ quando $\xi_W \geq \chi_{1,\alpha}^2$ e em que
 $\chi_{1,\alpha}^2$ é o quantil da distribuição qui-quadrado
com 1 grau de liberdade tal que $P(\chi_{1,\alpha}^2 \geq \chi_{1,\alpha}^2) = \alpha$.

b) Para testar $H_0: \beta = \beta^0$ contra $H_1: \beta \neq \beta^0$, a
estatística do teste escare é

$$\xi_{SR} = U_\beta(\beta^0)^T \widehat{\text{Var}}_0(\hat{\beta}) U_\beta(\beta^0) \xrightarrow[n \rightarrow \infty]{H_0} \chi_p^2.$$

Aqui, ficamos com $\xi_{SR} = U_\alpha(0)^T \widehat{\text{Var}}_0(\hat{\alpha}) \cdot$ Vimos
na dista 1 (que

$$U_\alpha = nr - \frac{n\bar{y}e^\alpha}{1+e^\alpha} \Rightarrow U_\alpha(0) = nr - \frac{n\bar{y}e^0}{1+e^0}$$

$$\Rightarrow U_\alpha(0) = nr - \frac{n\bar{y}}{2} = \frac{2nr - n\bar{y}}{2} = \frac{n(2r - \bar{y})}{2}$$

$$\text{Como } \text{Var}(\hat{\alpha}) = \frac{1+e^\alpha}{nr} \Rightarrow \text{Var}_0(\hat{\alpha}) = \frac{1+e^0}{nr} \quad (3)$$

$$\Rightarrow \text{Var}_0(\hat{\alpha}) = \frac{2}{nr}.$$

Assim, a estatística do teste escorre p/1 testar $H_0: \alpha = 0$ contra $H_1: \alpha \neq 0$ é

$$\xi_{SR} = \frac{n^2(2r-\bar{y})^2}{4} \cdot \frac{2}{nr} = \frac{n(2r-\bar{y})^2}{2r}.$$

Sob $H_0: \alpha = 0$, $\xi_{SR} \sim \chi^2_1$. Daí, rejeita-se H_0 , ao nível de significância $0 < \alpha < 1$, se $\xi_{SR} \geq \chi^2_{1,\alpha}$ em que $\chi^2_{1,\alpha}$ é tal que $P(\chi^2_1 \geq \chi^2_{1,\alpha}) = \alpha$.

c) Note que ao testar $H_0: \beta = 0$ contra $H_1: \beta \neq 0$ estamos testando se é uma subversão de $\beta = (\alpha, \beta)^T$ é diferente de zero. Vemos que para $\beta = (\beta_1, \beta_2)^T \in \mathbb{R}^p$, testar $H_0: \beta_1 = \beta_1^{(0)}$ contra $H_1: \beta_1 \neq \beta_1^{(0)}$, $\beta_1 \in \mathbb{R}^q$, testar $H_0: \beta_2 = \beta_2^{(0)}$ contra $H_1: \beta_2 \neq \beta_2^{(0)}$, a estatística do teste de

Wald é

$$\xi_W = (\hat{\beta}_1 - \beta_1^{(0)})^T \text{Var}(\hat{\beta}_1) (\hat{\beta}_1 - \beta_1^{(0)}) \xrightarrow[H_0]{n \uparrow \infty} \chi_q^2.$$

$$\text{Aqui, ficamos com } \xi_W = \frac{\hat{\beta}_1^2}{\text{Var}(\hat{\beta}_1)} \xrightarrow[H_0]{n \uparrow \infty} \chi_1^2.$$

$$\text{Temos que } \text{Var}(\hat{\beta}) = \hat{\text{Var}}(\hat{\beta}) = \frac{1}{4 \sum_{i=1}^m (x_i - \bar{x})^2}.$$

Já $\hat{\beta}$ é obtido de $\hat{\beta} = (\hat{\alpha}, \hat{\beta})^T$ tal que

$$U_{\beta}(\hat{\beta}) = \Omega_{xx}, \text{ em que } U_{\beta} = X^T V^{-1/2} (Y - \tilde{Y}),$$

em que $V^{-1/2} = \text{diag}\{\sqrt{|V_{11}|}, \sqrt{|V_{22}|}, \dots, \sqrt{|V_{nn}|}\}$,
pois $V_{ii} = V(x_i) = \lambda_i$ (Poisson).

6

De fato, vêa que

$$U_{\beta} = 2 \begin{bmatrix} 1 & 1 & \dots & 1 \\ x_1 - \bar{x} & x_2 - \bar{x} & \dots & x_n - \bar{x} \end{bmatrix} \begin{bmatrix} 1/\sqrt{\lambda_1} & 0 & \dots & 0 \\ 0 & 1/\sqrt{\lambda_2} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1/\sqrt{\lambda_m} \end{bmatrix} \begin{bmatrix} y_1 - \mu_1 \\ y_2 - \mu_2 \\ \vdots \\ y_n - \mu_m \end{bmatrix}$$

$$= 2 \begin{bmatrix} 1 & 1 & \dots & 1 \\ x_1 - \bar{x} & x_2 - \bar{x} & \dots & x_n - \bar{x} \end{bmatrix} \begin{bmatrix} (y_1 - \mu_1)/\sqrt{\lambda_1} \\ (y_2 - \mu_2)/\sqrt{\lambda_2} \\ \vdots \\ (y_n - \mu_m)/\sqrt{\lambda_m} \end{bmatrix}$$

$$= 2 \begin{bmatrix} \sum_{i=1}^m \frac{(y_i - \mu_i)}{\sqrt{\lambda_i}} \\ \sum_{i=1}^m \frac{(x_i - \bar{x})(y_i - \mu_i)}{\sqrt{\lambda_i}} \end{bmatrix} = \begin{bmatrix} U_{\alpha} \\ U_{\beta} \end{bmatrix}, \quad (*)$$

em que μ_i é tal que $\sqrt{\lambda_i} = \mu_i = \alpha + \beta(x_i - \bar{x})$.
 Assim, como não há forma fechada para $\hat{\beta}$,
 a estatística do teste de Wald ficará em
 termos de $\hat{\beta}$:

$$\xi_W = 4\hat{\beta}^2 \sum_{i=1}^m (x_i - \bar{x})^2 \stackrel{H_0}{\sim} \chi^2_1 \cdot \xi_W$$

dist. mala
asintótica de

obs: $\hat{\beta}$ é obtido de forma iterativa via o método
escor de Fisher.

d) Sob $H_0: \beta = 0$, a estatística do teste exponencial fica dada por

$$\xi_{SR} = U_{\beta}(\hat{\beta}^0) \widehat{\text{Var}}_{\beta}(\hat{\beta}) U_{\beta}(\hat{\beta}^0)$$

$$= [U_{\beta}(\hat{\beta}^0)]^2 \widehat{\text{Var}}_{\beta}(\hat{\beta}).$$

De (4) sabemos que

$$U_{\beta} = 2 \sum_{i=1}^m \frac{(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{s_{\beta}}} \Rightarrow$$

$$U_{\beta}(\hat{\beta}^0) = 2 \sum_{i=1}^m \frac{(x_i - \bar{x})(y_i - \hat{y}_i^0)}{\sqrt{\hat{s}_{\beta}^0}}, \quad \hat{\beta}^0 = \begin{pmatrix} \hat{\alpha}^0 \\ 0 \end{pmatrix},$$

$$\sqrt{\hat{s}_{\beta}^0} = \hat{s}_{\beta_1}^0 = \hat{\alpha}^0 + 0 \cdot (x_i - \bar{x}) = \hat{\alpha}^0, \text{ em que } \hat{\alpha}^0$$

$\hat{\alpha}^0$ é o EMV de α sob $H_0: \beta = 0$.

Sob $H_0: \beta = 0$, o valor $\hat{\alpha}^0$ é obtido de $U_{\alpha}^0 = 0$

$$\text{Sob } H_0: \beta = 0, \text{ o valor } \hat{\alpha}^0 \text{ é obtido de } U_{\alpha}^0 = 0$$

$$\Leftrightarrow \sqrt{\hat{s}_{\beta}^0} = \hat{\alpha}^0 \text{ e } \hat{s}_{\beta}^0 = (\hat{\alpha}^0)^2$$

$$\Leftrightarrow 2 \sum_{i=1}^m \frac{(y_i - \hat{y}_i^0)}{\sqrt{\hat{s}_{\beta}^0}} = 0 \Leftrightarrow 2 \sum_{i=1}^m \frac{[y_i - (\hat{\alpha}^0)^2]}{\hat{\alpha}^0} = 0$$

$$\Leftrightarrow \frac{2}{\hat{\alpha}^0} [m\bar{y} - m(\hat{\alpha}^0)^2] = 0 \Leftrightarrow \bar{y} = (\hat{\alpha}^0)^2 \Leftrightarrow \hat{\alpha}^0 = \bar{y}^{1/2}$$

$$\hat{\alpha}^0 = \bar{y}$$

Este resultado vale p/ todos MLG com componente sist. apenas com intercepto

Assim, o vetor $U_{\beta}(\hat{\beta}^0)$ fica expresso por

$$U_{\beta}(\hat{\beta}^0) = 2 \sum_{i=1}^m \frac{(x_i - \bar{x})(y_i - \bar{y})}{\bar{y}^{1/2}}.$$

Também, como $\text{Var}(\hat{\beta}) = \frac{1}{4 \sum_{i=1}^m (x_i - \bar{x})^2} = \text{Var}_{\beta^0}(\hat{\beta})$.

Logo, a estatística do teste escore é dada por

$$\xi_{SR} = \frac{4}{\bar{y}} \frac{\left(\sum_{i=1}^m (x_i - \bar{x})(y_i - \bar{y}) \right)^2}{\sum_{i=1}^m (x_i - \bar{x})^2} \stackrel{n \rightarrow \infty \text{ H}_0}{\sim} \chi_1^2 \text{ dist. nula asymptótica}$$

e) A estatística do teste da razão de verossimilhanças é dada por

$$\xi_{RV} = 2 \{ l(\hat{\beta}) - l(\hat{\beta}^0) \} \stackrel{n \rightarrow \infty}{\sim} \chi_q^2.$$

Sabemos que o logaritmo da função de verossimilhanças é

$$l(\beta) = \sum_{i=1}^m \{-r_i + y_i \log(r_i) - \log(y_i!)\} \Rightarrow$$

$$l(\hat{\beta}) = \sum_{i=1}^m \{-\hat{r}_i + y_i \log(\hat{r}_i) - \log(y_i!)\},$$

com $\hat{r}_i = \hat{x} + \hat{\beta}(x_i - \bar{x})$. Sabemos que

$$\hat{\beta}^0 = (\hat{x}^0 \ 0)^+ = (\bar{y}^{1/2} \ 0)^+ \cdot e^{\hat{r}^0} = (\hat{x}^0)^2.$$

(9)

Então,

$$\ell(\hat{\beta}^0) = \sum_{i=1}^m \left\{ -\hat{\mu}_i^0 + y_i \log(\hat{\mu}_i^0) - \log(y_i!) \right\}.$$

Assim, a estatística do TRV fica dada por

$$\xi_{RV} = 2 \sum_{i=1}^m \left\{ -\hat{\mu}_i + \hat{\mu}_i^0 + y_i \log(\hat{\mu}_i) - y_i \log(\hat{\mu}_i^0) - \log(y_i!) + \log(y_i!) \right\}$$

$$\hat{\mu}_i^0 = \bar{y}$$

$$= 2 \sum_{i=1}^m \left\{ \bar{y} - \hat{\mu}_i + y_i \log\left(\frac{\hat{\mu}_i}{\bar{y}}\right) \right\}.$$

Sob $H_0: \beta = 0$, a distribuição multianótica de

ξ_{RV} é χ^2_1 .

Poderemos ter expressado ξ_{RV} usando o resultado P1 ou M6s que

$$\xi_{RV} = \phi \{ D(\underline{y}; \hat{\beta}^0) - D(\underline{y}; \hat{\beta}) \}, \text{ em que}$$

$$D(\underline{y}; \hat{\beta}) = \sum_{i=1}^m d^2(y_i; \hat{\mu}_i), \text{ com}$$

$$d^2(y_i; \hat{\mu}_i) = \begin{cases} 2 \left[y_i \log\left(\frac{y_i}{\hat{\mu}_i}\right) + (\hat{\mu}_i - y_i) \right], & y_i > 0 \\ 2\hat{\mu}_i, & y_i = 0. \end{cases}$$

3) Suponha que $y_{ij} \stackrel{\text{ind}}{\sim} NI(x_{ij}, \phi)$, $i = 1, 2, \dots, m$, $j = 1, 2, \dots, n$, em que $\log(x_{ij}) = \alpha - \beta x_j$ e $\log(x_{i2}) = \alpha + \beta$. Queremos testar $H_0: \beta = 0$

contra $H_0: \beta \neq 0$.

a) Queremos escrever a matriz X do modelo tal que $X\beta = \eta$, $\beta = (\alpha, \beta)^T$ e

$$X_{2m \times 2} = \begin{bmatrix} 1 & -1 \\ 1 & -1 \\ \vdots & \vdots \\ 1 & -1 \\ 1 & 1 \\ 1 & 1 \\ \vdots & \vdots \\ 1 & 1 \end{bmatrix} \quad \begin{array}{l} m \text{ linhas} \\ \cdot \\ m \text{ linhas} \end{array}$$

$m=2m$

$x_2 \quad x_2 \quad X = [x_2 \ x_1]$

$$\log(\mu_1) = \eta_{1j} = \alpha - \beta$$

$$\log(\mu_2) = \eta_{2j} = \alpha + \beta, \quad j=1, 2, \dots, m.$$

b) Suponha que ϕ seja conhecido. Queremos expressar a estatística do teste escore R1 testar $H_0: \beta = 0$ contra $H_1: \beta \neq 0$.

$H_0: \beta = 0$ contra $H_1: \beta \neq 0$

Sabemos que $\gamma_{1j} \stackrel{\text{ind}}{\sim} NI(\mu_1, \phi)$ com $\mu_1 = e^{\alpha - \beta}$

e $\gamma_{2j} \stackrel{\text{ind}}{\sim} NI(\mu_2, \phi)$ com $\mu_2 = e^{\alpha + \beta}$, $j=1, 2, \dots, m$.

Note que sob $H_0: \beta = 0$, tem-se $\mu_1 = \mu_2 = e^\alpha$, i.e;

Queremos testar $H_0: \mu_1 = \mu_2$ contra $H_1: \mu_1 \neq \mu_2$.

Vemos que a estatística do teste escore pode ser escrita através de

$$\xi_{SR} = \hat{R}_{po}^{-1} \hat{W}_0 \hat{x}_2 \left(\hat{R}_0^{-1} \hat{W}_0 \hat{R}_0 \right)^{-1} \hat{x}_2 + \hat{W}_0 \hat{R}_{po}^{-1},$$

$$R = \hat{x}_2 - \hat{W}_0 \hat{x}_2 C, \quad C = (\hat{x}_2 + \hat{W}_0 \hat{x}_2)^{-1} \hat{x}_2 + \hat{W}_0 \hat{x}_2,$$

$$R_p = \phi^{1/2} V^{-1/2} (\hat{y} - \hat{u}).$$

como queremos testar $H_0: \beta = 0$ (subvector de β),
 particionaremos $X = [X_2 \ X_1]$. (11)

Vea que a matriz de pesos W é dada por

$$W = \text{diag}\{w_1, \dots, w_1, w_2, \dots, w_2\}, \quad w_i = (d_{ki}/d_{1i})^2/v_i.$$

$$\Rightarrow X_2^T W X_2 = [1 \dots 1 \ 1 \dots 1] \begin{bmatrix} w_1 & & & \\ & \ddots & & \\ & & w_1 & \\ & & & w_2 \end{bmatrix} X_2$$

$$= [w_1 \dots w_1 \ w_2 \dots w_2] \begin{bmatrix} 1 \\ \vdots \\ 1 \\ \vdots \\ 1 \\ \vdots \\ 1 \end{bmatrix}$$

$$= m(w_1 + w_2);$$

$$\Rightarrow X_2^T W X_1 = [w_1 \dots w_1 \ w_2 \dots w_2] \begin{bmatrix} -1 \\ \vdots \\ -1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} = m(w_2 - w_1);$$

$$\Rightarrow C = (X_2^T W X_2)^{-1} X_2^T W X_1 = \frac{m(w_2 - w_1)}{m(w_1 + w_2)} = \frac{w_2 - w_1}{w_1 + w_2};$$

$$\Rightarrow R = X_2 - X_2 C = \begin{bmatrix} -1 \\ \vdots \\ -1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} - \begin{bmatrix} 1 \\ \vdots \\ 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} \cdot \frac{(w_2 - w_1)}{w_1 + w_2} = \begin{bmatrix} -2w_1(w_1 + w_2) \\ \vdots \\ -2w_2((w_1 + w_2)) \\ 2w_1((w_1 + w_2)) \\ \vdots \\ 2w_2((w_1 + w_2)) \end{bmatrix}$$

$$\begin{aligned}
 \Rightarrow R^T W R &= \left[\frac{-2w_2}{w_1+w_2} \dots \frac{-2w_2}{w_1+w_2} \frac{2w_1}{w_1+w_2} \dots \frac{2w_1}{w_1+w_2} \right] \begin{bmatrix} w_1 \\ w_1 \\ w_2 \\ w_2 \end{bmatrix} R \\
 &= \left[\frac{-2w_1w_2}{w_1+w_2} \dots \frac{-2w_1w_2}{w_1+w_2} \frac{2w_1w_2}{w_1+w_2} \dots \frac{2w_1w_2}{w_1+w_2} \right] \begin{bmatrix} -2w_1(w_1+w_2) \\ -2w_2(w_1+w_2) \\ 2w_1(w_1+w_2) \\ 2w_2(w_1+w_2) \end{bmatrix} \\
 &= \frac{4m w_1 w_2^2}{(w_1+w_2)^2} + \frac{4m w_1^2 w_2}{(w_1+w_2)^2} \\
 &= \frac{4m w_1 + w_2 (w_2 + w_1)}{(w_1+w_2)^2} \\
 &= \frac{4m w_2 w_2}{w_1+w_2}.
 \end{aligned}$$

Agora, precisamos avaliar todas as quantidades sob H_0 : $\beta = 0$ ($\mu_1 = \mu_2$). Note que, sob H_0 , $w_1 = w_2 = w_0$. Então,

$$(\hat{R}_0^+ \hat{W}_0 \hat{R}_0)^{-1} = \frac{2 \hat{W}_0}{4m \hat{W}_0^2} (= \frac{1}{2m \hat{W}_0})$$

Também,

$$\hat{W}_0^{1/2} X_2 = \begin{bmatrix} \sqrt{\hat{W}_0} & & & \\ & \ddots & \sqrt{\hat{W}_0} & \\ & & \ddots & \sqrt{\hat{W}_0} \\ & & & \sqrt{\hat{W}_0} \end{bmatrix} \begin{bmatrix} -1 \\ \vdots \\ -1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} = \begin{bmatrix} -\sqrt{\hat{W}_0} \\ \vdots \\ -\sqrt{\hat{W}_0} \\ \sqrt{\hat{W}_0} \\ \vdots \\ \sqrt{\hat{W}_0} \end{bmatrix}.$$

Agora, precisamos de \hat{r}_{po} . As entradas do vetor \hat{r}_{po} são dadas por

$$r_{pj} = \frac{\sqrt{\phi}(y_{ij} - \mu)}{\sqrt{v_i}} \xrightarrow{\phi \text{ contínua}} \hat{r}_{pj} = \frac{\sqrt{\phi}(y_{ij} - \hat{r}_i^0)}{\sqrt{\hat{v}_i}},$$

em que $\hat{r}_i^0 = \bar{y}$ (este resultado vale p/ todos MLG apenas com intercepto), $i=1, 2$, $\hat{v}_i^0 = V(\hat{r}_i^0) = V(\bar{y}) = \bar{y}^3$ p/ $V(\mu) = \mu^3$ p/ a NI. Então, temos as entradas do vetor \hat{r}_{po} dadas por

$$\hat{r}_{pj}^0 = \frac{\sqrt{\phi}(y_{ij} - \bar{y})}{\sqrt{\bar{y}^3}}, \quad j=1, 2, \dots, 2m.$$

$$\Rightarrow \hat{R}_0^+ \hat{W}_0^{1/2} X_2 = [\hat{r}_{p1}^0 \dots \hat{r}_{pm}^0 \hat{r}_{p(m+1)}^0 \dots \hat{r}_{p2m}^0] \begin{bmatrix} -\sqrt{\hat{W}_0} \\ \vdots \\ -\sqrt{\hat{W}_0} \\ \sqrt{\hat{W}_0} \\ \vdots \\ \sqrt{\hat{W}_0} \end{bmatrix}$$

$$\begin{aligned}
 &= \sqrt{\hat{w}_0} \left\{ - \sum_{j=1}^m \frac{\sqrt{\phi} (y_{1j} - \bar{y})}{\sqrt{\bar{y}^3}} + \sum_{j=1}^m \frac{\sqrt{\phi} (y_{2j} - \bar{y})}{\sqrt{\bar{y}^3}} \right\} \quad (14) \\
 &= -\sqrt{\frac{\hat{w}_0 \phi}{\bar{y}^3}} \sum_{j=1}^m (y_{1j} - y_{2j}) \\
 &= \sqrt{\frac{\hat{w}_0 \phi}{\bar{y}^3}} m(\bar{y}_2 - \bar{y}_1), \text{ com } \hat{w}_0 = \frac{1}{\hat{\mu}_1^0} = \frac{1}{\bar{y}}
 \end{aligned}$$

Finalmente, a estatística do teste escore fica dada por

$$\xi_{SR} = \frac{\hat{w}_0 \phi}{\bar{y}^3} m^2 (\bar{y}_2 - \bar{y}_1)^2 \cdot \frac{1}{2m\hat{w}_0} = \frac{\phi m (\bar{y}_2 - \bar{y}_1)^2}{2\bar{y}^3}.$$

Sob $H_0: \beta = 0$, temos que $\xi_{SR} \xrightarrow{n \rightarrow \infty} \chi_1^2$.

c) Se ϕ for desconhecido, a estatística do teste escore fica dada pela expressão (**) substituindo ϕ pela sua estimativa de má-
-xima verossimilhança sob $H_0: \beta = 0$.

Sá vimos que o EMV de ϕ no caso da distribuição $N(\bar{y}, \hat{\mu}_1^2)$ é

$$\hat{\phi} = \frac{m}{D(y; \hat{\mu})}, \text{ em que } D(y; \hat{\mu}) = \sum_{i=1}^m \frac{(y_i - \hat{\mu}_i)^2}{y_i \hat{\mu}_i^2}.$$

Adptando a notação temos $\hat{\phi} = \frac{2m}{D(\underline{y}; \hat{\mu})}$, (15)

com

$$D(\underline{y}; \hat{\mu}) = \sum_{j=1}^m \frac{(y_{1j} - \hat{\mu}_1)^2}{y_{1j} \hat{\mu}_1^2} + \sum_{j=1}^m \frac{(y_{2j} - \hat{\mu}_2)^2}{y_{2j} \hat{\mu}_2^2}.$$

Sob $H_0: \beta = 0 (\mu_1 = \mu_2)$, temos que

$$\hat{\phi}^0 = \frac{2m}{D(\underline{y}; \hat{\mu}^0)}, \text{ em que}$$

$$D(\underline{y}; \hat{\mu}^0) = \frac{1}{\bar{y}^2} \left\{ \sum_{j=1}^m \frac{(y_{1j} - \bar{y})^2}{y_{1j}} + \sum_{j=1}^m \frac{(y_{2j} - \bar{y})^2}{y_{2j}} \right\}.$$

Logo,

$$\xi_{SR} = \frac{\hat{\phi}^0 m (\bar{y}_2 - \bar{y}_1)}{2 \bar{y}^3} \stackrel{H_0}{\sim} \chi_1^2.$$

d) Para expressar a estatística do teste de Wald p/ testar $H_0: \beta = 0$ contra $H_1: \beta \neq 0$, usaremos a expressão ($\hat{\phi}$ conhecido)

$$\xi_W = \hat{\phi} (\hat{\beta} - 0)^+ (\hat{R}^+ \hat{W} \hat{R}) (\hat{\beta} - 0).$$

$\hat{\beta}$ não possui forma fechada. Assim é obtida de forma iterativa via método escala de Fisher.

Já vimos que $R^+WR = \frac{4m\hat{w}_1\hat{w}_2}{\hat{w}_1 + \hat{w}_2}$. Daí, (16)

$$\hat{R}^+\hat{W}\hat{R} = \frac{4m\hat{w}_1\hat{w}_2}{\hat{w}_1 + \hat{w}_2}, \text{ em que } \hat{w}_1 = \frac{(d\mu_1/d\eta_1)^2}{V_1} \text{ e } \hat{w}_2 = \frac{(d\mu_2/d\eta_2)^2}{V_2}.$$

$$\hat{w}_1 = \frac{(d\mu_1/d\eta_1)^2}{V_1} \text{ e } \hat{w}_2 = \frac{(d\mu_2/d\eta_2)^2}{V_2}.$$

Vemos que p/ a distribuição NI quando a ligação é a logaritmica, $w_i = \frac{1}{\mu_i}$.

Então,

$$\hat{w}_1 = \frac{1}{\hat{\mu}_1}, \quad \hat{\mu}_1 = e^{\hat{\alpha} - \hat{\beta}}$$

$$\hat{w}_2 = \frac{1}{\hat{\mu}_2}, \quad \hat{\mu}_2 = e^{\hat{\alpha} + \hat{\beta}},$$

em que $\hat{\alpha} - \hat{\beta}$ são os EMVs de α e β (irrestritos).

Logo,

$$\xi_W = \phi \hat{\beta}^2 \cdot \frac{4m\hat{w}_1\hat{w}_2}{\hat{w}_1 + \hat{w}_2} \stackrel{H_0}{\sim} \chi_1^2. \quad (\star\star)$$

e) Quando ϕ é desconhecido, a estatística escreve é dada por $(\star\star)$ substituindo ϕ por $\hat{\phi}$ já obtida anteriormente. E, $\xi_W \stackrel{H_0}{\sim} \chi_1^2$.