

Modelos Lineares Generalizados

Modelo de regressão binomial negativa

Terezinha K. A. Ribeiro

terezinha.ribeiro@unb.br

Instituto de Ciências Exatas
Departamento de Estatística
Universidade de Brasília

- ▶ Distribuição binomial negativa
- ▶ Construção da distribuição
- ▶ Distribuição de Pascal
- ▶ Estrutura de regressão
- ▶ Estimação dos parâmetros

Distribuição binomial negativa

Seja Y uma variável aleatória com distribuição binomial negativa de parâmetros $\mu > 0$ e $\nu > 0$. A função de probabilidades de Y é dada por

$$f(y; \mu, \nu) = \frac{\Gamma(\nu + y)}{\Gamma(y + 1)\Gamma(\nu)} \left(\frac{\mu}{\mu + \nu}\right)^y \left(\frac{\nu}{\mu + \nu}\right)^\nu, \quad y \in \{0, 1, 2, \dots\}.$$

Denotaremos por $Y \sim \text{BN}(\mu, \nu)$.

Veja que

$$\begin{aligned} f(y; \mu, \nu) &= \exp \left\{ \log \left[\frac{\Gamma(\nu + y)}{\Gamma(y + 1)\Gamma(\nu)} \right] + y \log \left(\frac{\mu}{\mu + \nu} \right) + \nu \log \left(\frac{\nu}{\mu + \nu} \right) \right\} \\ &= \exp \left\{ \nu \left[\frac{y}{\nu} \log \left(\frac{\mu}{\mu + \nu} \right) + \log \left(\frac{\nu}{\mu + \nu} \right) \right] + \log \left[\frac{\Gamma(\nu + y)}{\Gamma(y + 1)\Gamma(\nu)} \right] \right\}. \end{aligned}$$

Construção da distribuição

Suponha que $Y|Z \sim \text{Poisson}(z)$ e $Z \sim \text{gama}(\mu, \nu)$, $\mu > 0$ e $\nu > 0$. Qual será a distribuição da variável aleatória Y ?

Sabemos que

$$f_{Y|Z=z}(y) = \frac{e^{-z} z^y}{y!}, \quad y \in \{0, 1, 2, \dots\},$$

$$g_Z(z; \mu, \nu) = \frac{1}{z} \frac{1}{\Gamma(\nu)} \left(\frac{z\nu}{\mu} \right)^\nu e^{-\nu z/\mu}, \quad z > 0.$$

Daí, a função de probabilidades de Y é

$$f(y; \mu, \nu) = \int_0^\infty f(y, z; \mu, \nu) dz,$$

em que $f(y, z; \mu, \nu)$ é a função densidade conjunta de Y e Z .

Construção da distribuição

Por definição,

$$\begin{aligned}f(y, z; \mu, \nu) &= f_{Y|Z=z}(y)g_Z(z; \mu, \nu) \\&= \frac{e^{-z}z^y}{y!} \frac{1}{z} \frac{1}{\Gamma(\nu)} \left(\frac{z\nu}{\mu}\right)^\nu e^{-\nu z/\mu} \\&= \frac{1}{y!} \left(\frac{\nu}{\mu}\right)^\nu \frac{1}{\Gamma(\nu)} e^{-z(1+\nu/\mu)} z^{\nu+y-1} \\&= \frac{1}{\Gamma(y+1)\Gamma(\nu)} \left(\frac{\nu}{\mu}\right)^\nu e^{-z(1+\nu/\mu)} z^{\nu+y-1}\end{aligned}$$

com $y \in \{0, 1, 2, \dots\}$, $z > 0$, $\nu > 0$.

Construção da distribuição

Assim, a função de probabilidades de Y é

$$\begin{aligned}f(y; \mu, \nu) &= \int_0^\infty \frac{1}{\Gamma(y+1)\Gamma(\nu)} \left(\frac{\nu}{\mu}\right)^\nu e^{-z(1+\nu/\mu)} z^{\nu+y-1} dz \\&= \frac{1}{\Gamma(y+1)\Gamma(\nu)} \left(\frac{\nu}{\mu}\right)^\nu \int_0^\infty e^{-z(1+\nu/\mu)} z^{\nu+y-1} dz.\end{aligned}$$

Faça

$$t = z(1 + \nu/\mu) \Rightarrow z = \frac{t}{1 + \nu/\mu} \Rightarrow \frac{dz}{dt} = \frac{1}{1 + \nu/\mu} \Rightarrow dz = \frac{1}{1 + \nu/\mu} dt.$$

Construção da distribuição

Logo, obtemos que

$$\begin{aligned}f(y; \mu, \nu) &= \frac{1}{\Gamma(y+1)\Gamma(\nu)} \left(\frac{\nu}{\mu}\right)^\nu \int_0^\infty e^{-t} \left(\frac{t}{1+\nu/\mu}\right)^{\nu+y-1} \frac{1}{1+\nu/\mu} dt \\&= \frac{1}{\Gamma(y+1)\Gamma(\nu)} \left(\frac{\nu}{\mu}\right)^\nu \frac{1}{(1+\nu/\mu)^{\nu+y}} \int_0^\infty e^{-t} t^{\nu+y-1} dt \\&= \frac{\Gamma(\nu+y)}{\Gamma(y+1)\Gamma(\nu)} \left(\frac{\nu}{\mu}\right)^\nu \frac{1}{(1+\nu/\mu)^{\nu+y}} \\&= \frac{\Gamma(\nu+y)}{\Gamma(y+1)\Gamma(\nu)} \left(\frac{\nu}{\mu}\right)^\nu \left(\frac{\mu}{\mu+\nu}\right)^{(\nu+y)} \\&= \frac{\Gamma(\nu+y)}{\Gamma(y+1)\Gamma(\nu)} \left(\frac{\mu}{\mu+\nu}\right)^y \left(\frac{\nu}{\mu+\nu}\right)^\nu.\end{aligned}$$

Distribuição binomial negativa

Inicialmente, considere o parâmetro ν conhecido. Assim, tomando como variável $Y^* = Y/\nu$, defina $\phi = \nu$,

$$\theta = \log \left(\frac{\mu}{\mu + \nu} \right) \Rightarrow \mu = \frac{\nu e^{\theta}}{1 - e^{\theta}}; \quad \theta < 0;$$

$$b(\theta) = -\log \left(\frac{\nu}{\mu + \nu} \right) = -\log(1 - e^{\theta});$$

$$c(y; \phi) = \log \left[\frac{\Gamma(\nu + y)}{\Gamma(y + 1)\Gamma(\nu)} \right] = \log \left[\frac{\Gamma(\phi + y)}{\Gamma(y + 1)\Gamma(\phi)} \right].$$

O suporte $y^* \in \{0, 1/\nu, 2/\nu, \dots\}$ não depende de parâmetros desconhecidos.

Neste caso, para ν um valor conhecido, $Y^* = Y/\nu \in \text{FE}(\mu, \phi)$.

Distribuição binomial negativa

Segue que

$$\mu^* = E(Y^*) = E\left(\frac{Y}{\nu}\right) = b'(\theta) = \frac{e^\theta}{1 - e^\theta} = \frac{\mu/(\mu + \nu)}{1 - \mu/(\mu + \nu)} = \frac{\mu}{\nu}.$$

Assim, $E(Y) = \mu$. Portanto, o parâmetro μ da distribuição binomial negativa é diretamente a média do modelo.

A função de variância é

$$\begin{aligned} V(\mu^*) &= b''(\theta) \\ &= \frac{e^\theta(1 - e^\theta) - e^\theta \cdot -e^\theta}{(1 - e^\theta)^2} \\ &= \frac{e^\theta}{1 - e^\theta} \frac{1}{1 - e^\theta} \\ &= \frac{\mu}{\nu} \frac{\mu + \nu}{\nu} \\ &= \frac{\mu(\mu + \nu)}{\nu^2}. \end{aligned}$$

Distribuição binomial negativa

$$\begin{aligned}\text{Var}(Y^*) &= \text{Var}\left(\frac{Y}{\nu}\right) \\ &= \phi^{-1} V(\mu^*) \\ &= \frac{1}{\nu} \frac{\mu(\mu + \nu)}{\nu^2} \\ &= \frac{\mu(\mu + \nu)}{\nu^3}.\end{aligned}$$

Isto implica que

$$\text{Var}(Y) = \nu^2 \text{Var}(Y^*) = \nu^2 \frac{\mu(\mu + \nu)}{\nu^3} = \frac{\mu(\mu + \nu)}{\nu}.$$

Observe que

$$\text{Var}(Y) = \frac{\mu^2}{\nu} + \mu > \mu.$$

Distribuição binomial negativa

Portanto, o modelo binomial negativa acomoda dados com sobredispersão.

Note que quanto maior for o parâmetro $\nu > 0$, menor será $\text{Var}(Y)$, e consequentemente, menor será a sobredispersão.

Apesar da distribuição de Poisson não ser um caso especial deste modelo, quando $\nu \rightarrow \infty$, a distribuição binomial negativa converge para a distribuição de Poisson de média μ .

Na prática, o parâmetro ν é desconhecido e deve estimado. Por esta razão, o modelo de regressão binomial negativa não é um MLG.

Distribuição de Pascal

A distribuição de Pascal é obtida como um caso especial da distribuição BN. Para tanto, considere

- ▶ $\nu = r > 0$ é um valor inteiro;
- ▶ tome $y' = y + r$, isto é, $y' \in \{r, r + 1, \dots\}$;
- ▶ $\pi = r/(\mu + r) \Rightarrow 1 - \pi = \mu/(\mu + r)$ com $0 < \pi < 1$.

Observe que

$$\frac{\Gamma(r+y)}{\Gamma(y+1)\Gamma(r)} = \frac{(r+y-1)!}{y!(r-1)!} = \binom{y+r-1}{y} = \binom{y'-1}{y'-r} = \binom{y'-1}{r-1}.$$

A função de probabilidade da binomial negativa fica expressa por

$$f(y; r, \pi) = \binom{y'-1}{r-1} \pi^r (1-\pi)^{y'-r}, \quad y' \in \{r, r+1, \dots\}.$$

Denota-se $Y' \sim \text{Pascal}(r, \pi)$.

Estrutura de regressão

Considere Y_1, Y_2, \dots, Y_n variáveis aleatórias independentes tais que $Y_i \sim \text{BN}(\mu_i, \phi)$. A função de probabilidade de Y_i é

$$f(y_i; \mu_i, \phi) = \frac{\Gamma(\phi + y_i)}{\Gamma(y_i + 1)\Gamma(\phi)} \left(\frac{\mu_i}{\mu_i + \phi} \right)^{y_i} \left(\frac{\phi}{\mu_i + \phi} \right)^{\phi},$$

em que $y_i \in \{0, 1, 2, \dots\}$, $\mu_i > 0$, $\phi > 0$ tais que

$$E(Y_i) = \mu_i, \quad \text{Var}(Y_i) = \mu_i + \frac{\mu_i^2}{\phi}.$$

Neste caso, temos

- ▶ média da resposta igual a μ_i ;
- ▶ variância dependente da média (heteroscedasticidade);
- ▶ variância maior do que a média;
- ▶ adequação para dados de contagem (alternativa ao MLG Poisson).

Estrutura de regressão

O modelo de regressão binomial negativa é definido por

i) $Y_i \mid \mathbf{x}_i \stackrel{\text{ind}}{\sim} \text{BN}(\mu_i, \phi)$

ii) $g(\mu_i) = \eta_i \Leftrightarrow \mu_i = g^{-1}(\eta_i)$ com $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$.

Como $\mu_i > 0$, analogamente ao MLG Poisson, as ligações mais utilizadas são

▶ $g(x) = \log(x)$;

▶ $g(x) = \sqrt{x}$;

▶ $g(x) = x$.

Estimação dos parâmetros

O logaritmo da função de verossimilhança para $\theta = (\beta^\top \phi)^\top$ é

$$\begin{aligned}\ell(\theta) &= \sum_{i=1}^n \left\{ \log \left[\frac{\Gamma(\phi + y_i)}{\Gamma(y_i + 1)\Gamma(\phi)} \right] + y_i \log \left(\frac{\mu_i}{\mu_i + \phi} \right) + \phi \log \left(\frac{\phi}{\mu_i + \phi} \right) \right\} \\ &= \sum_{i=1}^n \left\{ \log(\Gamma(\phi + y_i)) - \log(\Gamma(y_i + 1)) - \log(\Gamma(\phi)) \right. \\ &\quad \left. + y_i \log(\mu_i) + \phi \log(\phi) - (y_i + \phi) \log(\mu_i + \phi) \right\},\end{aligned}$$

com $\mu_i = g^{-1}(\eta_i)$.

O vetor escore para β é

$$U_{\beta}(\theta) = \frac{\partial \ell(\theta)}{\partial \beta}.$$

Estimação dos parâmetros

As entradas do vetor escore para β são obtidas de

$$\begin{aligned}\frac{\partial \ell(\theta)}{\partial \beta_j} &= \sum_{i=1}^n \left\{ \frac{y_i}{\mu_i} \frac{d\mu_i}{d\eta_i} \frac{\partial \eta_i}{\partial \beta_j} - \frac{(y_i + \phi)}{\mu_i + \phi} \frac{d\mu_i}{d\eta_i} \frac{\partial \eta_i}{\partial \beta_j} \right\} \\&= \sum_{i=1}^n \left\{ \frac{y_i}{\mu_i} - \frac{(y_i + \phi)}{\mu_i + \phi} \right\} \frac{d\mu_i}{d\eta_i} x_{ij} \\&= \sum_{i=1}^n \left\{ \frac{y_i(\mu_i + \phi) - \mu_i(y_i + \phi)}{\mu_i(\mu_i + \phi)} \right\} \frac{d\mu_i}{d\eta_i} x_{ij} \\&= \sum_{i=1}^n \left\{ \frac{y_i\mu_i + y_i\phi - \mu_i y_i - \mu_i\phi}{\mu_i(\mu_i + \phi)} \right\} \frac{d\mu_i}{d\eta_i} x_{ij} \\&= \sum_{i=1}^n \frac{\phi(y_i - \mu_i)}{\mu_i(\mu_i + \phi)} \frac{d\mu_i}{d\eta_i} x_{ij} \\&= \sum_{i=1}^n \frac{(y_i - \mu_i)}{(\mu_i^2/\phi + \mu_i)} \frac{d\mu_i}{d\eta_i} x_{ij}.\end{aligned}$$

Estimação dos parâmetros

Matricialmente,

$$U_{\beta}(\theta) = X^{\top} W F^{-1}(\mathbf{y} - \boldsymbol{\mu}),$$

em que X é a matriz do modelo $n \times p$, \mathbf{y} é o vetor de respostas, $\boldsymbol{\mu}$ é o vetor de médias, $W = \text{diag}\{\omega_1, \omega_2, \dots, \omega_n\}$, $F = \text{diag}\{f_1, f_2, \dots, f_n\}$,

$$\omega_i = \frac{(d\mu_i/d\eta_i)^2}{\mu_i + \mu_i^2/\phi}, \quad f_i = \frac{d\mu_i}{d\eta_i}.$$

A função escore para ϕ é dada por

$$\begin{aligned} U_{\phi} = \frac{\partial \ell(\theta)}{\partial \phi} &= \sum_{i=1}^n \left\{ \psi(\phi + y_i) - \psi(\phi) + \log(\phi) + \frac{\phi}{\phi} - \log(\mu_i + \phi) - \frac{(y_i + \phi)}{(\mu_i + \phi)} \right\} \\ &= \sum_{i=1}^n \left\{ \psi(\phi + y_i) - \psi(\phi) + \log\left(\frac{\phi}{\mu_i + \phi}\right) - \frac{(y_i + \phi)}{(\mu_i + \phi)} + 1 \right\}, \end{aligned}$$

em que $\psi(y) = d \log(\Gamma(y)) / dy$ é a função digama.

Estimação dos parâmetros

Para encontrar $\hat{\theta}$, fazemos

$$U_{\beta}(\theta) = \mathbf{0}, \quad U_{\phi}(\theta) = 0.$$

Observe que $\hat{\beta}$ e $\hat{\phi}$ não possuem forma fechada. Por esta razão, utiliza-se processo iterativo escore de Fisher para encontrar o valor de $\hat{\beta}$.

As demais quantidades inferenciais, testes de hipóteses, medidas de qualidade de ajuste e técnicas de diagnóstico podem ser desenvolvidas de forma análoga ao feito para os MLGs.