

Modelos Lineares Generalizados

Unidade II

Terezinha K. A. Ribeiro

terezinha.ribeiro@unb.br

Instituto de Ciências Exatas
Departamento de Estatística
Universidade de Brasília

- ▶ Modelo nulo e modelo saturado
- ▶ Função desvio
- ▶ Casos particulares
- ▶ Coeficiente de determinação
- ▶ Testes de hipóteses

Suponha que $Y_i | \mathbf{x}_i \stackrel{\text{ind}}{\sim} \text{FE}(\mu_i, \phi)$ e $g(\mu_i) = \beta_1$, para $i = 1, 2, \dots, n$.

Observe que o modelo suposto para os dados é um MLG que possui apenas o intercepto β_1 . Este modelo é usualmente conhecido por modelo nulo. Neste caso, a matriz do modelo X se reduz a um vetor coluna, formado de 1's.

O modelo nulo atribui toda a variação da resposta ao componente aleatório dos MLGs.

Como fica a estimativa de máxima verossimilhança para β_1 ? E a estimativa de μ_i ?

Neste caso, tem-se $\mu_i = g^{-1}(\beta_1)$ e $x_{i1} = 1$ para todo $i = 1, 2, \dots, n$.

Já vimos que o escore para β_j sob o MLG com p parâmetros é expresso por

$$U_{\beta_j} = \phi \sum_{i=1}^n (y_i - \mu_i) \frac{1}{V_i} \frac{d\mu_i}{d\eta_i} x_{ij}.$$

Se o modelo contém apenas o intercepto β_1 , então

$$U_{\beta_1} = \phi \sum_{i=1}^n (y_i - \mu_i) \frac{1}{V_i} \frac{d\mu_i}{d\eta_i},$$

em que μ_i , $V_i = V_i(\mu_i)$ e $d\mu_i/d\eta_i = [1/g'(\mu_i)]$ são constantes dependentes apenas de β_1 para todo i pois $\mu_i = g^{-1}(\beta_1)$.

Daí, a equação $U_{\beta_1} = 0$ implica que

$$\sum_{i=1}^n [y_i - g^{-1}(\hat{\beta}_1)] = 0 \Leftrightarrow \hat{\mu}_i = g^{-1}(\hat{\beta}_1) = \frac{1}{n} \sum_{i=1}^n y_i = \bar{y}, \forall i.$$

Note que

$$\hat{\beta}_1 = g(\hat{\mu}_i) = g(\bar{y}).$$

Portanto, os ajustes dos valores observados da resposta via o MLG apenas com o intercepto são diretamente a média amostral da resposta, isto é,

$$\hat{y}_i = \hat{\mu}_i = \bar{y}, \quad \forall i.$$

Modelo saturado

Em contrapartida, considere que $Y_i | \mathbf{x}_i \stackrel{\text{ind}}{\sim} \text{FE}(\mu_i, \phi)$ e $g(\mu_i) = \beta_i$, para $i = 1, 2, \dots, n$.

Observe que o modelo suposto para os dados é um MLG que possui n parâmetros, $\beta_1, \beta_2, \dots, \beta_n$. Mais especificamente,

$$\mu_1 = g^{-1}(\beta_1), \quad \mu_2 = g^{-1}(\beta_2), \quad \dots, \quad \mu_n = g^{-1}(\beta_n).$$

Este modelo é usualmente conhecido por modelo saturado ou modelo completo. Neste caso, a matriz do modelo é a matriz identidade de ordem n , isto é, $X = I_n$.

O modelo saturado atribui toda a variação da resposta ao componente sistemático dos MLGs pois ajusta-se perfeitamente aos dados.

Como ficam os EMVs para os parâmetros $\beta_1, \beta_2, \dots, \beta_n$? E a estimativa de μ_j ?

Note que a relação das respostas médias com os β 's é única e expressa por $g(\mu_i) = \beta_i$. Portanto, sob o modelo saturado podemos estimar diretamente as médias $\mu_1, \mu_2, \dots, \mu_n$, e posteriormente, estabelecer as estimativas de $\beta_1, \beta_2, \dots, \beta_n$.

Assim, o escore para $\mu_j, j = 1, 2, \dots, n$, sob o modelo saturado é

$$U_{\mu_j} = \phi \sum_{i=1}^n (y_i - \mu_i) \frac{1}{V_i}.$$

Modelo saturado

O vetor escore para $\mu = (\mu_1 \ \mu_2 \ \dots \ \mu_n)^\top$ é

$$U_\mu = \phi V^{-1}(\mathbf{y} - \mu),$$

em que $V = \text{diag}\{V_1, V_2, \dots, V_n\}$.

Daí, o EMV para o vetor de parâmetros μ é obtido de

$$\phi V^{-1}(\mathbf{y} - \tilde{\mu}) = \mathbf{0} \Leftrightarrow V^{-1}(\mathbf{y} - \tilde{\mu}) = \mathbf{0} \Leftrightarrow \tilde{\mu} = \mathbf{y}.$$

em que $\tilde{\mu}$ denota o EMV de μ sob o modelo saturado.

Logo, obtivemos que $\tilde{\mu}_i = y_i, \forall i$, e conseqüentemente,

$$\tilde{\beta}_i = g(\tilde{\mu}_i) = g(y_i).$$

Perceba que devido a $\hat{y}_i = \tilde{\mu}_i = y_i, \forall i$, o modelo saturado possui o ajuste perfeito aos dados.

Função desvio

Na prática, queremos ter um bom ajuste de um modelo suposto aos dados que possua $p < n$ parâmetros.

Para avaliar o quão bom é o ajuste sob um modelo com $p < n$ parâmetros, pode-se comparar a distância entre o ajuste via o modelo saturado e o modelo com p parâmetros. Essa mensuração pode ser feita através da função desvio.

A função desvio é definida por

$$D^*(\mathbf{y}; \hat{\boldsymbol{\mu}}) = \sum_{i=1}^n d^{*2}(y_i; \hat{\mu}_i) = 2 \{ \ell(\tilde{\boldsymbol{\mu}}) - \ell(\hat{\boldsymbol{\mu}}) \},$$

em que $\ell(\boldsymbol{\mu})$ é o logaritmo da função de verossimilhança avaliado em $\boldsymbol{\mu}$.

Por definição $D^*(\mathbf{y}; \hat{\boldsymbol{\mu}}) \geq 0$.

Função desvio

A quantidade $D^*(\mathbf{y}; \hat{\mu})$ é uma medida de qualidade de ajuste do modelo.

Note que para $p = n$ tem-se $D^*(\mathbf{y}; \hat{\mu}) = 0$.

Um valor pequeno para o desvio $D^*(\mathbf{y}; \hat{\mu})$ indica que, para um menor número de parâmetros $p < n$, obtemos um ajuste aos dados tão bom quanto sob o modelo saturado.

Portanto, sob um modelo bem ajustado aos dados, espera-se um valor pequeno para o desvio.

A função desvio pode ser definida sob qualquer classe de modelos de regressão. Não é uma medida que é útil apenas para os MLGs.

Função desvio

Na família exponencial uniparamétrica, supondo ϕ conhecido,

$$\ell(\boldsymbol{\mu}) = \sum_{i=1}^n \ell(\mu_i),$$

em que

$$\ell(\mu_i) = \phi[y_i\theta_i - b(\theta_i)] + c(y_i; \phi).$$

Segue que

$$\begin{aligned} D^*(\mathbf{y}; \hat{\boldsymbol{\mu}}) &= 2 \{ \ell(\tilde{\boldsymbol{\mu}}) - \ell(\hat{\boldsymbol{\mu}}) \} \\ &= 2 \sum_{i=1}^n [\ell(\tilde{\mu}_i) - \ell(\hat{\mu}_i)] \\ &= 2 \sum_{i=1}^n \left\{ \phi[y_i\tilde{\theta}_i - b(\tilde{\theta}_i)] + c(y_i; \phi) - \phi[y_i\hat{\theta}_i - b(\hat{\theta}_i)] - c(y_i; \phi) \right\} \\ &= 2 \sum_{i=1}^n \left\{ \phi[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i)] \right\}. \end{aligned}$$

Função desvio

Assim, a função desvio sob os MLGs pode ser expressa através de

$$D^*(\mathbf{y}; \hat{\boldsymbol{\mu}}) = \phi D(\mathbf{y}; \hat{\boldsymbol{\mu}}),$$

com

$$D(\mathbf{y}; \hat{\boldsymbol{\mu}}) = \sum_{i=1}^n d^2(y_i; \hat{\mu}_i), \quad d^{*2}(y_i; \hat{\mu}_i) = \phi d^2(y_i; \hat{\mu}_i),$$

$$d^2(y_i; \hat{\mu}_i) = 2 \left\{ y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right\}.$$

A quantidade $D(\mathbf{y}; \hat{\boldsymbol{\mu}})$ é chamado de desvio não escalonado.

Veremos mais à frente que os desvios individuais $d^{*2}(y_i; \hat{\mu}_i)$ serão utilizados para construir os resíduos conhecidos como componente do desvio.

Casos particulares - Distribuição normal

Sob o modelo normal, já vimos que $\theta_i = \mu_i$, $b(\theta_i) = \theta_i^2/2 = \mu_i^2/2$.

Assim, obtemos que

- ▶ as estimativas sob o modelo saturado são $\tilde{\theta}_i = \tilde{\mu}_i = y_i$, $b(\tilde{\theta}_i) = y_i^2/2$;
- ▶ as estimativas sob o modelo com p parâmetros são $\hat{\theta}_i = \hat{\mu}_i$, $b(\hat{\theta}_i) = \hat{\mu}_i^2/2$.

Daí, segue que o componente do desvio não escalonado é

$$\begin{aligned}d^2(y_i; \hat{\mu}_i) &= 2 \left\{ y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right\} \\&= 2 \left\{ y_i(y_i - \hat{\mu}_i) + \hat{\mu}_i^2/2 - y_i^2/2 \right\} \\&= 2 \left\{ \frac{2y_i^2 - 2y_i\hat{\mu}_i + \hat{\mu}_i^2 - y_i^2}{2} \right\} \\&= (y_i - \hat{\mu}_i)^2.\end{aligned}$$

Casos particulares - Distribuição normal

Neste caso, $\phi = 1/\sigma^2$, então o componente do desvio escalonado fica dado por

$$d^{*2}(y_i; \hat{\mu}_i) = \frac{(y_i - \hat{\mu}_i)^2}{\sigma^2}.$$

Portanto, a função desvio (escalonada) é

$$D^*(\mathbf{y}; \hat{\boldsymbol{\mu}}) = \sum_{i=1}^n \frac{(y_i - \hat{\mu}_i)^2}{\sigma^2} = \frac{\text{SQRes}}{\sigma^2},$$

em que $\text{SQRes} = \sum_{i=1}^n (y_i - \hat{\mu}_i)^2$ é a conhecida soma de quadrados dos resíduos sob o modelo de regressão normal.

Casos particulares - Distribuição normal

Sob a suposição $Y_i \mid \mathbf{x}_i \stackrel{\text{ind}}{\sim} N(\mu_i, \sigma^2)$, mostra-se que

$$D^*(\mathbf{y}; \hat{\boldsymbol{\mu}}) = \frac{\text{SQRes}}{\sigma^2} \sim \chi_{n-p}^2,$$

com χ_{n-p}^2 denota a distribuição qui-quadrado com $(n - p)$ graus de liberdade.

Este resultado implica que $E(D^*(\mathbf{y}; \hat{\boldsymbol{\mu}})) = n - p$. Por esta razão, um valor do desvio $D^*(\mathbf{y}; \hat{\boldsymbol{\mu}})$ próximo de $(n - p)$ indica que o modelo está bem ajustado.

Casos particulares - Distribuição Poisson

Sob o modelo Poisson, $\theta_i = \log(\mu_i)$, $b(\theta_i) = e^{\theta_i} = \mu_i$, e $\phi = 1$.

Assim, obtemos que

- ▶ as estimativas sob o modelo saturado são $\tilde{\theta}_i = \log(\tilde{\mu}_i) = \log(y_i)$, $b(\tilde{\theta}_i) = \tilde{\mu}_i = y_i$ com $y_i > 0$;
- ▶ as estimativas sob o modelo com p parâmetros são $\hat{\theta}_i = \log(\hat{\mu}_i)$, $b(\hat{\theta}_i) = \hat{\mu}_i$.

Daí, segue que o componente do desvio escalonado é

$$\begin{aligned}d^{*2}(y_i; \hat{\mu}_i) &= d^2(y_i; \hat{\mu}_i) \\&= 2 \left\{ y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right\} \\&= 2 \left\{ y_i(\log(y_i) - \log(\hat{\mu}_i)) + \hat{\mu}_i - y_i \right\} \\&= 2 \left\{ y_i \log \left(\frac{y_i}{\hat{\mu}_i} \right) + (\hat{\mu}_i - y_i) \right\}.\end{aligned}$$

Casos particulares - Distribuição Poisson

O que acontece quando $y_i = 0$? Vamos utilizar a definição de função desvio. Sabemos que

$$D^*(\mathbf{y}; \hat{\boldsymbol{\mu}}) = 2 \{ \ell(\tilde{\boldsymbol{\mu}}) - \ell(\hat{\boldsymbol{\mu}}) \} = 2 \sum_{i=1}^n [\ell(\tilde{\mu}_i) - \ell(\hat{\mu}_i)].$$

Então, para a observação y_i ,

$$d^{*2}(y_i; \hat{\mu}_i) = 2[\ell(\tilde{\mu}_i) - \ell(\hat{\mu}_i)] = 2[\log(f(y_i; \tilde{\mu}_i)) - \log(f(y_i; \hat{\mu}_i))].$$

Quando $y_i = 0$, a função de probabilidade da distribuição Poisson é $f(0; \mu_i) = e^{-\mu_i}$. Daí, segue que

$$f(0; \tilde{\mu}_i) = e^{-\tilde{\mu}_i} = e^{-0} = 1; \quad f(0; \hat{\mu}_i) = e^{-\hat{\mu}_i}.$$

Casos particulares - Distribuição Poisson

Assim, para $y_i = 0$,

$$d^{*2}(0; \hat{\mu}_i) = 2[\log(f(0; \hat{\mu}_i)) - \log(f(0; \hat{\mu}_i))] = 2[\log(1) + \hat{\mu}_i] = 2\hat{\mu}_i.$$

Portanto, o componente do desvio escalonado é expresso por

$$d^{*2}(y_i; \hat{\mu}_i) = 2 \left\{ y_i \log \left(\frac{y_i}{\hat{\mu}_i} \right) + (\hat{\mu}_i - y_i) \right\}, \quad y_i \in \{1, 2, 3, \dots\},$$

e para $y_i = 0$ é $d^{*2}(0; \hat{\mu}_i) = 2\hat{\mu}_i$.

Para $\mu_i \rightarrow \infty$, $\forall i$, $D^*(\mathbf{y}; \hat{\boldsymbol{\mu}})$ se aproxima da distribuição χ^2_{n-p} .

Casos particulares - Distribuição gama

Sob o modelo gama, $\theta_i = -1/\mu_i$, $b(\theta_i) = \log(\mu_i)$.

Assim, obtemos que

- ▶ as estimativas sob o modelo saturado são $\tilde{\theta}_i = -1/\tilde{\mu}_i = -1/y_i$, $b(\tilde{\theta}_i) = \log(\tilde{\mu}_i) = \log(y_i)$;
- ▶ as estimativas sob o modelo com p parâmetros são $\hat{\theta}_i = -1/\hat{\mu}_i$, $b(\hat{\theta}_i) = \log(\hat{\mu}_i)$.

Daí, segue que o componente do desvio não escalonado é

$$\begin{aligned}d^2(y_i; \hat{\mu}_i) &= 2 \left\{ y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right\} \\&= 2 \left\{ y_i \left(-\frac{1}{y_i} + \frac{1}{\hat{\mu}_i} \right) + \log(\hat{\mu}_i) - \log(y_i) \right\} \\&= 2 \left\{ \frac{(y_i - \hat{\mu}_i)}{\hat{\mu}_i} + \log \left(\frac{\hat{\mu}_i}{y_i} \right) \right\}.\end{aligned}$$

Consequentemente, $d^{*2}(y_i; \hat{\mu}_i) = \phi d^2(y_i; \hat{\mu}_i)$.

Quando ϕ é grande, mostra-se que

$$D^*(\mathbf{y}; \hat{\boldsymbol{\mu}}) \sim \chi^2_{n-p}.$$

Alguns trabalhos na literatura apontam que valores de ϕ a partir de 5 já se mostram grandes o suficiente para a aproximação ser razoável.

Casos particulares - Distribuição normal inversa

Sob o modelo normal inverso, $\theta_i = -1/2\mu_i^2$, $b(\theta_i) = -1/\mu_i$.

Assim, obtemos que

- ▶ as estimativas sob o modelo saturado são $\tilde{\theta}_i = -1/2\tilde{\mu}_i^2 = -1/2y_i^2$, $b(\tilde{\theta}_i) = -1/\tilde{\mu}_i = -1/y_i$;
- ▶ as estimativas sob o modelo com p parâmetros são $\hat{\theta}_i = -1/2\hat{\mu}_i^2$, $b(\hat{\theta}_i) = -1/\hat{\mu}_i$.

Daí, segue que o componente do desvio não escalonado é

$$\begin{aligned}d^2(y_i; \hat{\mu}_i) &= 2 \left\{ y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right\} \\ &= 2 \left\{ y_i \left(-\frac{1}{2y_i^2} + \frac{1}{2\hat{\mu}_i^2} \right) + \frac{1}{y_i} - \frac{1}{\hat{\mu}_i} \right\}.\end{aligned}$$

Casos particulares - Distribuição normal inversa

$$\begin{aligned}d^2(y_i; \hat{\mu}_i) &= -\frac{1}{y_i} + \frac{y_i}{\hat{\mu}_i^2} + \frac{2}{y_i} - \frac{2}{\hat{\mu}_i} \\&= \frac{-\hat{\mu}_i^2 + y_i^2 + 2\hat{\mu}_i^2 - 2y_i\hat{\mu}_i}{y_i\hat{\mu}_i^2} \\&= \frac{(y_i - \hat{\mu}_i)^2}{y_i\hat{\mu}_i^2}.\end{aligned}$$

Portanto, o componente do desvio escalonado é

$$d^{*2}(y_i; \hat{\mu}_i) = \phi d^2(y_i; \hat{\mu}_i) = \phi \frac{(y_i - \hat{\mu}_i)^2}{y_i\hat{\mu}_i^2}.$$

Analogamente, para ϕ é grande, mostra-se que

$$D^*(\mathbf{y}; \hat{\boldsymbol{\mu}}) \sim \chi_{n-p}^2.$$

Casos particulares - Distribuição binomial

Suponha que $Y_i \sim \text{binomial}(n_i, \mu_i)$, $0 < \mu_i < 1$, $\phi_i = n_i$, $i = 1, 2, \dots, k$.

Neste caso, $Y_i^* = Y_i/n_i \in \text{FE}(\mu_i, \phi_i)$ com $\mu_i = E(Y_i^*)$. Daí, tem-se que $\theta_i = \log(\mu_i/(1 - \mu_i))$, e $b(\theta_i) = -\log(1 - \mu_i)$.

Perceba que

$$\tilde{\mu}_i = y_i^* = \frac{y_i}{n_i}.$$

Assim,

- ▶ as estimativas sob o modelo saturado são

$$\tilde{\theta}_i = \log\left(\frac{\tilde{\mu}_i}{1 - \tilde{\mu}_i}\right) = \log\left(\frac{y_i^*}{1 - y_i^*}\right) = \log\left(\frac{y_i/n_i}{1 - y_i/n_i}\right),$$

$$b(\tilde{\theta}_i) = -\log(1 - \tilde{\mu}_i) = -\log(1 - y_i^*) = -\log(1 - y_i/n_i);$$

Casos particulares - Distribuição binomial

- ▶ as estimativas sob o modelo com p parâmetros são

$$\hat{\theta}_i = \log \left(\frac{\hat{\mu}_i}{1 - \hat{\mu}_i} \right), \quad b(\hat{\theta}_i) = -\log(1 - \hat{\mu}_i).$$

Daí, segue que o componente do desvio não escalonado é

$$\begin{aligned} d^2(y_i^*; \hat{\mu}_i) &= 2 \left\{ y_i^* (\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right\} \\ &= 2 \left\{ \frac{y_i}{n_i} \left[\log \left(\frac{y_i/n_i}{1 - y_i/n_i} \right) - \log \left(\frac{\hat{\mu}_i}{1 - \hat{\mu}_i} \right) \right] \right. \\ &\quad \left. + \log(1 - y_i/n_i) - \log(1 - \hat{\mu}_i) \right\} \\ &= 2 \left\{ \frac{y_i}{n_i} [\log(y_i/n_i) - \log(1 - y_i/n_i) - \log(\hat{\mu}_i) + \log(1 - \hat{\mu}_i)] \right. \\ &\quad \left. + \log(1 - y_i/n_i) - \log(1 - \hat{\mu}_i) \right\} \end{aligned}$$

Casos particulares - Distribuição binomial

$$\begin{aligned}d^2(y_i^*; \hat{\mu}_i) &= 2 \left\{ \frac{y_i}{n_i} \left[\log \left(\frac{y_i}{n_i \hat{\mu}_i} \right) - \log \left(\frac{1 - y_i/n_i}{1 - \hat{\mu}_i} \right) \right] + \log \left(\frac{1 - y_i/n_i}{1 - \hat{\mu}_i} \right) \right\} \\&= 2 \left\{ \frac{y_i}{n_i} \log \left(\frac{y_i}{n_i \hat{\mu}_i} \right) + \left(1 - \frac{y_i}{n_i} \right) \log \left(\frac{1 - y_i/n_i}{1 - \hat{\mu}_i} \right) \right\}.\end{aligned}$$

Daí, o componente do desvio escalonado fica dado por

$$\begin{aligned}d^{*2}(y_i^*; \hat{\mu}_i) &= n_i d^2(y_i^*; \hat{\mu}_i) \\&= 2 \left\{ y_i \log \left(\frac{y_i}{n_i \hat{\mu}_i} \right) + (n_i - y_i) \log \left(\frac{1 - y_i/n_i}{1 - \hat{\mu}_i} \right) \right\},\end{aligned}$$

desde que $y_i \in \{1, 2, \dots, n_i - 1\}$ ou $y_i^* \in \{1/n_i, 2/n_i, \dots, (n_i - 1)/n_i\}$.

Casos particulares - Distribuição binomial

Quando $y_i^* = 0$ ($y_i = 0$) e $y_i^* = 1$ ($y_i = n_i$), a quantidade anterior não está bem definida.

Pela definição de função desvio, sabemos que para a observação y_i ,

$$d^{*2}(y_i^*; \hat{\mu}_i) = 2[\ell(\tilde{\mu}_i) - \ell(\hat{\mu}_i)] = 2[\log(f(y_i^*; \tilde{\mu}_i)) - \log(f(y_i^*; \hat{\mu}_i))].$$

Para $y_i^* = 0$ (ou $y_i = 0$), a função de probabilidade de Y_i^* fica dada por

$$f(0; \mu_i) = \binom{n_i}{n_i \times 0} \mu_i^{n_i \times 0} (1 - \mu_i)^{n_i - n_i \times 0} = (1 - \mu_i)^{n_i}.$$

Casos particulares - Distribuição binomial

Segue que

$$f(0; \tilde{\mu}_i) = (1 - \tilde{\mu}_i)^{n_i} = (1 - \tilde{\mu}_i)^{n_i} = (1 - 0)^{n_i} = 1;$$

$$f(0; \hat{\mu}_i) = (1 - \hat{\mu}_i)^{n_i};$$

Então, o componente do desvio escalonado para $y_i^* = 0$ (ou $y_i = 0$) é

$$\begin{aligned} d^{*2}(0; \hat{\mu}_i) &= 2[\log(f(0; \tilde{\mu}_i)) - \log(f(0; \hat{\mu}_i))] \\ &= 2[\log(1) - \log((1 - \hat{\mu}_i)^{n_i})] \\ &= -2n_i \log(1 - \hat{\mu}_i). \end{aligned}$$

Casos particulares - Distribuição binomial

Para $y_i^* = 1$ (ou $y_i = n_i$), a função de probabilidade de Y_i^* fica dada por

$$f(1; \mu_i) = \binom{n_i}{n_i \times 1} \mu_i^{n_i \times 1} (1 - \mu_i)^{n_i - n_i \times 1} = \mu_i^{n_i}.$$

Segue que

$$f(1; \tilde{\mu}_i) = \tilde{\mu}_i^{n_i} = 1^{n_i} = 1;$$

$$f(1; \hat{\mu}_i) = \hat{\mu}_i^{n_i}.$$

O componente do desvio escalonado para $y_i^* = 1$ (ou $y_i = n_i$) é

$$\begin{aligned} d^{*2}(1; \hat{\mu}_i) &= 2[\log(f(1; \tilde{\mu}_i)) - \log(f(1; \hat{\mu}_i))] \\ &= 2[\log(1) - \log(\hat{\mu}_i^{n_i})] \\ &= -2n_i \log(\hat{\mu}_i). \end{aligned}$$

Casos particulares - Distribuição binomial

Resumindo, o componente do desvio escalonado fica dado por

$$d^{*2}(y_i^*; \hat{\mu}_i) = \begin{cases} 2 \left\{ y_i \log \left(\frac{y_i}{n_i \hat{\mu}_i} \right) + (n_i - y_i) \log \left(\frac{1 - y_i/n_i}{1 - \hat{\mu}_i} \right) \right\}, & y_i^* \in \left\{ \frac{1}{n_i}, \dots, \frac{n_i-1}{n_i} \right\} \\ -2n_i \log(1 - \hat{\mu}_i), & y_i^* = 0, \\ -2n_i \log(\hat{\mu}_i), & y_i^* = 1, \end{cases}$$

em que $0 < \hat{\mu}_i < 1$.

Para n_i , $\forall i$ grande, mostra-se que

$$D^*(\mathbf{y}; \hat{\boldsymbol{\mu}}) \sim \chi_{k-p}^2.$$

Coefficiente de determinação

Sob o modelo de regressão linear normal, define-se o coeficiente de determinação ou coeficiente de explicação do modelo de regressão ajustado através de

$$R^2 = 1 - \frac{\text{SQRes}}{\text{SQT}} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}.$$

Por definição $0 \leq R^2 \leq 1$ é a proporção da variação da resposta Y que é explicada pela regressão linear normal ajustada.

Esta medida possui algumas problemas:

- ▶ R^2 tende a ser maior quando o tamanho amostral é pequeno;
- ▶ R^2 sempre aumenta com inclusão de novas covariáveis.

Coeficiente de determinação

Para corrigir os problemas citados, utiliza-se o coeficiente de determinação ajustado definido por

$$R_a^2 = 1 - \frac{\text{SQRes}/(n-p)}{\text{SQT}/(n-1)}.$$

Diferentemente de R^2 , a medida R_a^2 não é uma proporção.

Mostra-se que

$$R_a^2 = R^2 - \frac{p-1}{n-p}(1 - R^2).$$

Assim, $R_a^2 \leq R^2$.

Também, mostra-se que $R_a^2 < 0$ quando $R^2 < (p-1)/(n-1)$.

Coefficiente de determinação

Uma extensão natural do coeficiente de determinação para os MLGs é

$$R^2 = 1 - \frac{D(\mathbf{y}; \hat{\boldsymbol{\mu}})}{D(\mathbf{y}; \bar{\mathbf{y}})},$$

em que $D(\mathbf{y}; \bar{\mathbf{y}})$ denota o desvio do modelo apenas com o intercepto.

Segundo Paula (2023), o coeficiente de determinação para os MLGs (exceto para o caso normal) raramente é maior do que 0,40. Assim, este valor é usado como referencial de um ótimo ajuste aos dados.

Existem diversos pseudo- R^2 na literatura. Pode-se definir, por exemplo,

$$R_p^2 = r_{\eta, g}^2,$$

em que $r_{\eta, g}$ denota a correlação linear entre o preditor ajustado $\hat{\eta}$ e a resposta transformada $g(\mathbf{y})$.

Coefficiente de determinação

Uma extensão natural do coeficiente de determinação para os MLGs é

$$R^2 = 1 - \frac{D(\mathbf{y}; \hat{\boldsymbol{\mu}})}{D(\mathbf{y}; \bar{\mathbf{y}})},$$

em que $D(\mathbf{y}; \bar{\mathbf{y}})$ denota o desvio do modelo apenas com o intercepto.

Segundo Paula (2023), o coeficiente de determinação para os MLGs (exceto para o caso normal) raramente é maior do que 0,40. Assim, este valor é usado como referencial de um ótimo ajuste aos dados.

Existem diversos pseudo- R^2 na literatura. Pode-se definir, por exemplo,

$$R_p^2 = r_{\eta, g}^2,$$

em que $r_{\eta, g}$ denota a correlação linear entre o preditor ajustado $\hat{\eta}$ e a resposta transformada $g(\mathbf{y})$.

Testes de hipóteses - Razão de verossimilhanças

Considere o particionamento $\beta = (\beta_1^\top \beta_2^\top)^\top \in \mathbb{R}^p$ com $\beta_1 \in \mathbb{R}^q$ e $\beta_2 \in \mathbb{R}^{p-q}$.

Inicialmente considere que o parâmetro de precisão ϕ seja um valor conhecido.

Queremos testar $H_0: \beta_1 = \mathbf{0}$ contra $H_1: \beta_1 \neq \mathbf{0}$. Para tanto, considere a estatística

$$\lambda(\mathbf{y}) = \frac{L(\hat{\mu}^0)}{L(\hat{\mu})},$$

em que $\hat{\mu}^0$ e $\hat{\mu}$ são os estimadores de máxima verossimilhança para μ sob H_0 (restrito a H_0) e sob o modelo irrestrito, respectivamente.

Testes de hipóteses - Razão de verossimilhanças

A estatística $\lambda(\mathbf{y})$ é chamada de razão de verossimilhanças, e satisfaz $0 \leq \lambda(\mathbf{y}) \leq 1$. Rejeita-se H_0 para valores baixos da estatística $\lambda(\mathbf{y})$.

O teste da razão de verossimilhanças (TRV) rejeita H_0 ao nível de significância $\alpha \cdot 100\%$ se $\lambda(\mathbf{y}) \leq \lambda_0$ em que λ_0 é obtido de

$$P_{H_0}(\lambda(\mathbf{Y}) \leq \lambda_0) = \alpha.$$

Note que precisamos conhecer a distribuição de $\lambda(\mathbf{Y})$ sob H_0 .

Geralmente não conhecemos a distribuição exata de $\lambda(\mathbf{Y})$ sob H_0 . Por esta razão, utiliza a distribuição assintótica de uma transformação de $\lambda(\mathbf{Y})$.

Testes de hipóteses - Razão de verossimilhanças

Sob H_0 e para n grande, mostra-se que

$$\zeta_{RV} = -2 \log[\lambda(\mathbf{Y})] \sim \chi_q^2.$$

No nosso caso, temos

$$\begin{aligned}\zeta_{RV} &= -2 \log \left[\frac{L(\hat{\mu}^0)}{L(\hat{\mu})} \right] \\&= -2 \{ \log[L(\hat{\mu}^0)] - \log[L(\hat{\mu})] \} \\&= 2 \{ \ell(\hat{\mu}) - \ell(\hat{\mu}^0) \} \\&= 2 \{ \ell(\hat{\mu}) - \ell(\tilde{\mu}) + \ell(\tilde{\mu}) - \ell(\hat{\mu}^0) \} \\&= D^*(\mathbf{y}; \hat{\mu}^0) - D^*(\mathbf{y}; \hat{\mu}) \\&= \phi[D(\mathbf{y}; \hat{\mu}^0) - D(\mathbf{y}; \hat{\mu})].\end{aligned}$$

Note que ϕ deve ser conhecido para que ζ_{RV} seja uma estatística.

Testes de hipóteses - Razão de verossimilhanças

Como $\lambda(\mathbf{y}) \leq 1$, tem-se que $\xi_{RV} \geq 0$. Assim, temos que

$$D^*(\mathbf{y}; \hat{\mu}^0) - D^*(\mathbf{y}; \hat{\mu}) \geq 0 \Rightarrow D^*(\mathbf{y}; \hat{\mu}^0) \geq D^*(\mathbf{y}; \hat{\mu}).$$

O desvio do modelo restrito sempre será maior ou igual que o desvio do modelo irrestrito.

Deve-se rejeitar $H_0: \beta_1 = \mathbf{0}$ para valores altos de ξ_{RV} . Assim, rejeita-se H_0 ao nível de significância $\alpha \cdot 100\%$ se $\xi_{RV} \geq \chi_{q,\alpha}^2$ em que $\chi_{q,\alpha}^2$ é obtido de

$$P(\chi_q^2 \geq \chi_{q,\alpha}^2) = \alpha.$$

Testes de hipóteses - Razão de verossimilhanças

Para o caso em que o parâmetro ϕ é desconhecido, considere

$$\begin{aligned} F_0 &= \frac{\xi_{RV}/q}{D^*(\mathbf{y}; \hat{\boldsymbol{\mu}})/(n-p)} \\ &= \frac{\phi[D(\mathbf{y}; \hat{\boldsymbol{\mu}}^0) - D(\mathbf{y}; \hat{\boldsymbol{\mu}})]/q}{\phi D(\mathbf{y}; \hat{\boldsymbol{\mu}})/(n-p)} \\ &= \frac{[D(\mathbf{y}; \hat{\boldsymbol{\mu}}^0) - D(\mathbf{y}; \hat{\boldsymbol{\mu}})]/q}{D(\mathbf{y}; \hat{\boldsymbol{\mu}})/(n-p)}. \end{aligned}$$

Observe que

- ▶ F_0 não depende de ϕ ;
- ▶ o numerador e o denominador de F_0 são variáveis qui-quadrado (aproximadamente) divididas pelos seus graus de liberdade;
- ▶ mostra-se independência entre numerador e denominador.

Testes de hipóteses - Razão de verossimilhanças

Sob $H_0: \beta_1 = 0$, para n grande ou para n qualquer e ϕ grande,

$$F_0 \sim F_{q,n-p},$$

em que $F_{q,n-p}$ denota a distribuição F de Snedecor com q graus de liberdade no numerador e $(n-p)$ graus de liberdade no denominador.

Deve-se rejeitar H_0 para valores grandes de F_0 . Logo, rejeita-se H_0 ao nível de significância $\alpha \cdot 100\%$ se $F_0 \geq F_{q,n-p,\alpha}$ em que $F_{q,n-p,\alpha}$ é obtido de

$$P(F_{q,n-p} \geq F_{q,n-p,\alpha}) = \alpha.$$

Testes de hipóteses - Razão de verossimilhanças

Agora, considere as hipóteses $H_0: \beta = \beta^0$ contra $H_1: \beta \neq \beta^0$, com $\beta^0 \in \mathbb{R}^p$ vetor de constantes preestabelecido.

Para ϕ conhecido, a estatística do TRV é

$$\xi_{RV} = \phi[D(\mathbf{y}; \hat{\mu}^0) - D(\mathbf{y}; \hat{\mu})],$$

em que $\hat{\mu}^0 = g^{-1}(\hat{\eta}_0)$ com $\hat{\eta}_0 = X\beta^0$.

Observe que, neste caso, $\hat{\mu}^0$ é uma constante que depende de β^0 estabelecido previamente em H_0 . Em outras palavras, aqui não é necessário estimar μ sob H_0 .

Além do TRV, podemos testar estas hipóteses através dos testes de Wald e escore.

Testes de hipóteses - Wald

Para testar $H_0: \beta = \beta^0$, a estatística do teste de Wald é definida por

$$\xi_W = (\hat{\beta} - \beta^0)^\top [\widehat{\text{Var}}(\hat{\beta})]^{-1} (\hat{\beta} - \beta^0),$$

em que $\widehat{\text{Var}}(\hat{\beta})$ denota a matriz de covariâncias assintótica de $\hat{\beta}$ estimada (avaliada em $\hat{\beta}$).

Sob H_0 e para n grande, mostra-se que

$$\xi_W \sim \chi_p^2.$$

Perceba que se H_0 é verdadeira, a estatística ξ_W deve assumir valor próximo a zero, caso contrário, assumirá valor discrepante positivo.

Assim, rejeita-se H_0 ao nível de significância $\alpha \cdot 100\%$ se $\xi_W \geq \chi_{p,\alpha}^2$ em que $\chi_{p,\alpha}^2$ é obtido de

$$P(\chi_p^2 \geq \chi_{p,\alpha}^2) = \alpha.$$

Testes de hipóteses - Wald

Em particular, se $p = 1$, a estatística de Wald é

$$\xi_W = \frac{(\hat{\beta} - \beta^0)^2}{\widehat{\text{Var}}(\hat{\beta})}.$$

Daí, rejeita-se H_0 ao nível de significância $\alpha \cdot 100\%$ se $\xi_{SR} \geq \chi^2_{1,\alpha}$.

Neste caso, a estatística ξ_W equivale ao quadrado da estatística:

$$T_0 = \frac{\hat{\beta} - \beta^0}{\widehat{\text{EP}}(\hat{\beta})},$$

em que $\widehat{\text{EP}}(\hat{\beta})$ denota o erro-padrão de $\hat{\beta}$ estimado.

Sob H_0 e para n grande, $T_0 \sim N(0, 1)$. Daí, rejeita-se H_0 ao nível de significância $\alpha \cdot 100\%$ se $T_0 \geq z_{\alpha/2}$ ou se $T_0 \leq -z_{\alpha/2}$, em que $z_{\alpha/2}$ é obtido de

$$P(Z \geq z_{\alpha/2}) = \alpha/2, \quad Z \sim N(0, 1)$$

Testes de hipóteses - Wald

A matriz de covariâncias assintótica de $\hat{\beta}$ sob os MLG é

$$\text{Var}(\hat{\beta}) = \phi^{-1}(X^{\top}WX)^{-1}.$$

Assim, se ϕ é conhecido, a estatística de Wald fica expressa por

$$\xi_W = \phi(\hat{\beta} - \beta^0)^{\top}(X^{\top}\widehat{W}X)(\hat{\beta} - \beta^0).$$

Note que valores grandes da estatística ξ_W indicam evidências contra H_0 . Logo, rejeita-se H_0 ao nível de significância $\alpha \cdot 100\%$ se $\xi_W \geq \chi_{p,\alpha}^2$.

A estatística Wald é umas das mais utilizadas na prática pela sua forma simples de ser calculada.

Testes de hipóteses - Escore

Para testar $H_0: \beta = \beta^0$, a estatística do teste escore ou teste de Rao se baseia em $U_\beta(\hat{\beta}) = \mathbf{0}$, e é definida por

$$\tilde{\zeta}_{SR} = U_\beta(\beta^0)^\top \widehat{\text{Var}_0(\hat{\beta})} U_\beta(\beta^0),$$

em que

- ▶ $U_\beta(\beta^0)$ denota o vetor escore de β avaliado em β^0 ;
- ▶ $\widehat{\text{Var}_0(\hat{\beta})}$ denota a matriz de covariâncias assintótica de $\hat{\beta}$ estimada sob H_0 (avaliada em β^0).

Sob H_0 e para n grande, mostra-se que

$$\tilde{\zeta}_{SR} \sim \chi_p^2.$$

Testes de hipóteses - Escore

Se H_0 é verdadeira, o valor de ξ_{SR} deve ser próximo a zero, enquanto que se H_0 é falsa, ξ_{SR} deve assumir um valor grande.

Vimos que para os MLGs,

$$U_{\beta} = \phi X^{\top} W^{1/2} V^{-1/2} (\mathbf{y} - \boldsymbol{\mu}), \quad \text{Var}(\hat{\boldsymbol{\beta}}) = \phi^{-1} (X^{\top} W X)^{-1}.$$

Daí,

$$U_{\beta}(\boldsymbol{\beta}^0) = \phi X^{\top} \widehat{W}_0^{1/2} \widehat{V}_0^{-1/2} (\mathbf{y} - \widehat{\boldsymbol{\mu}}_0), \quad \widehat{\text{Var}}_0(\hat{\boldsymbol{\beta}}) = \phi^{-1} (X^{\top} \widehat{W}_0 X)^{-1}.$$

Para os MLGs, se ϕ é conhecido, a estatística de escore fica dada por

$$\begin{aligned} \xi_{SR} &= U_{\beta}(\boldsymbol{\beta}^0)^{\top} \widehat{\text{Var}}_0(\hat{\boldsymbol{\beta}}) U_{\beta}(\boldsymbol{\beta}^0) \\ &= \phi^{-1} U_{\beta}(\boldsymbol{\beta}^0)^{\top} (X^{\top} \widehat{W}_0 X)^{-1} U_{\beta}(\boldsymbol{\beta}^0). \end{aligned}$$

Testes de hipóteses - Escore

A estatística ζ_{SR} é mais conveniente em situações em que a hipótese alternativa é bem mais complexa do que a hipótese nula. Portanto, esta pode uma boa alternativa quando estimar as quantidades necessárias sob H_0 é relativamente mais simples.

Rejeita-se H_0 ao nível de significância $\alpha \cdot 100\%$ se $\zeta_{SR} \geq \chi_{p,\alpha}^2$ em que $\chi_{p,\alpha}^2$ é obtido de

$$P(\chi_p^2 \geq \chi_{p,\alpha}^2) = \alpha.$$

Vale ressaltar que os três testes, em geral, são válidos para tamanhos amostrais grandes.

Testes de hipóteses - Caso normal

Vamos obter as expressões das três estatísticas de teste para o caso normal com função de ligação identidade e σ^2 conhecido.

A função desvio não escalonada para o caso normal com ligação identidade é

$$D(\mathbf{y}; \hat{\boldsymbol{\mu}}) = \sum_{i=1}^n (y_i - \hat{\mu}_i)^2 = \sum_{i=1}^n (y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}})^2.$$

Para a estatística do TRV,

$$\begin{aligned}\xi_{RV} &= \phi[D(\mathbf{y}; \hat{\boldsymbol{\mu}}^0) - D(\mathbf{y}; \hat{\boldsymbol{\mu}})] \\ &= \frac{1}{\sigma^2} \left[\sum_{i=1}^n (y_i - \mathbf{x}_i^\top \boldsymbol{\beta}^0)^2 - \sum_{i=1}^n (y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}})^2 \right] \\ &= \frac{1}{\sigma^2} \left[(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}^0)^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}^0) - (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})^\top (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) \right].\end{aligned}$$

Testes de hipóteses - Caso normal

Ainda, observe que

$$\begin{aligned}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}^0)^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}^0) &= (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}} + \mathbf{X}\hat{\boldsymbol{\beta}} - \mathbf{X}\boldsymbol{\beta}^0)^\top (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}} + \mathbf{X}\hat{\boldsymbol{\beta}} - \mathbf{X}\boldsymbol{\beta}^0) \\&= (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})^\top (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) + (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})^\top (\mathbf{X}\hat{\boldsymbol{\beta}} - \mathbf{X}\boldsymbol{\beta}^0) \\&\quad + (\mathbf{X}\hat{\boldsymbol{\beta}} - \mathbf{X}\boldsymbol{\beta}^0)^\top (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) + (\mathbf{X}\hat{\boldsymbol{\beta}} - \mathbf{X}\boldsymbol{\beta}^0)^\top (\mathbf{X}\hat{\boldsymbol{\beta}} - \mathbf{X}\boldsymbol{\beta}^0) \\&= (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})^\top (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) + 2(\mathbf{X}\hat{\boldsymbol{\beta}} - \mathbf{X}\boldsymbol{\beta}^0)^\top (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) \\&\quad + (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}^0)^\top \mathbf{X}^\top \mathbf{X} (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}^0).\end{aligned}$$

Testes de hipóteses - Caso normal

Sob o modelo normal com ligação identidade, vimos que o vetor escore para β é

$$U_{\beta} = \frac{1}{\sigma^2} X^{\top} (\mathbf{y} - \mu).$$

Segue que

$$U_{\beta} = \mathbf{0} \Leftrightarrow X^{\top} (\mathbf{y} - \hat{\mu}) = \mathbf{0},$$

com $\hat{\mu} = X\hat{\beta}$.

Então,

$$X^{\top} (\mathbf{y} - X\hat{\beta}) = X^{\top} \mathbf{y} - X^{\top} X\hat{\beta} = \mathbf{0} \Leftrightarrow X^{\top} X\hat{\beta} = X^{\top} \mathbf{y}.$$

Desde que $r(X) = r(X^{\top} X) = p$ (X é de posto completo), obtemos

$$\hat{\beta} = (X^{\top} X)^{-1} X^{\top} \mathbf{y}.$$

Testes de hipóteses - Caso normal

Assim,

$$\begin{aligned}2(\mathbf{X}\hat{\boldsymbol{\beta}} - \mathbf{X}\boldsymbol{\beta}^0)^\top (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) &= 2(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}^0)^\top \mathbf{X}^\top (\mathbf{y} - \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}) \\&= 2(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}^0)^\top (\mathbf{X}^\top \mathbf{y} - \mathbf{X}^\top \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}) \\&= 2(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}^0)^\top (\mathbf{X}^\top \mathbf{y} - \mathbf{X}^\top \mathbf{y}) \\&= 0.\end{aligned}$$

Segue que,

$$(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}^0)^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}^0) = (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})^\top (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) + (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}^0)^\top \mathbf{X}^\top \mathbf{X}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}^0).$$

Portanto, a estatística do TRV fica expressa por

$$\xi_{RV} = \frac{1}{\sigma^2} (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}^0)^\top \mathbf{X}^\top \mathbf{X}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}^0).$$

Testes de hipóteses - Caso normal

A estatística de Wald é

$$\xi_W = \phi(\hat{\beta} - \beta^0)^\top (X^\top \widehat{W} X)(\hat{\beta} - \beta^0).$$

No modelo normal com ligação identidade, sabemos que $W = I_n$, então $\widehat{W} = I_n$. Logo, obtemos que

$$\xi_W = \frac{1}{\sigma^2} (\hat{\beta} - \beta^0)^\top (X^\top X)(\hat{\beta} - \beta^0).$$

Note que $\xi_W = \xi_{RV}$.

Por fim, a estatística do teste escore é

$$\xi_{SR} = \phi^{-1} U_\beta(\beta^0)^\top (X^\top \widehat{W}_0 X)^{-1} U_\beta(\beta^0).$$

Mas,

$$U_\beta(\beta^0) = \frac{1}{\sigma^2} X^\top (\mathbf{y} - X\beta^0).$$

Testes de hipóteses - Caso normal

Também, $\widehat{W}_0 = I_n$. Então, segue que

$$\begin{aligned}\zeta_{SR} &= \sigma^2 \left[\frac{1}{\sigma^2} X^\top (\mathbf{y} - X\beta^0) \right]^\top (X^\top \widehat{W}_0 X)^{-1} \frac{1}{\sigma^2} X^\top (\mathbf{y} - X\beta^0) \\ &= \frac{1}{\sigma^2} (\mathbf{y} - X\beta^0)^\top X (X^\top X)^{-1} X^\top (\mathbf{y} - X\beta^0) \\ &= \frac{1}{\sigma^2} (X^\top \mathbf{y} - X^\top X\beta^0)^\top (X^\top X)^{-1} (X^\top \mathbf{y} - X^\top X\beta^0).\end{aligned}$$

Mas, $X^\top \mathbf{y} = X^\top X\widehat{\beta}$. Logo,

$$\begin{aligned}\zeta_{SR} &= \frac{1}{\sigma^2} (X^\top X\widehat{\beta} - X^\top X\beta^0)^\top (X^\top X)^{-1} (X^\top X\widehat{\beta} - X^\top X\beta^0) \\ &= \frac{1}{\sigma^2} (\widehat{\beta} - \beta^0)^\top (X^\top X)^\top (X^\top X)^{-1} (X^\top X)(\widehat{\beta} - \beta^0) \\ &= \frac{1}{\sigma^2} (\widehat{\beta} - \beta^0)^\top (X^\top X)(\widehat{\beta} - \beta^0).\end{aligned}$$

Quando o parâmetro de precisão ϕ é desconhecido, pode-se utilizar a estatística

$$F_0 = \frac{[D(\mathbf{y}; \hat{\mu}^0) - D(\mathbf{y}; \hat{\mu})]/p}{D(\mathbf{y}; \hat{\mu})/(n-p)}.$$

Sob H_0 e para ϕ grande, $F_0 \sim F_{p,n-p}$.

Também, se no denominador de F_0 tivermos uma estimativa consistente para ϕ^{-1} , o resultado será válido quando n cresce.

Rejeita-se H_0 ao nível de significância $\alpha \cdot 100\%$ se $F_0 \geq F_{p,n-p}$.

Testes de hipóteses - Modelos encaixados

Considere $\beta = (\beta_1^\top \beta_2^\top)^\top \in \mathbb{R}^p$ com $\beta_1 \in \mathbb{R}^q$ e $\beta_2 \in \mathbb{R}^{p-q}$.

Esta partição implica em $X = [X_1 \ X_2]$ com X_1 matriz $n \times q$ e X_2 matriz $n \times (p - q)$.

Suponha que o parâmetro de precisão ϕ seja um valor conhecido.

Queremos testar $H_0: \beta_1 = \beta_1^0$ contra $H_1: \beta_1 \neq \beta_1^0$. Aqui β_1^0 pode ser diferente do vetor nulo.

A estatística do TRV fica dada por

$$\xi_{RV} = \phi[D(\mathbf{y}; \hat{\mu}^0) - D(\mathbf{y}; \hat{\mu})],$$

em que $\hat{\mu}^0$ denota o EMV restrito a H_0 . Em outras palavras, fixa-se $\beta_1 = \beta_1^0$ e estima-se β_2 .

Sob H_0 e n grande, $\xi_{RV} \sim \chi_{q,\alpha}^2$. Daí, rejeita-se H_0 se $\xi_{RV} \geq \chi_{q,\alpha}^2$.

Testes de hipóteses - Modelos encaixados

Para ϕ conhecido, a estatística do teste de Wald é dada por

$$\xi_W = (\hat{\beta}_1 - \beta_1^0)^\top [\widehat{\text{Var}(\hat{\beta}_1)}]^{-1} (\hat{\beta}_1 - \beta_1^0),$$

em que $\hat{\beta}_1$ sai do vetor $\hat{\beta} = (\hat{\beta}_1^\top \hat{\beta}_2^\top)^\top$.

Usando resultados de álgebra matricial, mostra-se que

$$\text{Var}(\hat{\beta}_1) = \phi^{-1} [X_1^\top W^{1/2} M_2 W^{1/2} X_1]^{-1},$$

com $M_2 = I_n - H_2$ com $H_2 = W^{1/2} X_2 (X_2^\top W X_2)^{-1} X_2^\top W^{1/2}$.

Esta última expressão facilita a implementação da estatística de Wald.

Analogamente, sob H_0 e n grande, $\xi_W \sim \chi_q^2$. Rejeita-se H_0 se $\xi_W \geq \chi_{q,\alpha}^2$.

Testes de hipóteses - Modelos encaixados

Para ϕ conhecido, a estatística do teste escore é dada por

$$\xi_{SR} = U_{\beta_1}(\hat{\beta}^0)^\top \widehat{\text{Var}_0(\hat{\beta}_1)} U_{\beta_1}(\hat{\beta}^0),$$

em que $\hat{\beta}^0 = (\beta_1^0, \hat{\beta}_2^0)$, e

$$U_{\beta_1}(\beta) = \frac{\partial \ell(\beta)}{\partial \beta_1} = \phi X_1^\top W^{1/2} V^{-1/2} (\mathbf{y} - \mu).$$

Pode-se mostrar que

$$\text{Var}(\hat{\beta}_1) = \phi^{-1} (R^\top W R)^{-1}, \quad R = X_1 - X_2 C,$$

$$C = (X_2^\top W X_2)^{-1} X_2^\top W X_1.$$

Testes de hipóteses - Modelos encaixados

O vetor escore para β pode ser reescrito na forma

$$U_{\beta} = \phi^{1/2} X^{\top} W^{1/2} \mathbf{r}_p,$$

em que

$$\mathbf{r}_p = \phi^{1/2} V^{-1/2} (\mathbf{y} - \boldsymbol{\mu})$$

é conhecido como resíduo de Pearson (veremos mais à frente).

Daí, a estatística do teste escore pode ser expressa através de

$$\tilde{\xi}_{SR} = \hat{\mathbf{r}}_{p0}^{\top} \hat{W}_0^{1/2} X_1 (\hat{R}_0^{\top} \hat{W}_0 \hat{R}_0)^{-1} X_1^{\top} \hat{W}_0^{1/2} \hat{\mathbf{r}}_{p0},$$

em que as quantidades $\hat{\mathbf{r}}_{p0}$, \hat{W}_0 e \hat{R}_0 são avaliadas em $\hat{\beta}^0$. Nesse caso,

$$\hat{\mathbf{r}}_{p0} = \phi^{1/2} \hat{V}_0^{-1/2} (\mathbf{y} - \hat{\boldsymbol{\mu}}_0).$$

Testes de hipóteses - Modelos encaixados

Veja aplicação deste resultado para o modelo de análise de variância com um fator em Paula (2023), páginas 38-39.

Sob H_0 e para n grande, $\xi_{SR} \sim \chi^2_q$.

Portanto, rejeita-se H_0 se $\xi_{SR} \geq \chi^2_{q,\alpha}$.

A estatística do teste de Wald ainda pode ser reescrita dependendo da matriz R definida no teste escore:

$$\begin{aligned}\xi_W &= (\hat{\beta}_1 - \beta_1^0)^\top [\widehat{\text{Var}}(\hat{\beta}_1)]^{-1} (\hat{\beta}_1 - \beta_1^0) \\ &= \phi(\hat{\beta}_1 - \beta_1^0)^\top [\hat{R}^\top \hat{W} \hat{R}]^{-1} (\hat{\beta}_1 - \beta_1^0).\end{aligned}$$

E se o parâmetro ϕ for desconhecido?

Testes de hipóteses - Modelos encaixados

Para testar $H_0: \beta_1 = \beta_1^0$ contra $H_1: \beta_1 \neq \beta_1^0$ quando o parâmetro de precisão ϕ é desconhecido, as estatísticas ficam definidas como apresentando a seguir.

A estatística do teste Wald é

$$\begin{aligned}\xi_W &= (\hat{\beta}_1 - \beta_1^0)^\top [\widehat{\text{Var}(\hat{\beta}_1)}]^{-1} (\hat{\beta}_1 - \beta_1^0) \\ &= \hat{\phi}(\hat{\beta}_1 - \beta_1^0)^\top [\hat{R}^\top \hat{W} \hat{R}]^{-1} (\hat{\beta}_1 - \beta_1^0).\end{aligned}$$

Sob H_0 e para n grande, $\xi_W \sim \chi_q^2$.

A estatística do teste escore é

$$\begin{aligned}\xi_{SR} &= U_{\beta_1}(\hat{\theta}^0)^\top \widehat{\text{Var}_0(\hat{\beta}_1)} U_{\beta_1}(\hat{\theta}^0) \\ &= \hat{\mathbf{r}}_{p0}^\top \widehat{\mathbf{W}}_0^{1/2} \mathbf{X}_1 (\hat{\mathbf{R}}_0^\top \widehat{\mathbf{W}}_0 \hat{\mathbf{R}}_0)^{-1} \mathbf{X}_1^\top \widehat{\mathbf{W}}_0^{1/2} \hat{\mathbf{r}}_{p0},\end{aligned}$$

com $\hat{\theta}^0 = (\hat{\beta}^0, \hat{\phi}^0)^\top$ sendo o EMV para θ sob H_0 , e

$$\hat{\mathbf{r}}_{p0} = \hat{\phi}_0^{1/2} \hat{\mathbf{V}}_0^{-1/2} (\mathbf{y} - \hat{\boldsymbol{\mu}}_0).$$

Sob H_0 e para n grande, $\xi_{SR} \sim \chi_q^2$.

Testes de hipóteses - Modelos encaixados

Para definir a estatística ξ_{RV} , considere o resultado a seguir.

Para os modelos normal, gama e normal inverso, vale a seguinte decomposição:

$$c(y; \phi) = d(\phi) + \phi a(y) + u(y),$$

em que $a(\cdot)$, $d(\cdot)$, e $u(\cdot)$ são funções diferenciáveis.

A estatística do TRV fica expressa na forma

$$\xi_{RV} = 2\{\hat{\phi}t(\hat{\mu}) - \hat{\phi}^0t(\hat{\mu}^0)\} + 2n\{d(\hat{\phi}) - d(\hat{\phi}^0)\},$$

em que

$$t(\mu) = \sum_{i=1}^n t_i = \sum_{i=1}^n [y_i\theta_i - b(\theta_i) + a(y_i)].$$

Sob H_0 e para n grande, $\xi_{RV} \sim \chi_q^2$.

Testes de hipóteses - Modelos encaixados

Para o modelo gama,

$$\begin{aligned}c(y; \phi) &= (\phi - 1) \log(y) + \phi \log(\phi) - \log(\Gamma(\phi)) \\ &= \phi \log(y) - \log(y) + \phi \log(\phi) - \log(\Gamma(\phi)).\end{aligned}$$

Tome $a(y) = \log(y)$, $u(y) = -\log(y)$, e

$$d(\phi) = \phi \log(\phi) - \log(\Gamma(\phi)).$$

Também, temos que $\theta_i = -1/\mu_i$ e $b(\theta_i) = \log(\mu_i)$. Daí, obtemos que

$$\begin{aligned}t(\mu) &= \sum_{i=1}^n [y_i \theta_i - b(\theta_i) + a(y_i)] \\ &= \sum_{i=1}^n \left[-\frac{y_i}{\mu_i} - \log(\mu_i) + \log(y_i) \right] \\ &= \sum_{i=1}^n \left[\log\left(\frac{y_i}{\mu_i}\right) - \frac{y_i}{\mu_i} \right].\end{aligned}$$