

# Modelos Lineares Generalizados

## Unidade IV

Terezinha K. A. Ribeiro

terezinha.ribeiro@unb.br

Instituto de Ciências Exatas  
Departamento de Estatística  
Universidade de Brasília

# Organização

- ▶ Introdução
- ▶ Família exponencial
- ▶ Casos particulares
- ▶ Estimação dos parâmetros
- ▶ Procedimento iterativo
- ▶ Função desvio
- ▶ Resíduos
- ▶ Alavancagem
- ▶ Influência

Os modelos lineares generalizados duplos (MLGDs) são extensões dos MLGs que admitem modelar a média  $\mu$  e o parâmetro de precisão  $\phi$  simultaneamente. Assim, a precisão  $\phi$  também terá associada uma estrutura de regressão linear.

Ao admitir que a precisão da distribuição varie com a amostra, estaremos flexibilizando o modelo, e conseqüentemente, melhorando a qualidade do ajuste global do modelo suposto aos dados.

A partir dos MLGDs além de identificar quais covariáveis afetam o comportamento médio da resposta, também identificaremos quais covariáveis afetam a precisão da resposta.

Os MLGDs podem ser definidos por

- i)  $Y_i | \mathbf{x}_i \stackrel{\text{ind}}{\sim} \text{FE}(\mu_i, \phi_i);$
- ii)  $g(\mu_i) = \eta_i$  com  $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta} \Leftrightarrow \mu_i = g^{-1}(\eta_i);$
- ii)  $h(\phi_i) = \lambda_i$  com  $\lambda_i = \mathbf{z}_i^\top \boldsymbol{\gamma} \Leftrightarrow \phi_i = h^{-1}(\lambda_i);$
- ▶  $Y_i$  é a  $i$ -ésima variável resposta;
- ▶  $\mathbf{x}_i^\top = (x_{i1} \ x_{i2} \ \cdots \ x_{ip}) \in \mathbb{R}^p$  é o vetor de valores fixados das  $p$  covariáveis para a  $i$ -ésima observação no submodelo da média;
- ▶  $\mathbf{z}_i^\top = (z_{i1} \ z_{i2} \ \cdots \ z_{iq}) \in \mathbb{R}^q$  é o vetor de valores fixados das  $k$  covariáveis para a  $i$ -ésima observação no submodelo da precisão;

- ▶  $g(\cdot)$  e  $h(\cdot)$  são as respectivas funções de ligação (monótonas e diferenciáveis) para os submodelos da média e da precisão;
- ▶  $\eta_i$  e  $\lambda_i$  são os respectivos preditores lineares dos submodelos da média e da precisão para a  $i$ -ésima observação;
- ▶  $\text{FE}(\mu_i, \phi_i)$  denota a família exponencial uniparamétrica de média  $\mu_i$  e parâmetro de precisão  $\phi_i$  com função densidade de probabilidades dada por

$$f(y_i; \theta_i, \phi_i) = \exp \{ \phi_i [y_i \theta_i - b(\theta_i)] + c(y_i; \phi_i) \},$$

em que

$$c(y_i; \phi_i) = d(\phi_i) + \phi_i a(y_i) + u(y_i),$$

é a decomposição da função  $c(y_i; \phi_i)$  válida para as distribuições normal, gama e normal inversa.

# MLGs Duplos - Normal

Se  $Y_i \stackrel{\text{ind}}{\sim} N(\mu_i, \sigma_i^2)$ , a função densidade de probabilidades de  $Y_i$  é

$$\begin{aligned} f(y_i; \mu_i, \sigma_i^2) &= \frac{1}{\sqrt{2\pi\sigma_i^2}} \exp \left\{ -\frac{1}{2\sigma_i^2} (y_i - \mu_i)^2 \right\} \\ &= \exp \left\{ \frac{1}{\sigma_i^2} \left( \mu_i y_i - \frac{\mu_i^2}{2} \right) - \frac{1}{2} \left[ \log(2\pi\sigma_i^2) + \frac{y_i^2}{\sigma_i^2} \right] \right\}. \end{aligned}$$

Tome  $\phi_i = 1/\sigma_i^2$ ,  $\theta_i = \mu_i$ ,  $b(\theta_i) = \mu_i^2/2 = \theta_i^2/2$ , e

$$c(y_i; \phi_i) = -\frac{1}{2} \left[ \log(2\pi\sigma_i^2) + \frac{y_i^2}{\sigma_i^2} \right] = \frac{1}{2} \log(\phi_i) - \frac{1}{2} \log(2\pi) - \frac{1}{2} y_i^2 \phi_i.$$

Para o modelo normal temos

$$d(\phi_i) = \frac{1}{2} \log(\phi_i), \quad a(y_i) = -\frac{1}{2} y_i^2, \quad u(y_i) = -\frac{1}{2} \log(2\pi)$$

Se  $Y_i \stackrel{\text{ind}}{\sim} \text{gama}(\mu_i, \phi_i)$ , a função densidade de probabilidades de  $Y_i$  é

$$\begin{aligned} f(y_i; \mu_i, \phi_i) &= \frac{1}{\Gamma(\phi_i)} \left( \frac{\phi_i y_i}{\mu_i} \right)^{\phi_i} \exp \left\{ -\frac{\phi_i y_i}{\mu_i} \right\} \frac{1}{y_i} \\ &= \exp \{ \phi_i [-y_i / \mu_i - \log(\mu_i)] - \log \Gamma(\phi_i) + \phi_i \log(\phi_i y_i) - \log(y_i) \}. \end{aligned}$$

Tome  $\phi_i = \phi_i$ ,  $\theta_i = -\frac{1}{\mu_i} \Rightarrow \mu_i = -\theta_i^{-1}$ ,  $b(\theta_i) = \log(\mu_i) = -\log(-\theta_i)$ ,  
com  $\theta_i < 0$ ,

$$\begin{aligned} c(y_i; \phi_i) &= \phi_i \log(\phi_i y_i) - \log \Gamma(\phi_i) - \log(y_i) \\ &= \phi_i \log(\phi_i) - \log \Gamma(\phi_i) + \phi_i \log(y_i) - \log(y_i). \end{aligned}$$

Para o modelo gama temos

$$d(\phi_i) = \phi_i \log(\phi_i) - \log \Gamma(\phi_i), \quad a(y_i) = \log(y_i), \quad u(y_i) = -\log(y_i).$$

# MLGs Duplos - Normal inversa

Se  $Y_i \stackrel{\text{ind}}{\sim} \text{NI}(\mu_i, \phi_i)$ , a função densidade de probabilidades de  $Y_i$  é

$$\begin{aligned} f(y_i; \mu_i, \phi_i) &= \sqrt{\frac{\phi_i}{2\pi y_i^3}} \exp \left\{ -\frac{\phi_i (y_i - \mu_i)^2}{2\mu_i^2 y_i} \right\} \\ &= \exp \left\{ \phi_i \left[ -\frac{y_i}{2\mu_i^2} + \frac{1}{\mu_i} \right] - \frac{\phi_i}{2y_i} + \frac{1}{2} \log \left( \frac{\phi_i}{2\pi y_i^3} \right) \right\}. \end{aligned}$$

Tome  $\phi_i = \phi_i$ ,  $\theta_i = -\frac{1}{2\mu_i^2} \Rightarrow \mu_i = (-2\theta_i)^{-1/2}$ ,  $b(\theta_i) = -\frac{1}{\mu_i} = -(-2\theta_i)^{1/2}$ , com  $\theta_i < 0$ ,

$$c(y_i; \phi_i) = -\frac{\phi_i}{2y_i} + \frac{1}{2} \log \left( \frac{\phi_i}{2\pi y_i^3} \right) = \frac{1}{2} \log(\phi_i) - \frac{1}{2} \log(2\pi y_i^3) - \frac{\phi_i}{2y_i}.$$

Para o modelo NI temos

$$d(\phi_i) = \frac{1}{2} \log(\phi_i), \quad a(y_i) = -\frac{1}{2y_i}, \quad u(y_i) = -\frac{1}{2} \log(2\pi y_i^3).$$



# Família exponencial

Assim, para os modelos normal, gama e NI, vale que

$$\begin{aligned}f(y_i; \theta_i, \phi_i) &= \exp \{ \phi_i [y_i \theta_i - b(\theta_i)] + d(\phi_i) + \phi_i a(y_i) + u(y_i) \} \\&= \exp \{ \phi_i [y_i \theta_i - b(\theta_i) + a(y_i)] + d(\phi_i) + u(y_i) \} \\&= \exp \{ \phi_i t_i + d(\phi_i) + u(y_i) \},\end{aligned}$$

em que

$$t_i = y_i \theta_i - b(\theta_i) + a(y_i).$$

Note que  $t_i$  não depende de  $\phi_i$ .

Se  $\theta_i$  for fixado,  $f(y_i; \theta_i, \phi_i)$  é a densidade da família exponencial uniparamétrica de uma variável aleatória  $T_i$  com  $\theta_i = \phi_i$ ,  $b(\theta_i) = -d(\phi_i)$ ,  $\phi = 1$ ,  $c(y_i, \phi) = u(y_i)$ .

Em outras palavras,  $T_1, T_2, \dots, T_n$  com  $\theta_i$  fixado são variáveis aleatórias independentes com densidade na forma da família exponencial uniparamétrica.

# Família exponencial

Pelas propriedades da família exponencial uniparamétrica, temos que

$$\mu_{T_i} = E(T_i) = b'(\theta_i) = -d'(\phi_i) = -\frac{d}{d\phi_i} [d(\phi_i)];$$

$$\text{Var}(T_i) = -d''(\phi_i) = -\frac{d^2}{d\phi_i^2} [d(\phi_i)].$$

Para o modelo normal, temos

$$d(\phi_i) = \frac{1}{2} \log(\phi_i) \Rightarrow d'(\phi_i) = \frac{1}{2\phi_i}, \quad d''(\phi_i) = -\frac{1}{2\phi_i^2}.$$

# Família exponencial

Para o modelo gama, temos

$$d(\phi_i) = \phi_i \log(\phi_i) - \log \Gamma(\phi_i) \Rightarrow$$

$$d'(\phi_i) = \log(\phi_i) + \phi_i \frac{1}{\phi_i} - \psi(\phi_i) = 1 + \log(\phi_i) - \psi(\phi_i)$$

$$d''(\phi_i) = \frac{1}{\phi_i} - \psi'(\phi_i),$$

em que

$$\psi'(\phi) = \frac{d}{d\phi} \psi(\phi).$$

Para o modelo NI, temos

$$d(\phi_i) = \frac{1}{2} \log(\phi_i) \Rightarrow d'(\phi_i) = \frac{1}{2\phi_i}, \quad d''(\phi_i) = -\frac{1}{2\phi_i^2}.$$

# Estimação dos parâmetros

Seja  $\theta = (\beta^\top \gamma^\top)^\top \in \mathbb{R}^{p+q}$  o vetor de parâmetros a ser estimado. O logaritmo da função de verossimilhança fica dado por

$$\ell(\theta) = \sum_{i=1}^n \log [f(y_i; \theta_i, \phi_i)] = \sum_{i=1}^n \{ \phi_i t_i + d(\phi_i) + u(y_i) \},$$

em que  $t_i = y_i \theta_i - b(\theta_i) + a(y_i)$ .

O estimador de máxima verossimilhança (EMV) para  $\theta = (\beta^\top \gamma^\top)^\top$  é o valor de  $\theta$  que maximiza a função de verossimilhança  $\ell(\theta)$ , isto é,

$$\hat{\theta} = \underset{\theta \in \mathbb{R}^{p+q}}{\operatorname{argmax}} [\ell(\theta)],$$

em que  $\hat{\theta}$  é o EMV para  $\theta$ .

# Estimação dos parâmetros

O vetor escore para  $\theta$  é definido por

$$U(\theta) = \begin{bmatrix} U_{\beta}(\theta) \\ U_{\gamma}(\theta) \end{bmatrix} = \begin{bmatrix} \frac{\partial \ell(\theta)}{\partial \beta} \\ \frac{\partial \ell(\theta)}{\partial \gamma} \end{bmatrix}.$$

Para  $j = 1, 2, \dots, p$ , temos

$$\begin{aligned} U_{\beta_j} &= \frac{\partial \ell(\theta)}{\partial \beta_j} \\ &= \sum_{i=1}^n \frac{\partial}{\partial \beta_j} \{ \phi_i t_i + d(\phi_i) + u(y_i) \} \\ &= \sum_{i=1}^n \phi_i \frac{\partial}{\partial \beta_j} \{ y_i \theta_i - b(\theta_i) + a(y_i) \} \\ &= \sum_{i=1}^n \phi_i \left\{ y_i \frac{d\theta_i}{d\mu_i} \frac{d\mu_i}{d\eta_i} \frac{\partial \eta_i}{\partial \beta_j} - \frac{db(\theta_i)}{d\theta_i} \frac{d\theta_i}{d\mu_i} \frac{d\mu_i}{d\eta_i} \frac{\partial \eta_i}{\partial \beta_j} \right\}. \end{aligned}$$

# Estimação dos parâmetros

Sabemos que

$$\mu_i = b'(\theta_i) = \frac{db(\theta_i)}{d\theta_i}; \quad \frac{\partial \eta_i}{\partial \beta_j} = x_{ij};$$

$$V_i = V(\mu_i) = b''(\theta_i) = \frac{d^2b(\theta_i)}{d\theta_i^2} = \frac{d\mu_i}{d\theta_i} = \frac{1}{\frac{d\theta_i}{d\mu_i}};$$

$$\frac{d\mu_i}{d\eta_i} = \frac{d[g^{-1}(\eta_i)]}{d\eta_i} = \frac{1}{g'(g^{-1}(\eta_i))} = \frac{1}{g'(\mu_i)}.$$

Ficamos com

$$U_{\beta_j} = \sum_{i=1}^n \phi_i(y_i - \mu_i) \frac{1}{V_i} \frac{d\mu_i}{d\eta_i} x_{ij} = \sum_{i=1}^n \phi_i \left[ \sqrt{\frac{\omega_i}{V_i}} (y_i - \mu_i) x_{ij} \right],$$

em que

$$\omega_i = \frac{(d\mu_i/d\eta_i)^2}{V_i} > 0.$$

# Estimação dos parâmetros

O vetor escore para  $\beta$  fica dado por

$$U_{\beta}(\theta) = \frac{\partial \ell(\theta)}{\partial \beta} = X^{\top} \Phi W^{1/2} V^{-1/2} (\mathbf{y} - \mu),$$

em que  $\Phi = \text{diag}\{\phi_1, \phi_2, \dots, \phi_n\}$ ,  $W = \text{diag}\{\omega_1, \omega_2, \dots, \omega_n\}$ ,  $V = \text{diag}\{V_1, V_2, \dots, V_n\}$ ,

$$X = \begin{bmatrix} \mathbf{x}_1^{\top} \\ \mathbf{x}_2^{\top} \\ \vdots \\ \mathbf{x}_n^{\top} \end{bmatrix}, \quad \mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad \mu = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_n \end{bmatrix}.$$

# Estimação dos parâmetros

Para  $j = 1, 2, \dots, q$ , temos

$$\begin{aligned}U_{\gamma_j} &= \frac{\partial \ell(\boldsymbol{\theta})}{\partial \gamma_j} \\&= \sum_{i=1}^n \frac{\partial}{\partial \gamma_j} \{ \phi_i t_i + d(\phi_i) + u(y_i) \} \\&= \sum_{i=1}^n \left\{ t_i \frac{d\phi_i}{d\lambda_i} \frac{\partial \lambda_i}{\partial \gamma_j} + d'(\phi_i) \frac{d\phi_i}{d\lambda_i} \frac{\partial \lambda_i}{\partial \gamma_j} \right\}.\end{aligned}$$

Sabemos que

$$\begin{aligned}\mu_{T_i} &= -d'(\phi_i); \quad \frac{\partial \lambda_i}{\partial \gamma_j} = z_{ij}; \\ \frac{d\phi_i}{d\lambda_i} &= \frac{d[h^{-1}(\lambda_i)]}{d\lambda_i} = \frac{1}{h'(h^{-1}(\lambda_i))} = \frac{1}{h'(\phi_i)}.\end{aligned}$$



# Estimação dos parâmetros

Assim, ficamos com

$$U_{\gamma_j} = \sum_{i=1}^n \{t_i - E(T_i)\} \frac{z_{ij}}{h'(\phi_i)}.$$

O vetor escore para  $\gamma$  é

$$U_{\gamma}(\theta) = \frac{\partial \ell(\theta)}{\partial \gamma} = Z^{\top} H_{\gamma}^{-1} (\mathbf{t} - \mu_T),$$

em que  $H_{\gamma} = \text{diag}\{h'(\phi_1), h'(\phi_2), \dots, h'(\phi_n)\}$

$$Z = \begin{bmatrix} \mathbf{z}_1^{\top} \\ \mathbf{z}_2^{\top} \\ \vdots \\ \mathbf{z}_n^{\top} \end{bmatrix}, \quad \mathbf{z}_i = \begin{bmatrix} z_{i1} \\ z_{i2} \\ \vdots \\ z_{iq} \end{bmatrix}, \quad \mathbf{t} = \begin{bmatrix} t_1 \\ t_2 \\ \vdots \\ t_n \end{bmatrix}, \quad \mu_T = \begin{bmatrix} E(T_1) \\ E(T_2) \\ \vdots \\ E(T_n) \end{bmatrix}.$$

# Estimação dos parâmetros

A matriz de informação de Fisher é obtida a partir de

$$K_{\theta\theta} = \begin{bmatrix} K_{\beta\beta} & K_{\beta\gamma} \\ K_{\gamma\beta} & K_{\gamma\gamma} \end{bmatrix} = \begin{bmatrix} -E \left( \frac{\partial^2 \ell(\theta)}{\partial \beta \partial \beta^\top} \right) & -E \left( \frac{\partial^2 \ell(\theta)}{\partial \beta \partial \gamma} \right) \\ -E \left( \frac{\partial^2 \ell(\theta)}{\partial \gamma \partial \beta^\top} \right) & -E \left( \frac{\partial^2 \ell(\theta)}{\partial \gamma \partial \gamma^\top} \right) \end{bmatrix}.$$

Para  $j, l = 1, 2, \dots, p$ , tem-se que

$$\begin{aligned} \frac{\partial^2 \ell(\theta)}{\partial \beta_j \partial \beta_l} &= \frac{\partial U_{\beta_j}}{\partial \beta_l} = \frac{\partial}{\partial \beta_l} \left\{ \sum_{i=1}^n \phi_i (y_i - \mu_i) \frac{1}{V_i} \frac{d\mu_i}{d\eta_i} x_{ij} \right\} \\ &= - \sum_{i=1}^n \phi_i V_i^{-1} \left( \frac{d\mu_i}{d\eta_i} \right)^2 x_{ij} x_{il} + \sum_{i=1}^n \phi_i (y_i - \mu_i) \frac{d^2 \theta_i}{d\mu_i^2} \left( \frac{d\mu_i}{d\eta_i} \right)^2 x_{il} x_{ij} \\ &\quad + \sum_{i=1}^n \phi_i (y_i - \mu_i) \frac{d^2 \mu_i}{d\eta_i^2} V_i^{-1} x_{ij} x_{il}. \end{aligned}$$

# Estimação dos parâmetros

Portanto,

$$\begin{aligned} -E \left\{ \frac{\partial^2 \ell(\boldsymbol{\theta})}{\partial \beta_j \partial \beta_l} \right\} &= \sum_{i=1}^n \phi_i V_i^{-1} \left( \frac{d\mu_i}{d\eta_i} \right)^2 x_{ij} x_{il} \\ &= \sum_{i=1}^n \phi_i \omega_i x_{ij} x_{il}, \end{aligned}$$

desde que

$$E(Y_i - \mu_i) = 0, \quad \omega_i = \frac{(d\mu_i/d\eta_i)^2}{V_i}.$$

A matriz de informação de Fisher para  $\boldsymbol{\beta}$  é

$$K_{\boldsymbol{\beta}\boldsymbol{\beta}} = -E \left\{ \frac{\partial^2 \ell(\boldsymbol{\theta})}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}^\top} \right\} = \mathbf{X}^\top \boldsymbol{\Phi} \mathbf{W} \mathbf{X}.$$

# Estimação dos parâmetros

Também, temos que

$$\begin{aligned}\frac{\partial^2 \ell(\theta)}{\partial \gamma_j \partial \gamma_l} &= \frac{\partial U_{\gamma_j}}{\partial \gamma_l} \\&= \frac{\partial}{\partial \gamma_l} \left\{ \sum_{i=1}^n [t_i + d'(\phi_i)] \frac{z_{ij}}{h'(\phi_i)} \right\} \\&= \sum_{i=1}^n \frac{z_{ij}}{\{h'(\phi_i)\}^2} \left\{ d''(\phi_i) \frac{d\phi_i}{d\lambda_i} \frac{\partial \lambda_i}{\partial \gamma_l} h'(\phi_i) - [t_i + d'(\phi_i)] h''(\phi_i) \frac{d\phi_i}{d\lambda_i} \frac{\partial \lambda_i}{\partial \gamma_l} \right\} \\&= \sum_{i=1}^n \frac{z_{ij} z_{il}}{\{h'(\phi_i)\}^2} \left\{ \frac{d''(\phi_i)}{h'(\phi_i)} h'(\phi_i) - [t_i + d'(\phi_i)] \frac{h''(\phi_i)}{h'(\phi_i)} \right\} \\&= \sum_{i=1}^n \frac{z_{ij} z_{il}}{\{h'(\phi_i)\}^2} \left\{ d''(\phi_i) - [t_i + d'(\phi_i)] \frac{h''(\phi_i)}{h'(\phi_i)} \right\}.\end{aligned}$$

# Estimação dos parâmetros

Portanto,

$$-E \left\{ \frac{\partial^2 \ell(\boldsymbol{\theta})}{\partial \gamma_j \partial \gamma_l} \right\} = - \sum_{i=1}^n \frac{z_{ij} z_{il} d''(\phi_i)}{\{h'(\phi_i)\}^2} = \sum_{i=1}^n p_i z_{ij} z_{il},$$

desde que

$$E(T_i + d'(\phi_i)) = 0, \quad p_i = -\frac{d''(\phi_i)}{\{h'(\phi_i)\}^2}.$$

A matriz de informação de Fisher para  $\gamma$  é

$$K_{\gamma\gamma} = -E \left\{ \frac{\partial^2 \ell(\boldsymbol{\theta})}{\partial \gamma \partial \gamma^\top} \right\} = Z^\top P Z,$$

em que  $P = \text{diag}\{p_1, p_2, \dots, p_n\}$ . Ainda,  $P = V_\gamma H_\gamma^{-2}$  com  $V_\gamma = \text{diag}\{-d'''(\phi_1), \dots, -d'''(\phi_n)\}$ .

# Estimação dos parâmetros

Finalmente,

$$\begin{aligned}\frac{\partial^2 \ell(\boldsymbol{\theta})}{\partial \beta_j \partial \gamma_l} &= \frac{\partial U_{\beta_j}}{\partial \gamma_l} \\&= \frac{\partial}{\partial \gamma_l} \left\{ \sum_{i=1}^n \phi_i(y_i - \mu_i) \frac{1}{V_i} \frac{d\mu_i}{d\eta_i} x_{ij} \right\} \\&= \sum_{i=1}^n (y_i - \mu_i) \frac{1}{V_i} \frac{d\mu_i}{d\eta_i} x_{ij} \frac{d\phi_i}{d\lambda_i} \frac{\partial \lambda_i}{\partial \gamma_l} \\&= \sum_{i=1}^n (y_i - \mu_i) \frac{1}{V_i} \frac{d\mu_i}{d\eta_i} x_{ij} \frac{z_{il}}{h'(\phi_i)}.\end{aligned}$$

Observe que

$$-E \left\{ \frac{\partial^2 \ell(\boldsymbol{\theta})}{\partial \beta_j \partial \gamma_l} \right\} = 0,$$

pois  $E(Y_i - \mu_i) = 0$ .

# Estimação dos parâmetros

Isto implica que

$$K_{\beta\gamma} = K_{\gamma\beta}^{\top} = -E \left\{ \frac{\partial^2 \ell(\theta)}{\partial \beta \partial \gamma} \right\} = 0_{p \times q}.$$

A matriz de informação de Fisher para  $\theta = (\beta^{\top} \gamma^{\top})^{\top}$  é dada por

$$K_{\theta\theta} = \text{diag}\{K_{\beta\beta}, K_{\gamma\gamma}\} = \begin{bmatrix} X^{\top} \Phi W X & 0_{p \times q} \\ 0_{q \times p} & Z^{\top} P Z \end{bmatrix}.$$

Como a matriz  $K_{\theta\theta}$  é bloco diagonal, concluímos que os parâmetros  $\beta$  e  $\gamma$  são ortogonais.

# Normalidade assintótica do EMV

Para  $n$  grande, pode-se mostrar que

$$\hat{\theta} \sim N_{p+q}(\theta, K_{\theta\theta}^{-1}),$$

em que

$$K_{\theta\theta}^{-1} = \text{diag}\{K_{\beta\beta}^{-1}, K_{\gamma\gamma}^{-1}\} = \begin{bmatrix} (X^{\top} \Phi W X)^{-1} & 0_{p \times q} \\ 0_{q \times p} & (Z^{\top} P Z)^{-1} \end{bmatrix}.$$

Particularmente, para  $n$  grande,

$$\hat{\beta} \sim N_p(\beta, (X^{\top} \Phi W X)^{-1}),$$

$$\hat{\gamma} \sim N_q(\gamma, (Z^{\top} P Z)^{-1}).$$



# Processo iterativo para estimar $\beta$ e $\gamma$

Os estimadores de máxima verossimilhança para  $\beta$  e  $\gamma$  devem ser obtidos a partir de

$$U_{\beta}(\theta) = \mathbf{0} \Leftrightarrow X^{\top} \Phi W^{1/2} V^{-1/2} (\mathbf{y} - \mu) = \mathbf{0},$$

$$U_{\gamma}(\theta) = \mathbf{0} \Leftrightarrow Z^{\top} H_{\gamma}^{-1} (\mathbf{t} - \mu_T) = \mathbf{0},$$

respectivamente.

Observe que  $\hat{\beta}$  e  $\hat{\gamma}$  não possuem forma fechada.

Por esta razão, desenvolve-se o processo iterativo escore de Fisher sob os MLGDs.

# Processo iterativo para estimar $\beta$ e $\gamma$

O procedimento iterativo Escore de Fisher para  $\beta$  fica definido por

$$\beta^{(m+1)} = \beta^{(m)} + \left\{ K_{\beta\beta}^{-1} \right\}^{(m)} U_{\beta}^{(m)}, \quad m = 0, 1, 2, \dots, \quad (1)$$

com

$$U_{\beta}(\theta) = X^{\top} \Phi W^{1/2} V^{-1/2} (\mathbf{y} - \mu), \quad K_{\beta\beta}^{-1} = (X^{\top} \Phi W X)^{-1}.$$

Analogamente, para  $\gamma$  o procedimento iterativo fica expresso por

$$\gamma^{(m+1)} = \gamma^{(m)} + \left\{ K_{\gamma\gamma}^{-1} \right\}^{(m)} U_{\gamma}^{(m)}, \quad m = 0, 1, 2, \dots, \quad (2)$$

com

$$U_{\gamma}(\theta) = Z^{\top} H_{\gamma}^{-1} (\mathbf{t} - \mu_T), \quad K_{\gamma\gamma}^{-1} = (Z^{\top} P Z)^{-1}.$$

# Processo iterativo para estimar $\beta$ e $\gamma$

Ainda, veja que

$$\begin{aligned}\beta^{(m)} &= \left\{ (X^\top \Phi W X)^{-1} \right\}^{(m)} \left[ X^\top \Phi^{(m)} W^{(m)} X \right] \beta^{(m)} \\ &= \left\{ (X^\top \Phi W X)^{-1} \right\}^{(m)} X^\top \Phi^{(m)} W^{(m)} \eta^{(m)},\end{aligned}$$

em que  $\eta^{(m)} = X\beta^{(m)}$  é o preditor linear associado ao submodelo da média no passo  $m$  do processo iterativo Escore de Fisher.

De forma similar, temos

$$\begin{aligned}\gamma^{(m)} &= \left\{ (Z^\top P Z)^{-1} \right\}^{(m)} \left[ Z^\top P^{(m)} Z \right] \gamma^{(m)} \\ &= \left\{ (Z^\top P Z)^{-1} \right\}^{(m)} Z^\top P^{(m)} \lambda^{(m)},\end{aligned}$$

em que  $\lambda^{(m)} = Z\gamma^{(m)}$  é o preditor linear associado ao submodelo da precisão no passo  $m$  do processo iterativo Escore de Fisher.

# Processo iterativo para estimar $\beta$ e $\gamma$

Substituindo a expressão de  $\beta^{(m)}$  em (1) ficamos com

$$\begin{aligned}\beta^{(m+1)} &= \beta^{(m)} + \left\{ K_{\beta\beta}^{-1} \right\}^{(m)} U_{\beta}^{(m)} \\&= \left\{ (X^{\top} \Phi W X)^{-1} \right\}^{(m)} X^{\top} \Phi^{(m)} W^{(m)} \eta^{(m)} \\&+ \left\{ (X^{\top} \Phi W X)^{-1} \right\}^{(m)} X^{\top} \Phi^{(m)} \left\{ W^{1/2} \right\}^{(m)} \left\{ V^{-1/2} \right\}^{(m)} (\mathbf{y} - \mu^{(m)}) \\&= \left\{ (X^{\top} \Phi W X)^{-1} \right\}^{(m)} X^{\top} \Phi^{(m)} W^{(m)} \left\{ \eta^{(m)} \right. \\&+ \left. \left\{ W^{-1/2} \right\}^{(m)} \left\{ V^{-1/2} \right\}^{(m)} (\mathbf{y} - \mu^{(m)}) \right\} \\&= \left\{ (X^{\top} \Phi W X)^{-1} \right\}^{(m)} X^{\top} \Phi^{(m)} W^{(m)} \mathbf{y}^{*(m)},\end{aligned}$$

em que

$$\mathbf{y}^{*(m)} = \eta^{(m)} + \left\{ W^{-1/2} \right\}^{(m)} \left\{ V^{-1/2} \right\}^{(m)} (\mathbf{y} - \mu^{(m)}).$$

# Processo iterativo para estimar $\beta$ e $\gamma$

Substituindo a expressão de  $\gamma^{(m)}$  em (2) ficamos com

$$\begin{aligned}\gamma^{(m+1)} &= \gamma^{(m)} + \left\{ K_{\gamma\gamma}^{-1} \right\}^{(m)} U_{\gamma}^{(m)} \\&= \left\{ (Z^{\top} P Z)^{-1} \right\}^{(m)} Z^{\top} P^{(m)} \lambda^{(m)} \\&+ \left\{ (Z^{\top} P Z)^{-1} \right\}^{(m)} Z^{\top} \left\{ H_{\gamma}^{-1} \right\}^{(m)} (\mathbf{t}^{(m)} - \boldsymbol{\mu}_T^{(m)}) \\&= \left\{ (Z^{\top} P Z)^{-1} \right\}^{(m)} Z^{\top} P^{(m)} \left\{ \lambda^{(m)} + \left\{ V_{\gamma}^{-1} \right\}^{(m)} H_{\gamma}^{(m)} (\mathbf{t}^{(m)} - \boldsymbol{\mu}_T^{(m)}) \right\} \\&= \left\{ (Z^{\top} P Z)^{-1} \right\}^{(m)} Z^{\top} P^{(m)} \mathbf{z}^{*(m)},\end{aligned}$$

em que

$$\mathbf{z}^{*(m)} = \lambda^{(m)} + \left\{ V_{\gamma}^{-1} \right\}^{(m)} H_{\gamma}^{(m)} (\mathbf{t}^{(m)} - \boldsymbol{\mu}_T^{(m)}).$$

Lembre-se que  $P = V_{\gamma} H_{\gamma}^{-2}$ .

# Processo iterativo para estimar $\beta$ e $\gamma$

Novamente, observa-se que o processo iterativo de Escore de Fisher pode ser visto como um processo iterativo de mínimos quadrados reponderados.

A matriz  $\Phi W$  possui o papel de reponderar  $\hat{\beta}$ , enquanto que a matriz  $P$  possui o papel de reponderar  $\hat{\gamma}$ . Por esta razão,  $\Phi W$  e  $P$  são vistas como matrizes de ponderações ou “pesos” que mudam a cada passo do processo iterativo.

O processo iterativo pode ser resolvido alternando-se as duas equações obtidas para  $\beta^{(m+1)}$  e  $\gamma^{(m+1)}$  até a convergência.

O processo pode ser iniciado com a equação obtida para  $\beta^{(m+1)}$  avaliada sob as estimativas de um MLG com  $\phi_i = \phi$ ,  $\forall i$  (ou ainda  $\Phi = \phi I_n$ ), isto é, os valores iniciais  $\beta^{(0)}$  e  $\gamma^{(0)}$  são as estimativas de máxima verossimilhança sob um MLG com precisão constante.

O MLGD normal é definido por

- i)  $Y_i | \mathbf{x}_i \stackrel{\text{ind}}{\sim} N(\mu_i, \phi_i^{-1})$  com  $\phi_i = \sigma_i^2$ ;
- ii)  $g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta} \Leftrightarrow \mu_i = g^{-1}(\mathbf{x}_i^\top \boldsymbol{\beta})$ ;
- iii)  $h(\phi_i) = \mathbf{z}_i^\top \boldsymbol{\gamma} \Leftrightarrow \phi_i = h^{-1}(\mathbf{z}_i^\top \boldsymbol{\gamma})$ .

As opções de função de ligação que podem ser utilizadas para  $g(\cdot)$  são as mesmas vistas sobre os MLGs.

As opções de função de ligação que podem ser utilizadas para  $h(\cdot)$  são as mesmas utilizadas para modelar parâmetros estritamente positivos. Em particular, a ligação logarítmica é a ligação vastamente utilizada.

# MLG normal duplo

Um modelo de regressão linear normal heteroscedástico pode ser obtido como caso especial dos MLGDs normais.

Considere o modelo

$$Y_i = \mathbf{x}_i^\top \boldsymbol{\beta} + \varepsilon_i, \quad \varepsilon_i \stackrel{\text{ind}}{\sim} \text{N}(0, \phi_i^{-1}),$$

com estrutura de regressão para a precisão  $\phi$  dada por

$$\log(\phi_i) = \mathbf{z}_i^\top \boldsymbol{\gamma} \Rightarrow \log(\sigma_i^2) = -\mathbf{z}_i^\top \boldsymbol{\gamma}.$$

Sob este modelo,

$$\mu_i = \text{E}(Y_i) = \mathbf{x}_i^\top \boldsymbol{\beta}, \quad \text{Var}(Y_i) = \phi_i^{-1} = \sigma_i^2 = e^{-\mathbf{z}_i^\top \boldsymbol{\gamma}}.$$

Assim, a média e a variância da resposta estão sendo modeladas simultaneamente. Neste caso,  $g(x) = x$  e  $h(x) = \log(x)$ .



Lembre-se que sob ligação  $g(\cdot)$  canônica,  $W = V$ . Daí, o vetor escore para  $\beta$  fica dado por

$$U_{\beta}(\theta) = X^{\top} \Phi W^{1/2} V^{-1/2} (\mathbf{y} - \mu) = X^{\top} \Phi (\mathbf{y} - \mu),$$

em que  $\Phi = \text{diag}\{\sigma_1^{-2}, \sigma_2^{-2}, \dots, \sigma_n^{-2}\}$  sob o modelo normal.

O vetor escore para  $\gamma$  fica dado por

$$U_{\gamma}(\theta) = Z^{\top} H_{\gamma}^{-1} (\mathbf{t} - \mu_T),$$

em que  $H_{\gamma} = \text{diag}\{h'(\phi_1), \dots, h'(\phi_n)\}$  com  $h'(\phi_i) = \phi_i^{-1}$  desde que  $h(x) = \log(x)$ .

Assim,  $H_{\gamma} = \text{diag}\{\sigma_1^2, \dots, \sigma_n^2\}$ .

# MLG normal duplo

Também,  $\mathbf{t} = (t_1 \ t_2 \cdots t_n)^\top$  com  $t_i = y_i\theta_i - b(\theta_i) + a(y_i)$ .

Para este modelo, ficamos com

$$\begin{aligned}t_i &= y_i\mu_i - \frac{\mu_i^2}{2} - \frac{1}{2}y_i^2 \\&= \frac{2y_i\mu_i - \mu_i^2 - y_i^2}{2} \\&= -\frac{(y_i - \mu_i)^2}{2}.\end{aligned}$$

Assim,

$$\mathbf{t}^\top = \left[ -\frac{(y_1 - \mu_1)^2}{2} \quad -\frac{(y_2 - \mu_2)^2}{2} \quad \cdots \quad -\frac{(y_n - \mu_n)^2}{2} \right]$$

O vetor  $\mu_T$  fica expresso por

$$\mu_T^\top = [-d'(\phi_1) \quad -d'(\phi_2) \quad \cdots \quad -d'(\phi_n)].$$

Sob o modelo normal,  $d(\phi_i) = \frac{1}{2} \log(\phi_i)$  que implica em  $d'(\phi_i) = \frac{1}{2\phi_i}$ .  
Assim, ficamos com

$$\begin{aligned}\mu_T^\top &= \left[ -\frac{1}{2\phi_1} \quad -\frac{1}{2\phi_2} \quad \cdots \quad -\frac{1}{2\phi_n} \right] \\ &= \left[ -\frac{\sigma_1^2}{2} \quad -\frac{\sigma_2^2}{2} \quad \cdots \quad -\frac{\sigma_n^2}{2} \right].\end{aligned}$$

A matriz de Fisher para  $\beta$  é

$$K_{\beta\beta} = X^\top \Phi W X = X^\top \Phi X,$$

desde que  $W = V = I_n$  pois  $V_i = 1, \forall i$ .

# MLG normal duplo

A matriz de Fisher para  $\gamma$  é

$$K_{\gamma\gamma} = Z^{\top} P Z,$$

em que  $P = \text{diag}\{p_1, p_2, \dots, p_n\}$  com

$$p_i = -\frac{d''(\phi_i)}{\{h'(\phi_i)\}^2} = -\frac{[-1/(2\phi_i^2)]}{\{\phi_i^{-1}\}^2} = \frac{1}{2}.$$

No modelo normal linear heteroscedástico as ponderações no processo iterativo associado ao submodelo da precisão são constantes.

Daí, ficamos com

$$K_{\gamma\gamma} = \frac{1}{2} Z^{\top} Z.$$

Para  $n$  grande, temos que

$$\hat{\beta} \sim N_p\left(\beta, (X^{\top} \Phi X)^{-1}\right), \quad \hat{\gamma} \sim N_q\left(\gamma, 2(Z^{\top} Z)^{-1}\right).$$

# Função desvio - submodelo da média

Sob os MLGDs pode-se definir as respectivas funções desvio para cada submodelo.

Supondo  $\phi_i$  conhecido  $\forall i$ , o desvio para o submodelo da média é

$$D_{\mu}^*(\mathbf{y}; \hat{\boldsymbol{\mu}}, \boldsymbol{\phi}) = \sum_{i=1}^n d_{\mu}^{*2}(y_i; \hat{\mu}_i, \phi_i) = 2 \{ \ell(\tilde{\boldsymbol{\mu}}) - \ell(\hat{\boldsymbol{\mu}}) \},$$

em que  $\boldsymbol{\phi} = (\phi_1 \ \phi_2 \ \cdots \ \phi_n)^{\top}$ ,  $\ell(\boldsymbol{\mu})$  é o logaritmo da função de verossimilhança avaliado em  $\boldsymbol{\mu}$ , e

$$d_{\mu}^{*2}(y_i; \hat{\mu}_i, \phi_i) = 2\phi_i \left\{ y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right\}.$$

Na prática  $\phi_i$  é desconhecido, assim deve-se substituir  $\phi_i$  por  $\hat{\phi}_i = h^{-1}(\hat{\lambda}_i)$ .

Para  $\phi_i$  grande para todo  $i$ , mostra-se que

$$D^*(\mathbf{y}; \hat{\boldsymbol{\mu}}, \boldsymbol{\phi}) \sim \chi_{n-p}^2.$$

# Função desvio - submodelo da precisão

Supondo  $\mu_i$  conhecido  $\forall i$ , o desvio para o submodelo da precisão é

$$D_{\phi}^*(\mathbf{y}; \hat{\phi}, \mu) = \sum_{i=1}^n d_{\phi}^{*2}(y_i; \hat{\phi}_i, \mu_i) = 2 \{ \ell(\tilde{\phi}) - \ell(\hat{\phi}) \},$$

em que  $\ell(\phi)$  é o logaritmo da função de verossimilhança avaliado em  $\phi$ .

Sob o MLGD, supondo  $\mu_i$  conhecido,

$$\ell(\phi) = \sum_{i=1}^n \ell(\phi_i),$$

em que

$$\ell(\phi_i) = \phi_i t_i + d(\phi_i) + u(y_i).$$

# Função desvio - submodelo da precisão

$$\begin{aligned}D_{\phi}^*(\mathbf{y}; \hat{\phi}, \mu) &= 2 \{ \ell(\tilde{\phi}) - \ell(\hat{\phi}) \} \\&= 2 \sum_{i=1}^n [\ell(\tilde{\phi}_i) - \ell(\hat{\phi}_i)] \\&= 2 \sum_{i=1}^n \{ \tilde{\phi}_i t_i + d(\tilde{\phi}_i) + u(y_i) - \hat{\phi}_i t_i - d(\hat{\phi}_i) - u(y_i) \} \\&= 2 \sum_{i=1}^n \{ t_i(\tilde{\phi}_i - \hat{\phi}_i) + d(\tilde{\phi}_i) - d(\hat{\phi}_i) \} .\end{aligned}$$

Assim, obtemos que

$$d_{\phi}^{*2}(y_i; \hat{\phi}_i, \mu_i) = 2 \{ t_i(\tilde{\phi}_i - \hat{\phi}_i) + d(\tilde{\phi}_i) - d(\hat{\phi}_i) \} ,$$

em que  $\tilde{\phi}_i$  é a estimativa de máxima verossimilhança para  $\phi_i$  sob o modelo saturado.

# Modelo saturado

Na prática  $\mu_i$  (e, portanto,  $t_i$ ) é desconhecido. Então, deve-se substituir  $\mu_i(t_i)$  por  $\hat{\mu}_i = g^{-1}(\hat{\eta}_i)$  ( $\hat{t}_i = y_i\hat{\theta}_i - b(\hat{\theta}_i) + a(y_i)$ ).

Qual é a estimativa de máxima verossimilhança para  $\phi_i$  sob o modelo saturado?

Considere que  $Y_i | \mathbf{x}_i \stackrel{\text{ind}}{\sim} \text{FE}(\mu_i, \phi_i)$  com  $\mu_i$  fixado, e  $h(\phi_i) = \gamma_i$ , para  $i = 1, 2, \dots, n$ .

O modelo suposto para os dados é um MLG que possui  $n$  parâmetros,  $\gamma_1, \gamma_2, \dots, \gamma_n$ . Mais especificamente,

$$\phi_1 = h^{-1}(\gamma_1), \quad \phi_2 = h^{-1}(\gamma_2), \quad \dots, \quad \phi_n = h^{-1}(\gamma_n).$$



# Função desvio - submodelo da precisão

Neste caso, a matriz associada ao submodelo da precisão é a matriz identidade de ordem  $n$ , isto é,  $Z = I_n$ .

Note que a relação entre as precisões e os  $\gamma$ 's é única e expressa por  $h(\phi_i) = \gamma_i$ . Portanto, sob o modelo saturado podemos estimar diretamente as precisões  $\phi_1, \phi_2, \dots, \phi_n$ , e posteriormente, estabelecer as estimativas de  $\gamma_1, \gamma_2, \dots, \gamma_n$ .

O escore para  $\phi_j, j = 1, 2, \dots, n$ , sob o modelo saturado é

$$U_{\phi_j} = \sum_{i=1}^n \frac{\partial}{\partial \phi_j} \{ \phi_i t_i + d(\phi_i) + u(y_i) \} = t_j + d'(\phi_j).$$

O vetor escore para  $\boldsymbol{\phi} = (\phi_1 \ \phi_2 \ \dots \ \phi_n)^\top$  é

$$U_{\boldsymbol{\phi}} = (\mathbf{t} - \boldsymbol{\mu}_T).$$

# Função desvio - submodelo da precisão

O EMV para o vetor de parâmetros  $\phi$  é obtido de

$$(\mathbf{t} - \tilde{\mu}_T) = \mathbf{0} \Leftrightarrow \mathbf{t} = \tilde{\mu}_T,$$

em que  $\tilde{\mu}_T$  denota o EMV de  $\mu_T$  sob o modelo saturado.

Portanto,  $\tilde{\phi}_i$  é obtido tal que forma que  $t_i = -d'(\tilde{\phi}_i)$ , ou ainda,

$$d'(\tilde{\phi}_i) = -t_i, \quad \forall i.$$

Para o modelo normal, temos que  $d'(\tilde{\phi}_i) = 1/(2\tilde{\phi}_i)$ , e portanto,

$$\frac{1}{2\tilde{\phi}_i} = -t_i \Rightarrow \tilde{\phi}_i = -\frac{1}{2t_i},$$

em que

$$t_i = -\frac{(y_i - \mu_i)^2}{2}.$$

# Função desvio - submodelo da precisão

Na prática, troca-se  $t_i$  por  $\hat{t}_i$  na expressão de  $\tilde{\phi}_i$ . Daí, ficamos com

$$\tilde{\phi}_i = -\frac{1}{2\hat{t}_i} = \frac{1}{(y_i - \hat{\mu}_i)^2}.$$

Para  $\phi_i$  grande para todo  $i$ , mostra-se que

$$D^*(\mathbf{y}; \hat{\boldsymbol{\phi}}, \boldsymbol{\mu}) \sim \chi_{n-q}^2.$$

Para o modelo normal inversa, também temos que  $d'(\tilde{\phi}_i) = 1/(2\tilde{\phi}_i)$ , e portanto,

$$\frac{1}{2\tilde{\phi}_i} = -t_i \Rightarrow \tilde{\phi}_i = -\frac{1}{2t_i},$$

porém  $t_i$  é definido diferente.

# Função desvio - submodelo da precisão

Temos que  $\theta_i = -\frac{1}{2\mu_i^2}$ ,  $b(\theta_i) = -1/\mu_i$ , e  $a(y_i) = -1/(2y_i)$ . Assim, ficamos com

$$\begin{aligned}t_i &= y_i\theta_i - b(\theta_i) + a(y_i) \\&= -\frac{y_i}{2\mu_i^2} + \frac{1}{\mu_i} - \frac{1}{2y_i} \\&= -\frac{y_i^2 - 2\mu_i y_i + \mu_i^2}{2\mu_i^2 y_i} \\&= -\frac{(y_i - \mu_i)^2}{2\mu_i^2 y_i}.\end{aligned}$$

# Função desvio - submodelo da precisão

Para o modelo gama, temos

$$d'(\phi_i) = 1 + \log(\phi_i) - \psi(\phi_i).$$

Sabemos que  $\tilde{\phi}_i$  é obtido tal que forma que

$$\begin{aligned} d'(\tilde{\phi}_i) &= -t_i, \quad \forall i \Rightarrow \\ 1 + \log(\tilde{\phi}_i) - \psi(\tilde{\phi}_i) &= -t_i \end{aligned}$$

Observe que, neste caso,  $\tilde{\phi}_i$  não possui forma fechada. Assim,  $\tilde{\phi}_i$  deve ser obtido através da solução de uma equação não linear.

# Resíduos - submodelo da média

O resíduo componente do desvio para o submodelo da média é definido por

$$\widehat{t_{D_{\mu i}}} = \frac{d_{\mu}^*(y_i; \widehat{\mu}_i, \widehat{\phi}_i)}{\sqrt{1 - \widehat{h}_{ii}}},$$

em que

$$d_{\mu}^*(y_i; \widehat{\mu}_i, \widehat{\phi}_i) = \pm \sqrt{2\widehat{\phi}_i} \left\{ y_i(\tilde{\theta}_i - \widehat{\theta}_i) + b(\widehat{\theta}_i) - b(\tilde{\theta}_i) \right\}^{1/2},$$

$\pm$  corresponde ao sinal de  $(y_i - \widehat{\mu}_i)$ , e

$$\widehat{h}_{ii} = \widehat{\phi}_i \widehat{\omega}_i \mathbf{x}_i^{\top} (\mathbf{X}^{\top} \widehat{\Phi} \widehat{W} \mathbf{X})^{-1} \mathbf{x}_i.$$

# Alavancagem - submodelo da média

Sob os MLGDs, a medida  $\hat{h}_{ij}$  pode ser vista como a variação causada em  $\hat{\eta}_i$  quando a resposta modificada associada ao submodelo da média  $\hat{y}_i^*$  é acrescida de uma contaminação infinitesimal, isto é,

$$\hat{h}_{ij} = \frac{\partial \hat{\eta}_i}{\partial \hat{y}_i^*}.$$

Assim,  $\hat{h}_{ij}$  é a medida de alavancagem associada ao submodelo da média obtida como sendo o  $i$ -ésimo elemento da diagonal principal de

$$\hat{H} = \hat{\Phi}^{1/2} \hat{W}^{1/2} X (X^\top \hat{\Phi} \hat{W} X)^{-1} X^\top \hat{\Phi}^{1/2} \hat{W}^{1/2}.$$

# Resíduos - submodelo da precisão

O resíduo componente do desvio para o submodelo da precisão é definido por

$$\widehat{t_{D_{\phi_i}}} = \frac{d_{\phi}^*(y_i; \widehat{\phi}_i, \widehat{\mu}_i)}{\sqrt{1 - \widehat{r}_{ii}}},$$

em que

$$d_{\phi}^*(y_i; \widehat{\phi}_i, \widehat{\mu}_i) = \pm \sqrt{2} \left\{ \widehat{t}_i(\widetilde{\phi}_i - \widehat{\phi}_i) + d(\widetilde{\phi}_i) - d(\widehat{\phi}_i) \right\}^{1/2},$$

$\pm$  corresponde ao sinal de  $(\widehat{t}_i + d'(\widehat{\phi}_i))$ , e

$$\widehat{r}_{ii} = \widehat{\rho}_i \mathbf{z}_i^{\top} (\mathbf{Z}^{\top} \widehat{\mathbf{P}} \mathbf{Z})^{-1} \mathbf{z}_i.$$



# Alavancagem - submodelo da precisão

Sob os MLGDs, a medida  $\hat{r}_{ii}$  pode ser vista como a variação causada em  $\hat{\lambda}_i$  quando a resposta modificada associada ao submodelo da precisão  $\hat{z}_i^*$  é acrescida de uma contaminação infinitesimal, isto é,

$$\hat{r}_{ii} = \frac{\partial \hat{\lambda}_i}{\partial \hat{z}_i^*}.$$

Assim,  $\hat{r}_{ii}$  é a medida de alavancagem associada ao submodelo da precisão obtida como sendo o  $i$ -ésimo elemento da diagonal principal de

$$\hat{R} = \hat{P}^{1/2} Z (Z^\top \hat{P} Z)^{-1} Z^\top \hat{P}^{1/2}.$$

# Resíduos - Ajuste global

O resíduo quantílico sob os MLGDs é definido por

$$r_{qi} = \Phi^{-1}(F(y_i; \hat{\mu}_i, \hat{\phi}_i)), \quad i = 1, 2, \dots, n.$$

Observe que, para  $n$  finito, os resíduos quantílicos não são normais padrão independentes desde que calcula-se  $r_{qi}$  sob as estimativas  $\hat{\mu}_i, \hat{\phi}_i$ .

Entretanto, se  $\hat{\mu}_i$  e  $\hat{\phi}_i$  são estimadores consistentes de  $\mu_i$  e  $\phi$ , respectivamente, então  $r_{qi} \stackrel{\text{iid}}{\sim} N(0, 1)$  para  $n$  grande.

Se  $y_i$  for um valor discrepante com relação ao modelo postulado  $F$ , o valor de  $F(y_i; \hat{\mu}_i, \hat{\phi}_i)$  será próximo de zero ou próximo de um. Consequentemente,  $|r_{qi}|$  assumirá um valor maior ou igual que 3, indicando assim  $y_i$  como aberrante.

# Influência - submodelo da média

A influência da  $i$ -ésima observação em  $\hat{\beta}$  pode ser mensurada através do afastamento pela verossimilhança definido por

$$LD_{\mu_i} = 2\{\ell(\hat{\beta}) - \ell(\hat{\beta}_{(i)})\},$$

em que  $\hat{\beta}_{(i)}$  é o EMV de  $\beta$  sem a  $i$ -ésima observação.

A distância de Cook aproximada para o submodelo da média é

$$LD_{\mu_i} = \hat{t}_{S_{\mu_i}}^2 \frac{\hat{h}_{ii}}{1 - \hat{h}_{ii}},$$

em que

$$\hat{t}_{S_{\mu_i}} = \frac{\sqrt{\hat{\phi}_i}(y_i - \hat{\mu}_i)}{\sqrt{\hat{V}_i(1 - \hat{h}_{ii})}}$$

é o resíduo de Pearson studentizado para o submodelo da média.

# Influência - submodelo da precisão

A influência da  $i$ -ésima observação em  $\hat{\gamma}$  pode ser mensurada através do afastamento pela verossimilhança definido por

$$LD_{\phi_i} = 2\{\ell(\hat{\gamma}) - \ell(\hat{\gamma}_{(i)})\},$$

em que  $\hat{\gamma}_{(i)}$  é o EMV de  $\gamma$  sem a  $i$ -ésima observação.

A distância de Cook aproximada para o submodelo da precisão é

$$LD_{\phi_i} = \hat{t}_{S_{\phi_i}}^2 \frac{\hat{r}_{ii}}{1 - \hat{r}_{ii}},$$

em que

$$\hat{t}_{S_{\phi_i}} = \frac{\hat{t}_i + d'(\hat{\phi}_i)}{\sqrt{-d''(\hat{\phi}_i)(1 - \hat{r}_{ii})}}$$

é o resíduo de Pearson studentizado para o submodelo da precisão.