

# Modelos Lineares Generalizados

## Unidade I

Terezinha K. A. Ribeiro

terezinha.ribeiro@unb.br

Instituto de Ciências Exatas  
Departamento de Estatística  
Universidade de Brasília

- ▶ Introdução
- ▶ Família exponencial uniparamétrica e suas propriedades
- ▶ Casos particulares
- ▶ Funções de ligação
- ▶ Estimação dos parâmetros
- ▶ Procedimento iterativo

O modelo de regressão linear normal (MRLN) amostral é definido por

$$Y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i, \quad i = 1, 2, \dots, n,$$

em que

- ▶  $Y_i$  é uma variável aleatória (observável) denominada de resposta;
- ▶  $x_{i1}, x_{i2}, \dots, x_{ip}$  são  $p < n$  variáveis não aleatórias (observáveis) chamadas de covariáveis; se  $x_{i1} = 1, \forall i$ , o modelo possui intercepto;
- ▶  $\beta_1, \beta_2, \dots, \beta_p$ , são os coeficientes/parâmetros da regressão desconhecidos que devem ser estimados;
- ▶  $\varepsilon_i$  é uma variável aleatória (não observável) denominada de erro da regressão e supõe-se que  $\varepsilon_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$ , com  $\stackrel{\text{iid}}{\sim}$  denotando “se distribuem de forma independente e são identicamente distribuídas”.

Veja que

$$E(Y_i) = \mu_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip},$$

$$\text{Var}(Y_i) = \sigma^2, \quad \forall i.$$

Note que este modelo é homoscedástico, ou seja, apesar da média de  $Y_i$  variar com as observações, a variância de  $Y_i$  é constante.

Para interpretar o coeficiente  $\beta_j$ ,  $j = 1, 2, \dots, p$ , considere o aumento de uma unidade em  $x_{ij}$  e que as demais covariáveis estão fixadas:

$$\mu_i(x'_{ij}) - \mu_i(x_{ij}) = \beta_j, \quad x'_{ij} = x_{ij} + 1.$$

Observa-se que  $\beta_j$  é a variação (aumento ou diminuição) na resposta média quando é adicionada uma unidade em  $x_{ij}$ . A variação na resposta média para um aumento de  $b$  unidades em  $x_{ij}$  é mensurada a partir de  $b \times \beta_j$ .

Veja que

$$E(Y_i) = \mu_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip},$$

$$\text{Var}(Y_i) = \sigma^2, \quad \forall i.$$

Note que este modelo é homoscedástico, ou seja, apesar da média de  $Y_i$  variar com as observações, a variância de  $Y_i$  é constante.

Para interpretar o coeficiente  $\beta_j$ ,  $j = 1, 2, \dots, p$ , considere o aumento de uma unidade em  $x_{ij}$  e que as demais covariáveis estão fixadas:

$$\mu_i(x'_{ij}) - \mu_i(x_{ij}) = \beta_j, \quad x'_{ij} = x_{ij} + 1.$$

Observa-se que  $\beta_j$  é a variação (aumento ou diminuição) na resposta média quando é adicionada uma unidade em  $x_{ij}$ . A variação na resposta média para um aumento de  $b$  unidades em  $x_{ij}$  é mensurada a partir de  $b \times \beta_j$ .

Forma equivalente de definir o MRLN:

- i)  $Y_i \mid \mathbf{x}_i \stackrel{\text{ind}}{\sim} N(\mu_i, \sigma^2)$  – componente aleatória;
- ii)  $\mu_i = \mathbf{x}_i^\top \boldsymbol{\beta}$  – componente determinística ou sistemática

em que  $\mathbf{x}_i^\top = (x_{i1} \ x_{i2} \ \cdots \ x_{ip}) \in \mathbb{R}^p$  é o vetor de valores conhecidos das  $p$  covariáveis para a  $i$ -ésima observação,  $\boldsymbol{\beta} = (\beta_1 \ \beta_2 \ \cdots \ \beta_p)^\top \in \mathbb{R}^p$  é o vetor de coeficientes da regressão, e  $\stackrel{\text{ind}}{\sim}$  denota “se distribuem de forma independente”.

Note que nesta última definição, o erro da regressão  $\varepsilon_i$  não está explicitado.

Os modelos lineares generalizados (MLGs) são definidos por

i)  $Y_i | \mathbf{x}_i \stackrel{\text{ind}}{\sim} \text{FE}(\mu_i, \phi)$

ii)  $g(\mu_i) = \eta_i \Leftrightarrow \mu_i = g^{-1}(\eta_i)$  com  $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$ ,

em que  $\text{FE}(\cdot, \cdot)$  denota uma distribuição pertencente à família de distribuições exponencial uniparamétrica;  $\phi > 0$  é um parâmetro de precisão ( $\phi^{-1}$  é um parâmetro de dispersão);  $g(\cdot)$  é uma função de ligação monótona e diferenciável;  $\eta_i$  é o preditor linear.

- ▶ Em i) ampliamos o número de opções para a distribuição de probabilidades da resposta  $Y_i$ .
- ▶ Em ii), ganhamos flexibilidade na modelagem da média  $\mu_i$  por meio de uma função  $g(\cdot)$ .

Os modelos lineares generalizados (MLGs) são definidos por

i)  $Y_i \mid \mathbf{x}_i \stackrel{\text{ind}}{\sim} \text{FE}(\mu_i, \phi)$

ii)  $g(\mu_i) = \eta_i \Leftrightarrow \mu_i = g^{-1}(\eta_i)$  com  $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$ ,

em que  $\text{FE}(\cdot, \cdot)$  denota uma distribuição pertencente à família de distribuições exponencial uniparamétrica;  $\phi > 0$  é um parâmetro de precisão ( $\phi^{-1}$  é um parâmetro de dispersão);  $g(\cdot)$  é uma função de ligação monótona e diferenciável;  $\eta_i$  é o preditor linear.

- ▶ Em i) ampliamos o número de opções para a distribuição de probabilidades da resposta  $Y_i$ .
- ▶ Em ii), ganhamos flexibilidade na modelagem da média  $\mu_i$  por meio de uma função  $g(\cdot)$ .



Em situações em que  $Y_i$  possui uma distribuição assimétrica, o MRLN não é adequado pois a inferência dos parâmetros (intervalar e testes de hipóteses) é construída sob a suposição de normalidade de  $Y_i \mid \mathbf{x}_i$ .

Em cenários como este, pode-se transformar  $Y_i$  para atingir normalidade. Por exemplo, para  $Y_i > 0$ , pode-se utilizar a transformação logarítmica. Daí, o MRLN é ajustado considerando como variável resposta  $Y_i^* = \log(Y_i)$ :

$$Y_i^* = \log(Y_i) = \mu_i^* + \varepsilon_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i,$$

com  $E(Y_i^*) = \mu_i^*$ .

Nesta abordagem, a interpretação de  $\beta_1, \beta_2, \dots, \beta_p$  é feita com relação à média do logaritmo da resposta. Neste caso,  $\beta_j$  é a variação na média de  $Y_i^*$  quando é adicionada uma unidade em  $x_{ij}$ .

Aqui  $\beta_j$  não é interpretado (de forma exata) diretamente em termos da média de  $Y_i$ .

Observe que

$$\begin{aligned} Y_i = e^{\log(Y_i)} &= \exp\{\beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i\} \\ &= \exp\{\beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip}\} \exp\{\varepsilon_i\}. \end{aligned}$$

Assim,

$$E(Y_i) = \exp\{\beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip}\} E(\exp\{\varepsilon_i\}).$$

Será que é possível calcular a média de  $Y_i$ ?

Dado que  $\varepsilon_i \sim N(0, \sigma^2)$ , qual é a distribuição da variável aleatória  $e^{\varepsilon_i}$ ?

**Revisão.** Se  $Z \sim N(\mu, \sigma^2)$ , então vale que

- ▶  $W = e^Z \sim \text{LN}(\mu, \sigma)$  com  $\text{LN}(\mu, \sigma)$  denotando a distribuição log-normal de parâmetros  $\mu \in \mathbb{R}$  e  $\sigma > 0$ ;
- ▶  $W = e^Z \sim \text{LN}(\mu, \sigma)$  com  $\text{Med}(W) = e^\mu$ ,

$$E(W) = e^{\mu + \sigma^2/2}, \quad \text{Var}(W) = (e^{\sigma^2} - 1)e^{2\mu + \sigma^2},$$

em que  $\text{Med}(W)$  denota a mediana da variável  $W$ .

De  $\varepsilon_i \sim N(0, \sigma^2)$ , tem-se que  $\exp\{\varepsilon_i\} \sim \text{LN}(0, \sigma)$ . Assim, obtemos

$$E(e^{\varepsilon_i}) = e^{\sigma^2/2}, \quad \text{Med}(e^{\varepsilon_i}) = e^0 = 1.$$

Daí, segue que

$$\mu_i = E(Y_i) = \exp\{\beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip}\} e^{\sigma^2/2}.$$

Se  $\sigma^2$  é um valor próximo a zero, então

$$\mu_i = E(Y_i) \approx \exp\{\beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip}\}.$$

Alguns estudos mostram que  $\sigma^2$  é um valor muito próximo a zero quando a transformação logarítmica é aplicada em  $Y$ .

Supondo que  $\sigma^2$  é próximo a zero, como interpretamos  $\beta_0$  e  $\beta_1$ ?

Considere o aumento de uma unidade em  $x_{ij}$  e que as demais co-variáveis estão fixadas:

$$\frac{\mu_i(x'_{ij})}{\mu_i(x_{ij})} \approx \frac{\exp\{\beta_1 x_{i1} + \cdots + \beta_j(x_{ij} + 1) + \cdots + \beta_p x_{ip}\}}{\exp\{\beta_1 x_{i1} + \cdots + \beta_j x_{ij} + \cdots + \beta_p x_{ip}\}} = e^{\beta_j},$$

em que  $x'_{ij} = x_{ij} + 1$ .

Observa-se que  $e^{\beta_j}$  é a variação percentual **aproximada** na resposta média quando é adicionada uma unidade em  $x_{ij}$ .

Logo, a interpretação dos coeficientes do MRLN com resposta transformada através do logaritmo não é exata!

De forma geral,

$$E(g(Y)) \neq g(E(Y)).$$

Por esta razão, ao aplicar uma transformação  $g(\cdot)$  na resposta  $Y_i$  e, em seguida, ajustar um MRLN sob  $g(Y_i)$ , perdemos a fácil interpretação dos coeficientes da regressão em termos da média da resposta.

Esta é a grande desvantagem desta abordagem. Perde-se interpretação dos  $\beta$ 's diretamente em termos da média de  $Y_i$ .

Uma grande diferença dos MLGs com relação ao MRLN é manter a distribuição assumida para a variável resposta intacta, e transformar o parâmetro  $\mu_i$  flexibilizando o ajuste do modelo aos dados.

A transformação  $g(\cdot)$  é aplicada na média da resposta (parâmetro) através de

$$g(\mu_i) = \eta_i.$$

Além da flexibilidade, a ideia da função de ligação é mapear o espaço em que está o parâmetro de localização  $\mu_i$  para a reta real, garantindo que os parâmetros de regressão sejam estimados sem restrições.

Por exemplo, suponha que  $Y_i$  segue uma distribuição de probabilidades positiva. Assim,  $\mu_i = E(Y_i) > 0$ . Seja  $g(z) = \log(z)$ , então  $g^{-1}(z) = e^z$ . Consequentemente,

$$g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta} \Rightarrow \log(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta} \in \mathbb{R} \Rightarrow \mu_i = \exp\{\mathbf{x}_i^\top \boldsymbol{\beta}\} > 0.$$

# Família exponencial uniparamétrica

Se  $Y \in \text{FE}(\mu, \phi)$ , a função densidade (ou função de probabilidade) de  $Y$  possui a forma

$$f(y; \theta, \phi) = \exp\{\phi[\theta y - b(\theta)] + c(y; \phi)\}, \quad (1)$$

em que

- ▶ o suporte desta família de distribuições não depende de  $\theta$  ou  $\phi$ ;
- ▶  $\theta = \theta(\mu)$  é uma função de  $\mu$  e é chamado de parâmetro canônico;
- ▶  $b(\theta)$  é uma função diferenciável que depende apenas de  $\theta$ ;
- ▶  $c(y; \phi)$  é uma função que depende de  $y$  e  $\phi$  e é diferenciável nos seus argumentos.

Note a função densidade em (1) é um caso particular da família exponencial de distribuições. A variável  $y$  aparece de forma linear em (1).



# Família exponencial uniparamétrica

Para derivar algumas propriedades desta família de distribuições, considere

$$\ell(\theta, \phi) = \log[f(y; \theta, \phi)] = \phi[\theta y - b(\theta)] + c(y; \phi).$$

As funções escore para  $\theta$  e  $\phi$  são dadas por

$$U_{\theta} = \frac{\partial \ell(\theta, \phi)}{\partial \theta} = \phi [y - b'(\theta)] ,$$

$$U_{\phi} = \frac{\partial \ell(\theta, \phi)}{\partial \phi} = \theta y - b(\theta) + c'(y; \theta),$$

em que

$$b'(\theta) = \frac{d}{d\theta}[b(\theta)], \quad c'(y; \phi) = \frac{d}{d\phi}[c(y; \theta)].$$

# Família exponencial uniparamétrica

Considere as seguintes condições de regularidade:

- $C_1)$  O suporte da distribuição de  $Y$  não depende de  $\theta$  ou  $\phi$ ;
- $C_2)$  É válida a troca entre os sinais de derivação e integração sob a densidade  $f(\cdot; \theta, \phi)$ .

Sob estas condições é válido que

$$E(U_\theta) = 0, \quad E(U'_\theta) = -E(U_\theta^2),$$

com

$$U'_\theta = \frac{\partial^2 \ell(\theta, \phi)}{\partial \theta^2}.$$

Daí, segue que

$$E\{\phi[Y - b'(\theta)]\} = 0 \Rightarrow E(Y) = \mu = b'(\theta).$$

# Família exponencial uniparamétrica

Também, temos que

$$U_{\theta}^2 = \{ \phi [y - b'(\theta)] \}^2 = \phi^2 (y - \mu)^2$$

$$\Rightarrow E(U_{\theta}^2) = \phi^2 E[(Y - \mu)^2] = \phi^2 \text{Var}(Y).$$

Ainda,  $U'_{\theta} = -\phi b''(\theta)$  com  $b''(\theta) = \frac{d^2}{d\theta^2}[b(\theta)]$ . Então,

$$E(U'_{\theta}) = -E(U_{\theta}^2) \Rightarrow -\phi b''(\theta) = -\phi^2 \text{Var}(Y)$$

$$\Rightarrow \text{Var}(Y) = \phi^{-1} b''(\theta) = \phi^{-1} V(\mu),$$

em que  $V(\mu) = b''(\theta)$  é conhecida como função de variância.

# Família exponencial uniparamétrica

A função de variância caracteriza a distribuição da família exponencial uniparamétrica. Por exemplo, a função de variância

$$V(\mu) = \mu(1 - \mu), 0 < \mu < 1,$$

caracteriza a classe de distribuições binomiais de sucesso  $\mu$  ou  $1 - \mu$ .

Note que para  $V(\mu)$  fixada,  $\text{Var}(Y) = \phi^{-1} V(\mu)$  aumenta quando  $\phi$  diminui, e, diminui quando  $\phi$  cresce. Por esta razão,  $\phi$  é considerado um parâmetro de precisão.

# Resultados aproximados

Sejam  $Y_1, Y_2, \dots, Y_n$  variáveis aleatórias independentes e identicamente distribuídas (iid) com  $E(Y_i) = \mu$  e  $\text{Var}(Y_i) = \sigma^2$ . Pelo Teorema do Limite Central, para  $n$  grande,

$$\bar{Y} \stackrel{a}{\sim} N\left(\mu, \frac{\sigma^2}{n}\right),$$

em que  $\stackrel{a}{\sim}$  denota “segue distribuição aproximada”.

Nos MLGs temos apenas independência entre  $Y_1, Y_2, \dots, Y_n$ . Para  $\phi$  grande,

$$Y \stackrel{a}{\sim} N\left(\mu, \frac{V(\mu)}{\phi}\right).$$

Note que este último resultado é válido para  $n = 1$  e precisão  $\phi$  grande.

# Casos particulares - Distribuição normal

Seja  $Y$  uma variável aleatória com distribuição normal de média  $\mu$  e variância  $\sigma^2$ . A função densidade de  $Y$  é dada por

$$f(y; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (y - \mu)^2 \right\}, \quad \begin{array}{l} y \in \mathbb{R}, \\ \mu \in \mathbb{R}, \\ \sigma^2 > 0. \end{array}$$

Denotaremos por  $Y \sim N(\mu, \sigma^2)$ .

Veja que

$$\begin{aligned} f(y; \mu, \sigma^2) &= \exp \left\{ -\frac{1}{2\sigma^2} (y^2 - 2\mu y + \mu^2) - \log \left[ (2\pi\sigma^2)^{1/2} \right] \right\} \\ &= \exp \left\{ \frac{1}{\sigma^2} \left( \mu y - \frac{\mu^2}{2} \right) - \frac{1}{2\sigma^2} y^2 - \frac{1}{2} \log (2\pi\sigma^2) \right\} \\ &= \exp \left\{ \frac{1}{\sigma^2} \left( \mu y - \frac{\mu^2}{2} \right) - \frac{1}{2} \left[ \log (2\pi\sigma^2) + \frac{y^2}{\sigma^2} \right] \right\}. \end{aligned}$$

# Casos particulares - Distribuição normal

Tome  $\phi = 1/\sigma^2$ ,  $\theta = \mu$ ,  $b(\theta) = \mu^2/2 = \theta^2/2$ , e

$$\begin{aligned}c(y; \phi) &= -\frac{1}{2} \left[ \log(2\pi\sigma^2) + \frac{y^2}{\sigma^2} \right] \\&= -\frac{1}{2} \left[ \log(2\pi\phi^{-1}) + \phi y^2 \right] \\&= -\frac{1}{2} \left[ \log\left(\frac{2\pi}{\phi}\right) + \phi y^2 \right] \\&= \frac{1}{2} \left[ \log\left(\frac{\phi}{2\pi}\right) - \phi y^2 \right].\end{aligned}$$

Também, o suporte da distribuição normal não depende de  $\theta$  ou  $\phi$  pois  $y \in \mathbb{R}$ .

Portanto,  $Y \in \text{FE}(\mu, \phi)$ .

# Casos particulares - Distribuição normal

Pelas propriedades da família exponencial uniparamétrica, temos que

$$E(Y) = b'(\theta) = \frac{2\theta}{2} = \theta = \mu;$$

$$V(\mu) = b''(\theta) = 1 \Rightarrow \text{Var}(Y) = \phi^{-1} V(\mu) = \sigma^2.$$

Para  $Y \sim N(\mu, \sigma^2)$ , temos

- ▶ média igual a  $\mu$ ;
- ▶ função de variância  $V(\mu)$  não depende da média  $\mu$ ;
- ▶ variância igual a  $\sigma^2$  (homoscedasticidade);
- ▶ adequação para dados contínuos reais;
- ▶ simetria em torno da média  $\mu$ .



# Casos particulares - Distribuição Poisson

Seja  $Y$  uma variável aleatória com distribuição de Poisson de parâmetro  $\mu$ . A função de probabilidade de  $Y$  é dada por

$$f(y; \mu) = \frac{e^{-\mu} \mu^y}{y!}, \quad y \in \{0, 1, 2, \dots\}, \quad \mu > 0.$$

Denotaremos por  $Y \sim \text{Poisson}(\mu)$ .

Veja que

$$f(y; \mu) = \exp \{y \log(\mu) - \mu - \log(y!)\}.$$

Tome  $\theta = \log(\mu) \Rightarrow \mu = e^\theta$ ,  $b(\theta) = \mu = e^\theta$ ,  $\phi = 1$  (conhecido), e  $c(y; \phi) = -\log(y!)$ .

Além disso, o suporte da distribuição Poisson não depende de  $\theta$  ou  $\phi$  desde que  $y \in \{0, 1, 2, \dots\}$ .

Logo,  $Y \in \text{FE}(\mu, \phi)$ .

# Casos particulares - Distribuição Poisson

Segue que

$$E(Y) = b'(\theta) = e^{\theta} = \mu;$$

$$V(\mu) = b''(\theta) = e^{\theta} = \mu \Rightarrow \text{Var}(Y) = \phi^{-1} V(\mu) = \mu.$$

Para  $Y \sim \text{Poisson}(\mu)$ , temos

- ▶ média igual a  $\mu$ ;
- ▶ variância igual a média (heteroscedasticidade);
- ▶ adequação para dados de contagem.

Dizemos que o modelo de Poisson acomoda equidispersão, isto é, acomoda dados que satisfazem  $E(Y) = \text{Var}(Y)$ . Esta é uma restrição forte desta distribuição para modelagem de dados de contagem.

# Casos particulares - Distribuição gama

Seja  $Y$  uma variável aleatória com distribuição gama de média  $\mu$  e coeficiente de variação  $\phi^{-1/2}$ . A função densidade de  $Y$  é dada por

$$f(y; \mu, \phi) = \frac{1}{\Gamma(\phi)} \left( \frac{\phi y}{\mu} \right)^\phi \exp \left\{ -\frac{\phi y}{\mu} \right\} \frac{1}{y}, \quad \begin{array}{l} y > 0, \\ \mu > 0, \\ \phi > 0, \end{array}$$

em que  $\Gamma(\cdot)$  é a função gama definida por

$$\Gamma(\phi) = \int_0^\infty t^{\phi-1} e^{-t} dt.$$

Esta função densidade está reparametrizada de tal forma que  $\mu = E(Y)$ .

Denotaremos por  $Y \sim \text{gama}(\mu, \phi)$ .

Se  $\phi = 1$  temos a distribuição exponencial. Se  $\phi = k/2$  e  $\mu = k$  temos a distribuição qui-quadrado com  $k$  graus de liberdade.

# Casos particulares - Distribuição gama

Veja que

$$\begin{aligned}f(y; \mu, \phi) &= \exp \left\{ -\log \Gamma(\phi) + \phi \log \left( \frac{\phi y}{\mu} \right) - \frac{\phi y}{\mu} - \log(y) \right\} \\&= \exp \left\{ -\log \Gamma(\phi) + \phi [\log(\phi y) - \log(\mu)] - \frac{\phi y}{\mu} - \log(y) \right\} \\&= \exp \{ \phi [-y/\mu - \log(\mu)] - \log \Gamma(\phi) + \phi \log(\phi y) - \log(y) \}.\end{aligned}$$

Tome  $\phi = \phi$ ,  $\theta = -\frac{1}{\mu} \Rightarrow \mu = -\theta^{-1}$ ,  $b(\theta) = \log(\mu) = -\log(-\theta)$ , com  $\theta < 0$ ,

$$\begin{aligned}c(y; \phi) &= \phi \log(\phi y) - \log \Gamma(\phi) - \log(y) \\&= \phi \log(\phi) + \phi \log(y) - \log \Gamma(\phi) - \log(y) \\&= (\phi - 1) \log(y) + \phi \log(\phi) - \log \Gamma(\phi).\end{aligned}$$

Além disto, o suporte da distribuição gama não depende de  $\theta$  ou  $\phi$  desde que  $y > 0$ . Logo,  $Y \in \text{FE}(\mu, \phi)$ .

Segue que

$$E(Y) = b'(\theta) = -\frac{1}{-\theta}(-1) = -\frac{1}{\theta} = \mu;$$

$$V(\mu) = b''(\theta) = \frac{1}{\theta^2} = \left(-\frac{1}{\theta}\right)^2 = \mu^2 \Rightarrow \text{Var}(Y) = \phi^{-1} V(\mu) = \phi^{-1} \mu^2.$$

Note que

$$\text{CV}(Y) = \frac{\text{DP}(Y)}{E(Y)} = \frac{(\phi^{-1} \mu^2)^{1/2}}{\mu} = \phi^{-1/2},$$

com  $\text{CV}(Y)$  e  $\text{DP}(Y)$  denotando coeficiente de variação e desvio-padrão de  $Y$ , respectivamente.

# Casos particulares - Distribuição gama

Para  $Y \sim \text{gama}(\mu, \phi)$ , temos

- ▶ média igual a  $\mu$ ;
- ▶ variância dependente da média através de  $\mu^2$  (heteroscedasticidade);
- ▶ coeficiente de variação igual a  $\phi^{-1/2}$ ;
- ▶ adequação para dados contínuos positivos assimétricos.

Adicionalmente, temos que para  $\phi$  grande

$$Y \stackrel{a}{\sim} N\left(\mu, \frac{\mu^2}{\phi}\right).$$

# Casos particulares - Distribuição normal inversa

Seja  $Y$  uma variável aleatória com distribuição normal inversa de média  $\mu$  e parâmetro de precisão  $\phi$ . A função densidade de  $Y$  é dada por

$$f(y; \mu, \phi) = \sqrt{\frac{\phi}{2\pi y^3}} \exp \left\{ -\frac{\phi(y - \mu)^2}{2\mu^2 y} \right\}, \quad \begin{array}{l} y > 0, \\ \mu > 0, \\ \phi > 0. \end{array}$$

Denotaremos por  $Y \sim \text{NI}(\mu, \phi)$ .

Veja que

$$\begin{aligned} f(y; \mu, \phi) &= \exp \left\{ -\frac{\phi(y^2 - 2\mu y + \mu^2)}{2\mu^2 y} + \frac{1}{2} \log \left( \frac{\phi}{2\pi y^3} \right) \right\} \\ &= \exp \left\{ \phi \left[ -\frac{y}{2\mu^2} + \frac{1}{\mu} \right] - \frac{\phi}{2y} + \frac{1}{2} \log \left( \frac{\phi}{2\pi y^3} \right) \right\}. \end{aligned}$$

# Casos particulares - Distribuição normal inversa

Tome  $\phi = \phi$ ,  $\theta = -\frac{1}{2\mu^2} \Rightarrow \mu = (-2\theta)^{-1/2}$ ,  $b(\theta) = -\frac{1}{\mu} = -(-2\theta)^{1/2}$ ,  
com  $\theta < 0$ ,

$$c(y; \phi) = -\frac{\phi}{2y} + \frac{1}{2} \log \left( \frac{\phi}{2\pi y^3} \right).$$

Além disto, o suporte da distribuição normal inversa não depende de  $\theta$  ou  $\phi$  desde que  $y > 0$ . Logo,  $Y \in \text{FE}(\mu, \phi)$ .

Segue que

$$E(Y) = b'(\theta) = -\frac{1}{2}(-2\theta)^{-1/2}(-2) = (-2\theta)^{-1/2} = \mu;$$

$$V(\mu) = b''(\theta) = -\frac{1}{2}(-2\theta)^{-3/2}(-2) = \left[(-2\theta)^{-1/2}\right]^3 = \mu^3$$

$$\Rightarrow \text{Var}(Y) = \phi^{-1} V(\mu) = \phi^{-1} \mu^3.$$



# Casos particulares - Distribuição normal inversa

Para  $Y \sim \text{NI}(\mu, \phi)$ , temos

- ▶ média igual a  $\mu$ ;
- ▶ variância dependente da média através de  $\mu^3$  (heteroscedasticidade);
- ▶ variância cresce mais rapidamente com  $\mu$  quando comparado ao modelo gama;
- ▶ adequação para dados contínuos positivos assimétricos;
- ▶ alternativa ao modelo gama.

Adicionalmente, temos que para  $\phi$  grande

$$Y \stackrel{a}{\sim} N\left(\mu, \frac{\mu^3}{\phi}\right).$$

# Casos particulares - Distribuição binomial

Seja  $Y$  uma variável aleatória com distribuição binomial de parâmetros  $n$  e  $0 < \mu < 1$ . A função de probabilidade de  $Y$  é dada por

$$f(y; \mu) = \binom{n}{y} \mu^y (1 - \mu)^{n-y}, \quad y \in \{0, 1, 2, \dots, n\}.$$

Denotaremos por  $Y \sim \text{binomial}(n, \mu)$ . O parâmetro  $n$  é conhecido.

Observe que

$$\begin{aligned} f(y; \mu) &= \exp \left\{ \log \binom{n}{y} + y \log(\mu) + (n - y) \log(1 - \mu) \right\} \\ &= \exp \left\{ y \log \left( \frac{\mu}{1 - \mu} \right) + n \log(1 - \mu) + \log \binom{n}{y} \right\}. \end{aligned}$$

# Casos particulares - Distribuição binomial

Considere  $\phi = 1$ ,

$$\theta = \log \left( \frac{\mu}{1 - \mu} \right) \Rightarrow \mu = \frac{e^{\theta}}{1 + e^{\theta}}, \quad \theta \in \mathbb{R};$$

$$b(\theta) = -n \log(1 - \mu) = -n \log \left( \frac{1}{1 + e^{\theta}} \right) = n \log(1 + e^{\theta});$$

$$c(y; \phi) = \log \binom{n}{y}.$$

Além disto, o suporte da distribuição binomial é o conjunto  $\{0, 1, 2, \dots, n\}$  que não depende de parâmetros desconhecidos. Logo,  $Y \in \text{FE}(\mu, \phi)$ .

Note que o suporte depende de  $n$ , entretanto o valor  $n$  sempre será conhecido.

# Casos particulares - Distribuição binomial

Segue que

$$E(Y) = b'(\theta) = \frac{ne^{\theta}}{1 + e^{\theta}} = n\mu;$$

$$V(\mu) = b''(\theta) = \frac{n[e^{\theta}(1 + e^{\theta}) - e^{\theta}e^{\theta}]}{(1 + e^{\theta})^2} = \frac{ne^{\theta}}{(1 + e^{\theta})^2} = n\mu(1 - \mu);$$

$$\Rightarrow \text{Var}(Y) = \phi^{-1} V(\mu) = n\mu(1 - \mu).$$

Assim, a função de variância  $V(\mu)$  depende do tamanho amostral  $n$ . Gostaríamos que  $V(\mu)$  dependa apenas da média  $\mu$ .

# Casos particulares - Distribuição binomial

Para resolver este “problema”, realizaremos uma mudança de escala através da transformação  $Y^* = \frac{Y}{n}$ . Note que  $Y^*$  representa a proporção de sucessos em  $n$  ensaios independentes de Bernoulli, cada um com probabilidade de ocorrência  $\mu$  com  $nY^* \sim \text{binomial}(n, \mu)$ .

Daí, a função de probabilidade de  $Y^*$  fica dada por

$$\begin{aligned} f(y^*; \mu) &= \binom{n}{ny^*} \mu^{ny^*} (1 - \mu)^{n - ny^*} \\ &= \exp \left\{ n \left[ y^* \log \left( \frac{\mu}{1 - \mu} \right) + \log(1 - \mu) \right] + \log \left( \binom{n}{ny^*} \right) \right\}. \end{aligned}$$

com  $y^* \in \left\{ 0, \frac{1}{n}, \dots, 1 \right\}$ .

# Casos particulares - Distribuição binomial

Tome  $\phi = n$  (conhecido),

$$\theta = \log \left( \frac{\mu}{1 - \mu} \right) \Rightarrow \mu = \frac{e^\theta}{1 + e^\theta}, \quad \theta \in \mathbb{R};$$

$$b(\theta) = -\log(1 - \mu) = -\log \left( \frac{1}{1 + e^\theta} \right) = \log(1 + e^\theta);$$

$$c(y; \phi) = \log \binom{n}{ny^*} = \log \binom{\phi}{\phi y^*}.$$

Além disto, o suporte da distribuição binomial é o conjunto  $\left\{0, \frac{1}{n}, \dots, 1\right\}$  que não depende de parâmetros desconhecidos. Logo,  $Y^* \in \text{FE}(\mu, \phi)$ .

# Casos particulares - Distribuição binomial

Segue que

$$E(Y^*) = b'(\theta) = \frac{e^\theta}{1 + e^\theta} = \mu;$$

$$V(\mu) = b''(\theta) = \frac{e^\theta (1 + e^\theta) - e^\theta e^\theta}{(1 + e^\theta)^2} = \frac{e^\theta}{(1 + e^\theta)^2} = \mu(1 - \mu);$$

$$\Rightarrow \text{Var}(Y^*) = \phi^{-1} V(\mu) = n^{-1} \mu(1 - \mu).$$

# Casos particulares - Distribuição binomial

Para  $Y^* = \frac{Y}{n}$  com  $nY^* \sim \text{binomial}(n, \mu)$ , temos

- ▶ média igual a  $\mu$ ;
- ▶ variância dependente da média através de  $\mu(1 - \mu)$  (heteroscedasticidade);
- ▶ variância assume valor menor nos extremos ( $\mu$  próximo a zero ou  $\mu$  próximo a um);
- ▶ adequação para modelagem de probabilidade de sucesso;
- ▶ quando  $n = 1$  obtém-se a regressão logística.

Adicionalmente, temos que para  $n$  grande

$$Y \overset{a}{\sim} N\left(\mu, \frac{\mu(1 - \mu)}{n}\right).$$



# Casos particulares

Na tabela abaixo estão apresentadas as principais distribuições pertencentes à família exponencial uniparamétrica.

Tabela 1: Principais distribuições pertencentes à  $FE(\mu, \phi)$ .

Distribuição	$\theta$	$\phi$	$b(\theta)$	$V(\mu)$
Normal	$\mu$	$1/\sigma^2$	$\theta^2/2$	1
Poisson	$\log(\mu)$	1	$e^\theta$	$\mu$
Gama	$-\frac{1}{\mu}$	$1/CV^2$	$-\log(-\theta)$	$\mu^2$
Normal Inversa	$-\frac{1}{2\mu^2}$	$\phi$	$-(-2\theta)^{1/2}$	$\mu^3$
Binomial	$\log\left(\frac{\mu}{1-\mu}\right)$	$n$	$\log(1 + e^\theta)$	$\mu(1 - \mu)$

# Funções de ligação

Como escolher uma função de ligação  $g(\cdot)$  adequada?

A princípio qualquer função monótona e diferenciável pode ser utilizada. Entretanto, existem algumas funções de ligação que são mais interessantes.

Dizemos que uma função de ligação  $g(\cdot)$  é canônica quando esta é obtida de  $\theta_i = \eta_i$ .

Para a distribuição normal sabemos que o parâmetro canônico é  $\theta_i = \mu_i$ . Assim, a igualdade  $\theta_i = \eta_i$  implica em  $\mu_i = \eta_i$ . Portanto, a função de ligação canônica para a distribuição normal é a ligação identidade

$$g(z) = z, \quad z \in \mathbb{R}.$$

# Funções de ligação

Como escolher uma função de ligação  $g(\cdot)$  adequada?

A princípio qualquer função monótona e diferenciável pode ser utilizada. Entretanto, existem algumas funções de ligação que são mais interessantes.

Dizemos que uma função de ligação  $g(\cdot)$  é canônica quando esta é obtida de  $\theta_i = \eta_i$ .

Para a distribuição normal sabemos que o parâmetro canônico é  $\theta_i = \mu_i$ . Assim, a igualdade  $\theta_i = \eta_i$  implica em  $\mu_i = \eta_i$ . Portanto, a função de ligação canônica para a distribuição normal é a ligação identidade

$$g(z) = z, \quad z \in \mathbb{R}.$$

# Funções de ligação

Para a distribuição Poisson temos que  $\theta_i = \log(\mu_i)$ . Assim,  $\theta_i = \eta_i$  implica em  $\log(\mu_i) = \eta_i$ . Daí, a função de ligação canônica para a distribuição Poisson é a ligação logarítmica

$$g(z) = \log(z), \quad z > 0.$$

Para a distribuição gama temos que  $\theta_i = -1/\mu_i$ . Assim,  $\theta_i = \eta_i$  implica em  $-1/\mu_i = \eta_i$ . Por conveniência, a função de ligação canônica para a distribuição gama é definida como

$$g(z) = \frac{1}{z}, \quad z \in \mathbb{R}$$

e esta é chamada de ligação recíproca.

# Funções de ligação

Para a distribuição Poisson temos que  $\theta_i = \log(\mu_i)$ . Assim,  $\theta_i = \eta_i$  implica em  $\log(\mu_i) = \eta_i$ . Daí, a função de ligação canônica para a distribuição Poisson é a ligação logarítmica

$$g(z) = \log(z), \quad z > 0.$$

Para a distribuição gama temos que  $\theta_i = -1/\mu_i$ . Assim,  $\theta_i = \eta_i$  implica em  $-1/\mu_i = \eta_i$ . Por conveniência, a função de ligação canônica para a distribuição gama é definida como

$$g(z) = \frac{1}{z}, \quad z \in \mathbb{R}$$

e esta é chamada de ligação recíproca.

# Funções de ligação

Para a distribuição normal inversa temos que  $\theta_i = -1/2\mu_i^2$ . Assim,  $\theta_i = \eta_i$  implica em  $-1/2\mu_i^2 = \eta_i$ . Por conveniência, a função de ligação canônica para a distribuição normal inversa é definida como

$$g(z) = \frac{1}{z^2}, \quad z \in \mathbb{R}$$

e esta é chamada de ligação recíproca ao quadrado.

Para a distribuição binomial temos que  $\theta_i = \log(\mu_i/(1 - \mu_i))$ . Assim,  $\theta_i = \eta_i$  implica em  $\log(\mu_i/(1 - \mu_i)) = \eta_i$ . Daí, a função de ligação canônica para a distribuição binomial, denominada de logito, é

$$g(z) = \text{logito}(z) = \log\left(\frac{z}{1-z}\right), \quad 0 < z < 1.$$

Neste caso, a função de ligação é inversa da função de distribuição acumulada (FDA) da distribuição logística.

# Funções de ligação

Para a distribuição normal inversa temos que  $\theta_i = -1/2\mu_i^2$ . Assim,  $\theta_i = \eta_i$  implica em  $-1/2\mu_i^2 = \eta_i$ . Por conveniência, a função de ligação canônica para a distribuição normal inversa é definida como

$$g(z) = \frac{1}{z^2}, \quad z \in \mathbb{R}$$

e esta é chamada de ligação recíproca ao quadrado.

Para a distribuição binomial temos que  $\theta_i = \log(\mu_i/(1 - \mu_i))$ . Assim,  $\theta_i = \eta_i$  implica em  $\log(\mu_i/(1 - \mu_i)) = \eta_i$ . Daí, a função de ligação canônica para a distribuição binomial, denominada de logito, é

$$g(z) = \text{logito}(z) = \log\left(\frac{z}{1-z}\right), \quad 0 < z < 1.$$

Neste caso, a função de ligação é inversa da função de distribuição acumulada (FDA) da distribuição logística.

# Funções de ligação

Na tabela abaixo temos as funções de ligação canônicas das principais distribuições pertencentes à família exponencial uniparamétrica.

**Tabela 2:** Ligações canônicas das principais distribuições pertencentes à  $FE(\mu, \phi)$ .

Distribuição	$g(z)$	Nome
Normal	$z$	identidade
Poisson	$\log(z)$	logarítmica
Gama	$1/z$	recíproca
Normal Inversa	$1/z^2$	recíproca ao quadrado
Binomial	$\text{logito}(z)$	logito



# Funções de ligação

Existem outras funções de ligação que são muito utilizadas na prática. Em especial, quando o parâmetro a ser modelado pertence ao intervalo  $(0, 1)$ .

- ▶ Ligação probito:

$$g(z) = \text{probit}(z) = \Phi^{-1}(z), \quad 0 < z < 1,$$

em que  $\Phi^{-1}(\cdot)$  denota a inversa da FDA da distribuição normal padrão.

- ▶ Ligação complemento log-log:

$$g(z) = \log(-\log(1 - z)), \quad 0 < z < 1.$$

Neste caso,  $g(z)$  corresponde a inversa da FDA da distribuição Gumbel padrão.

# Funções de ligação

Existem outras funções de ligação que são muito utilizadas na prática. Em especial, quando o parâmetro a ser modelado pertence ao intervalo  $(0, 1)$ .

- Ligação probito:

$$g(z) = \text{probit}(z) = \Phi^{-1}(z), \quad 0 < z < 1,$$

em que  $\Phi^{-1}(\cdot)$  denota a inversa da FDA da distribuição normal padrão.

- Ligação complemento log-log:

$$g(z) = \log(-\log(1 - z)), \quad 0 < z < 1.$$

Neste caso,  $g(z)$  corresponde a inversa da FDA da distribuição Gumbel padrão.

# Funções de ligação

Existem outras funções de ligação que são muito utilizadas na prática. Em especial, quando o parâmetro a ser modelado pertence ao intervalo  $(0, 1)$ .

- ▶ Ligação probito:

$$g(z) = \text{probit}(z) = \Phi^{-1}(z), \quad 0 < z < 1,$$

em que  $\Phi^{-1}(\cdot)$  denota a inversa da FDA da distribuição normal padrão.

- ▶ Ligação complemento log-log:

$$g(z) = \log(-\log(1 - z)), \quad 0 < z < 1.$$

Neste caso,  $g(z)$  corresponde a inversa da FDA da distribuição Gumbel padrão.

- Ligação cauchit:

$$g(z) = \tan(\pi(z - 0,5)), \quad 0 < z < 1,$$

em que  $\tan(\cdot)$  denota a função tangente. Neste caso,  $g(z)$  é a inversa da FDA da distribuição Cauchy padrão.

As ligações probito, complemento log-log e cauchit são alternativas a ligação logito para modelar parâmetros  $\theta$  tais que  $0 < \theta < 1$ . Por esta razão, estas ligações podem ser utilizadas para modelar a média da proporção de sucessos  $\mu$  do modelo binomial.

- Ligação cauchit:

$$g(z) = \tan(\pi(z - 0,5)), \quad 0 < z < 1,$$

em que  $\tan(\cdot)$  denota a função tangente. Neste caso,  $g(z)$  é a inversa da FDA da distribuição Cauchy padrão.

As ligações probito, complemento log-log e cauchit são alternativas a ligação logito para modelar parâmetros  $\theta$  tais que  $0 < \theta < 1$ . Por esta razão, estas ligações podem ser utilizadas para modelar a média da proporção de sucessos  $\mu$  do modelo binomial.

# Funções de ligação

As ligações logito, probito e cauchit são simétricas, isto é,

$$g(z) = -g(1 - z).$$

Isto é uma consequência das ligações serem baseadas em distribuições simétricas. O mesmo não pode ser dito sobre a ligação complemento log-log que é assimétrica.

Várias das ligações discutidas foram obtidas a partir de inversas de FDAs de distribuições de probabilidade contínuas padronizadas.

De forma geral, considerando  $F(z)$  uma FDA contínua em sua forma padronizada, pode-se definir uma função de ligação a partir de

$$\mu_i = F(\eta_i) \Leftrightarrow F^{-1}(\mu_i) = \eta_i, \quad 0 < \mu_i < 1, \quad \eta_i \in \mathbb{R}.$$

Daí, define-se a ligação como sendo  $g(z) = F^{-1}(z)$  com  $0 < z < 1$ .

# Funções de ligação

As ligações logito, probito e cauchit são simétricas, isto é,

$$g(z) = -g(1 - z).$$

Isto é uma consequência das ligações serem baseadas em distribuições simétricas. O mesmo não pode ser dito sobre a ligação complemento log-log que é assimétrica.

Várias das ligações discutidas foram obtidas a partir de inversas de FDAs de distribuições de probabilidade contínuas padronizadas.

De forma geral, considerando  $F(z)$  uma FDA contínua em sua forma padronizada, pode-se definir uma função de ligação a partir de

$$\mu_i = F(\eta_i) \Leftrightarrow F^{-1}(\mu_i) = \eta_i, \quad 0 < \mu_i < 1, \quad \eta_i \in \mathbb{R}.$$

Daí, define-se a ligação como sendo  $g(z) = F^{-1}(z)$  com  $0 < z < 1$ .

# Funções de ligação

Para ajustar MLGs no R utiliza-se a função `glm` do pacote `stats`.

- ▶ Para o modelo normal, as ligações disponíveis são identidade, logarítmica e recíproca;
- ▶ Para o modelo Poisson, as ligações disponíveis são identidade, logarítmica, raiz quadrada;
- ▶ Para o modelo gama, as ligações disponíveis são identidade, logarítmica e recíproca;
- ▶ Para o modelo normal inversa, as ligações disponíveis são identidade, logarítmica, recíproca e recíproca ao quadrado;
- ▶ Para o modelo binomial, as ligações disponíveis são logito, probito, complemento log-log, cauchit, logarítmica.

O padrão para cada modelo é a ligação canônica. Entretanto, a ligação canônica não é necessariamente a mais utilizada.



# Funções de ligação

Para ajustar MLGs no R utiliza-se a função `glm` do pacote `stats`.

- ▶ Para o modelo normal, as ligações disponíveis são identidade, logarítmica e recíproca;
- ▶ Para o modelo Poisson, as ligações disponíveis são identidade, logarítmica, raiz quadrada;
- ▶ Para o modelo gama, as ligações disponíveis são identidade, logarítmica e recíproca;
- ▶ Para o modelo normal inversa, as ligações disponíveis são identidade, logarítmica, recíproca e recíproca ao quadrado;
- ▶ Para o modelo binomial, as ligações disponíveis são logito, probito, complemento log-log, cauchit, logarítmica.

O padrão para cada modelo é a ligação canônica. Entretanto, a ligação canônica não é necessariamente a mais utilizada.

# Funções de ligação

Para ajustar MLGs no R utiliza-se a função `glm` do pacote `stats`.

- ▶ Para o modelo normal, as ligações disponíveis são identidade, logarítmica e recíproca;
- ▶ Para o modelo Poisson, as ligações disponíveis são identidade, logarítmica, raiz quadrada;
- ▶ Para o modelo gama, as ligações disponíveis são identidade, logarítmica e recíproca;
- ▶ Para o modelo normal inversa, as ligações disponíveis são identidade, logarítmica, recíproca e recíproca ao quadrado;
- ▶ Para o modelo binomial, as ligações disponíveis são logito, probito, complemento log-log, cauchit, logarítmica.

O padrão para cada modelo é a ligação canônica. Entretanto, a ligação canônica não é necessariamente a mais utilizada.

# Funções de ligação

Para ajustar MLGs no R utiliza-se a função `glm` do pacote `stats`.

- ▶ Para o modelo normal, as ligações disponíveis são identidade, logarítmica e recíproca;
- ▶ Para o modelo Poisson, as ligações disponíveis são identidade, logarítmica, raiz quadrada;
- ▶ Para o modelo gama, as ligações disponíveis são identidade, logarítmica e recíproca;
- ▶ Para o modelo normal inversa, as ligações disponíveis são identidade, logarítmica, recíproca e recíproca ao quadrado;
- ▶ Para o modelo binomial, as ligações disponíveis são logito, probito, complemento log-log, cauchit, logarítmica.

O padrão para cada modelo é a ligação canônica. Entretanto, a ligação canônica não é necessariamente a mais utilizada.

# Funções de ligação

Para ajustar MLGs no R utiliza-se a função `glm` do pacote `stats`.

- ▶ Para o modelo normal, as ligações disponíveis são identidade, logarítmica e recíproca;
- ▶ Para o modelo Poisson, as ligações disponíveis são identidade, logarítmica, raiz quadrada;
- ▶ Para o modelo gama, as ligações disponíveis são identidade, logarítmica e recíproca;
- ▶ Para o modelo normal inversa, as ligações disponíveis são identidade, logarítmica, recíproca e recíproca ao quadrado;
- ▶ Para o modelo binomial, as ligações disponíveis são logito, probito, complemento log-log, cauchit, logarítmica.

O padrão para cada modelo é a ligação canônica. Entretanto, a ligação canônica não é necessariamente a mais utilizada.

# Funções de ligação - Interpretações

Para realizar interpretação de algumas funções de ligação, considere a estrutura de regressão:

$$g(\mu) = \eta = \alpha + \beta x,$$

em que  $x$  é uma covariável contínua. Seja  $x' = x + 1$ .

Se  $g(z) = z$ , então

$$\mu' = \alpha + \beta(x + 1) = \alpha + \beta x + \beta = \mu + \beta.$$

Assim,  $\beta$  é a variação na média da resposta quando  $x$  é acrescido de uma unidade.

A interpretação é análoga para o caso com duas ou mais covariáveis desde que as demais covariáveis estejam fixadas.

# Funções de ligação - Interpretações

Se  $g(z) = \log(z)$ , então  $\log(\mu) = \alpha + \beta x \Rightarrow \mu = e^{\alpha + \beta x}$ . Daí, segue que

$$\mu' = e^{\alpha + \beta(x+1)} = e^{\alpha + \beta x} e^{\beta} = \mu e^{\beta} \Rightarrow e^{\beta} = \frac{\mu'}{\mu}.$$

Logo,  $e^{\beta}$  é a variação percentual na média da resposta quando  $x$  é acrescido de uma unidade.

Se  $e^{\beta} > 1$ , então tem-se aumento percentual na média quando  $x$  aumenta. Se  $0 < e^{\beta} < 1$ , então tem-se redução percentual na média quando  $x$  aumenta.

Novamente, a interpretação é análoga para o caso com duas ou mais covariáveis desde que as demais covariáveis estejam fixadas.

# Funções de ligação - Interpretações

Se  $g(z) = \text{logito}(z)$ , então  $\text{logito}(z) = \alpha + \beta x$ .

Veja que

$$\log\left(\frac{\mu}{1-\mu}\right) = \alpha + \beta x \Rightarrow \frac{\mu}{1-\mu} = e^{\alpha+\beta x},$$

em que  $0 < \mu < 1$  é a probabilidade de sucesso. A quantidade  $\mu/(1-\mu)$  é denominada de chance do sucesso.

- ▶ Se a chance é igual a 1, sucesso e fracasso são igualmente prováveis;
- ▶ Se a chance é maior do que 1, o sucesso é mais provável do que o fracasso;
- ▶ Se a chance é menor do que 1, o fracasso é mais provável do que o sucesso.

# Funções de ligação - Interpretações

Adicionando uma unidade em  $x$ , obtemos que a chance do sucesso fica dada por

$$\frac{\mu'}{1 - \mu'} = e^{\alpha + \beta(x+1)} = e^{\alpha + \beta x} e^{\beta} = \frac{\mu}{1 - \mu} e^{\beta}.$$

Consequentemente,

$$e^{\beta} = \frac{\mu' / (1 - \mu')}{\mu / (1 - \mu)}.$$

Portanto,  $e^{\beta}$  é a razão de chances do sucesso quando adiciona-se uma unidade em  $x$ .

Por exemplo, considere  $Y$  é a ocorrência de uma certa doença ( $Y = 1$  se doente, caso contrário,  $Y = 0$ ) e  $x$  é a idade do indivíduo. Neste caso,  $e^{\beta}$  é a variação percentual na chance do indivíduo desenvolver a doença quando aumenta-se um ano na idade.



# Estimação dos parâmetros

Por suposição  $Y_i \mid \mathbf{x}_i \stackrel{\text{ind}}{\sim} \text{FE}(\mu_i, \phi)$  com  $\mu_i = g^{-1}(\eta_i)$  e  $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$ .

O vetor de parâmetros  $\boldsymbol{\theta} = (\boldsymbol{\beta}^\top \phi)^\top$  é desconhecido e deve ser estimado com base em dados amostrais. Sob os MLGs, o procedimento de estimação baseia-se no método de máxima verossimilhança.

Considere a função de verossimilhança  $L(\boldsymbol{\theta})$  como sendo a função densidade de probabilidade conjunta de  $\mathbf{Y} = (Y_1, Y_2, \dots, Y_n)^\top$ .

O estimador de máxima verossimilhança (EMV) para  $\boldsymbol{\theta} = (\boldsymbol{\beta}^\top \phi)^\top$  é o valor de  $\boldsymbol{\theta}$  que maximiza a função de verossimilhança  $L(\boldsymbol{\theta})$ , isto é,

$$\hat{\boldsymbol{\theta}} = \underset{\boldsymbol{\theta} \in \mathbb{R}^{p+1}}{\operatorname{argmax}} [L(\boldsymbol{\theta})],$$

em que  $\hat{\boldsymbol{\theta}}$  é o EMV para  $\boldsymbol{\theta}$ . Ao maximizar  $L(\boldsymbol{\theta})$  com relação a  $\boldsymbol{\theta}$  estaremos determinando o valor de  $\boldsymbol{\theta}$  com maior plausibilidade de ter gerado a amostra  $\mathbf{Y}$ .

# Estimação dos parâmetros

Pela independência de  $Y_1, \dots, Y_n$ , a função de verossimilhança fica dada por

$$\begin{aligned} L(\theta) &= \prod_{i=1}^n f(y_i; \theta_i, \phi) \\ &= \prod_{i=1}^n \exp\{\phi[\theta_i y_i - b(\theta_i)] + c(y_i; \phi)\} \\ &= \exp\left\{\sum_{i=1}^n [\phi[\theta_i y_i - b(\theta_i)] + c(y_i; \phi)]\right\} \\ &= \exp\left\{\phi \sum_{i=1}^n [\theta_i y_i - b(\theta_i)] + \sum_{i=1}^n c(y_i; \phi)\right\}. \end{aligned}$$

# Estimação dos parâmetros

O valor de  $\theta$  que maximiza  $L(\theta)$  é o mesmo que maximiza  $\ell(\theta) = \log(L(\theta))$  pois a função logaritmo é monótona crescente. Assim, o logaritmo da função de verossimilhança para  $\theta$  é

$$\ell(\theta) = \phi \sum_{i=1}^n [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^n c(y_i; \phi).$$

Para encontrar o valor de  $\theta$  que maximiza  $\ell(\theta)$ , podemos derivar  $\ell(\theta)$  com relação a  $\theta$ , e posteriormente, igualar a derivada obtida ao vetor de zeros de dimensão  $(p + 1)$ .

O vetor escore para  $\theta$  é definido por

$$U(\theta) = \begin{bmatrix} U_{\beta}(\theta) \\ U_{\phi}(\theta) \end{bmatrix} = \begin{bmatrix} \frac{\partial \ell(\theta)}{\partial \beta} \\ \frac{\partial \ell(\theta)}{\partial \phi} \end{bmatrix}.$$

# Estimação dos parâmetros

Daí, para  $j = 1, 2, \dots, p$ , temos

$$U_{\beta_j} = \frac{\partial \ell(\boldsymbol{\theta})}{\partial \beta_j} = \phi \sum_{i=1}^n \left\{ y_i \frac{d\theta_i}{d\mu_i} \frac{d\mu_i}{d\eta_i} \frac{\partial \eta_i}{\partial \beta_j} - \frac{db(\theta_i)}{d\theta_i} \frac{d\theta_i}{d\mu_i} \frac{d\mu_i}{d\eta_i} \frac{\partial \eta_i}{\partial \beta_j} \right\}.$$

Sabemos que

$$\mu_i = b'(\theta_i) = \frac{db(\theta_i)}{d\theta_i}; \quad \frac{\partial \eta_i}{\partial \beta_j} = x_{ij};$$

$$V_i = V(\mu_i) = b''(\theta_i) = \frac{d^2 b(\theta_i)}{d\theta_i^2} = \frac{d\mu_i}{d\theta_i} = \frac{1}{\frac{d\theta_i}{d\mu_i}};$$

$$\frac{d\mu_i}{d\eta_i} = \frac{d[g^{-1}(\eta_i)]}{d\eta_i} = \frac{1}{g'(g^{-1}(\eta_i))} = \frac{1}{g'(\mu_i)}.$$

# Estimação dos parâmetros

Assim, ficamos com

$$U_{\beta_j} = \phi \sum_{i=1}^n (y_i - \mu_i) \frac{1}{V_i} \frac{d\mu_i}{d\eta_i} x_{ij} = \sum_{i=1}^n \phi \left[ \sqrt{\frac{\omega_i}{V_i}} (y_i - \mu_i) x_{ij} \right],$$

em que

$$\omega_i = \frac{(d\mu_i/d\eta_i)^2}{V_i} > 0$$

é visto com um peso.

Note que o numerador de  $\omega_i$  depende da função de ligação e o denominador de  $\omega_i$  caracteriza a distribuição de probabilidades da FE.

Daí, o vetor escore para  $\beta$  é

$$U_{\beta}(\theta) = \frac{\partial \ell(\theta)}{\partial \beta} = \phi X^{\top} W^{1/2} V^{-1/2} (\mathbf{y} - \boldsymbol{\mu}),$$

# Estimação dos parâmetros

em que  $W = \text{diag}\{\omega_1, \omega_2, \dots, \omega_n\}$ ,  $V = \text{diag}\{V_1, V_2, \dots, V_n\}$ ,

$$X = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix}, \quad \mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad \boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_n \end{bmatrix}$$

Por fim, o escore para  $\phi$  é dado por

$$U_\phi(\boldsymbol{\theta}) = \frac{\partial \ell(\boldsymbol{\theta})}{\partial \phi} = \sum_{i=1}^n [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^n c'(y_i; \phi),$$

em que  $c'(y_i; \phi) = dc(y_i; \phi) / d\phi$ .

# Estimação dos parâmetros

Note que se  $g(\cdot)$  é a ligação canônica ( $\theta_i = \eta_i$ ),

$$\frac{d\mu_i}{d\eta_i} = \frac{d\mu_i}{d\theta_i} \frac{d\theta_i}{d\eta_i} = V_i,$$

pois  $d\theta_i/d\eta_i = 1$ .

Assim, sob ligação canônica tem-se que os pesos se reduzem a

$$\omega_i = \frac{(d\mu_i/d\eta_i)^2}{V_i} = \frac{V_i^2}{V_i} = V_i,$$

e o vetor escore para  $\beta$  fica expresso por

$$U_{\beta}(\theta) = \phi X^{\top} V^{1/2} V^{-1/2} (\mathbf{y} - \boldsymbol{\mu}) = \phi X^{\top} (\mathbf{y} - \boldsymbol{\mu}).$$

# Estimação dos parâmetros

Para encontrar  $\hat{\theta}$ , fazemos

$$U_{\beta}(\theta) = \mathbf{0}, \quad U_{\phi}(\theta) = 0.$$

Mas,

$$U_{\beta}(\theta) = \mathbf{0} \Leftrightarrow X^{\top} \widehat{W}^{1/2} \widehat{V}^{-1/2} (\mathbf{y} - \hat{\mu}) = \mathbf{0}.$$

Note que o sistema de equações acima não depende de  $\hat{\phi}$ . Assim, o parâmetro  $\phi$  não precisa ser estimado conjuntamente com  $\beta$ .

De forma geral,  $\hat{\beta}$  não possui forma fechada. Por esta razão, estudaremos um processo iterativo para encontrar o valor de  $\hat{\beta}$ .



# Estimação dos parâmetros

De  $U_{\phi}(\theta) = 0$ , obtemos que

$$-\sum_{i=1}^n [y_i \hat{\theta}_i - b(\hat{\theta}_i)] = \sum_{i=1}^n c'(y_i; \hat{\phi}).$$

Quando estivermos sob os modelos normal e normal inversa, veremos que  $\hat{\phi}$  possui forma fechada.

Lembre-se que há situações em que não será necessário estimar  $\phi$  pois este será um valor conhecido.

# Estimação dos parâmetros

A matriz de informação de Fisher é obtida a partir de

$$K_{\theta\theta} = \begin{bmatrix} K_{\beta\beta} & K_{\beta\phi} \\ K_{\phi\beta} & K_{\phi\phi} \end{bmatrix} = \begin{bmatrix} -E \left( \frac{\partial^2 \ell(\theta)}{\partial \beta \partial \beta^\top} \right) & -E \left( \frac{\partial^2 \ell(\theta)}{\partial \beta \partial \phi} \right) \\ -E \left( \frac{\partial^2 \ell(\theta)}{\partial \phi \partial \beta^\top} \right) & -E \left( \frac{\partial^2 \ell(\theta)}{\partial \phi \partial \phi} \right) \end{bmatrix}.$$

Para  $j, l = 1, 2, \dots, p$ , tem-se que

$$\begin{aligned} \frac{\partial^2 \ell(\theta)}{\partial \beta_j \partial \beta_l} &= \frac{\partial U_{\beta_j}}{\partial \beta_l} = \frac{\partial}{\partial \beta_l} \left\{ \phi \sum_{i=1}^n (y_i - \mu_i) \frac{1}{V_i} \frac{d\mu_i}{d\eta_i} x_{ij} \right\} \\ &= \phi \sum_{i=1}^n \frac{\partial [(y_i - \mu_i)]}{\partial \beta_l} V_i^{-1} \frac{d\mu_i}{d\eta_i} x_{ij} + \phi \sum_{i=1}^n (y_i - \mu_i) x_{ij} \frac{\partial}{\partial \beta_l} \left[ V_i^{-1} \frac{d\mu_i}{d\eta_i} \right] \end{aligned}$$

# Estimação dos parâmetros

A matriz de informação de Fisher é obtida a partir de

$$K_{\theta\theta} = \begin{bmatrix} K_{\beta\beta} & K_{\beta\phi} \\ K_{\phi\beta} & K_{\phi\phi} \end{bmatrix} = \begin{bmatrix} -E \left( \frac{\partial^2 \ell(\theta)}{\partial \beta \partial \beta^\top} \right) & -E \left( \frac{\partial^2 \ell(\theta)}{\partial \beta \partial \phi} \right) \\ -E \left( \frac{\partial^2 \ell(\theta)}{\partial \phi \partial \beta^\top} \right) & -E \left( \frac{\partial^2 \ell(\theta)}{\partial \phi \partial \phi} \right) \end{bmatrix}.$$

Para  $j, l = 1, 2, \dots, p$ , tem-se que

$$\begin{aligned} \frac{\partial^2 \ell(\theta)}{\partial \beta_j \partial \beta_l} &= \frac{\partial U_{\beta_j}}{\partial \beta_l} = \frac{\partial}{\partial \beta_l} \left\{ \phi \sum_{i=1}^n (y_i - \mu_i) \frac{1}{V_i} \frac{d\mu_i}{d\eta_i} x_{ij} \right\} \\ &= \phi \sum_{i=1}^n \frac{\partial[(y_i - \mu_i)]}{\partial \beta_l} V_i^{-1} \frac{d\mu_i}{d\eta_i} x_{ij} + \phi \sum_{i=1}^n (y_i - \mu_i) x_{ij} \frac{\partial}{\partial \beta_l} \left[ V_i^{-1} \frac{d\mu_i}{d\eta_i} \right] \end{aligned}$$

# Estimação dos parâmetros

$$\begin{aligned}\frac{\partial^2 \ell(\boldsymbol{\theta})}{\partial \beta_j \partial \beta_l} &= \phi \sum_{i=1}^n \left\{ -\frac{d\mu_i}{d\eta_i} \frac{\partial \eta_i}{\partial \beta_l} V_i^{-1} \frac{d\mu_i}{d\eta_i} x_{ij} \right\} \\ &\quad + \phi \sum_{i=1}^n (y_i - \mu_i) x_{ij} \left\{ \frac{\partial}{\partial \beta_l} \left[ V_i^{-1} \right] \frac{d\mu_i}{d\eta_i} + V_i^{-1} \frac{d^2 \mu_i}{d\eta_i^2} \frac{\partial \eta_i}{\partial \beta_l} \right\} \\ &= -\phi \sum_{i=1}^n V_i^{-1} \left( \frac{d\mu_i}{d\eta_i} \right)^2 x_{ij} x_{il} + \phi \sum_{i=1}^n (y_i - \mu_i) x_{ij} \frac{d^2 \theta_i}{d\mu_i^2} \frac{d\mu_i}{d\eta_i} \frac{\partial \eta_i}{\partial \beta_l} \frac{d\mu_i}{d\eta_i} \\ &\quad + \phi \sum_{i=1}^n (y_i - \mu_i) x_{ij} V_i^{-1} \frac{d^2 \mu_i}{d\eta_i^2} x_{il},\end{aligned}$$

desde que

$$V_i^{-1} = \frac{d\theta_i}{d\mu_i}.$$

# Estimação dos parâmetros

Segue que

$$\begin{aligned}\frac{\partial^2 \ell(\boldsymbol{\theta})}{\partial \beta_j \partial \beta_l} = & -\phi \sum_{i=1}^n V_i^{-1} \left( \frac{d\mu_i}{d\eta_i} \right)^2 x_{ij} x_{il} + \phi \sum_{i=1}^n (y_i - \mu_i) \frac{d^2 \theta_i}{d\mu_i^2} \left( \frac{d\mu_i}{d\eta_i} \right)^2 x_{il} x_{ij} \\ & + \phi \sum_{i=1}^n (y_i - \mu_i) \frac{d^2 \mu_i}{d\eta_i^2} V_i^{-1} x_{ij} x_{il}.\end{aligned}$$

Portanto,

$$\begin{aligned}-E \left\{ \frac{\partial^2 \ell(\boldsymbol{\theta})}{\partial \beta_j \partial \beta_l} \right\} &= \phi \sum_{i=1}^n V_i^{-1} \left( \frac{d\mu_i}{d\eta_i} \right)^2 x_{ij} x_{il} \\ &= \phi \sum_{i=1}^n \omega_i x_{ij} x_{il},\end{aligned}$$

desde que

$$E(Y_i - \mu_i) = 0, \quad \omega_i = \frac{(d\mu_i/d\eta_i)^2}{V_i}.$$

# Estimação dos parâmetros

Matricialmente, a matriz de informação de Fisher para  $\beta$  é

$$K_{\beta\beta} = -E \left\{ \frac{\partial^2 \ell(\theta)}{\partial \beta \partial \beta^\top} \right\} = \phi X^\top W X.$$

Se  $W$  é uma matriz positiva definida, então  $r(X^\top W X) = r(X)$ . Se  $X$  é de posto completo, então  $X^\top W X$  é invertível e positiva definida.

Se a ligação é a canônica ( $\theta_i = \eta_i$ ), tem-se  $\omega_i = V_i$ , e consequentemente,

$$K_{\beta\beta} = \phi X^\top V X.$$

# Estimação dos parâmetros

Com relação ao parâmetro  $\phi$ ,

$$\frac{\partial^2 \ell(\boldsymbol{\theta})}{\partial \phi^2} = \frac{\partial}{\partial \phi} \left\{ \sum_{i=1}^n [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^n c'(y_i; \phi) \right\} = \sum_{i=1}^n c''(y_i; \phi),$$

em que

$$c''(y_i; \phi) = \frac{d^2 c(y_i; \phi)}{d\phi^2}.$$

Daí, a informação de Fisher para  $\phi$  é

$$K_{\phi\phi} = -E \left\{ \frac{\partial^2 \ell(\boldsymbol{\theta})}{\partial \phi^2} \right\} = -E \left\{ \sum_{i=1}^n c''(Y_i; \phi) \right\} = -\sum_{i=1}^n E[c''(Y_i; \phi)].$$

# Estimação dos parâmetros

Finalmente, para  $j = 1, 2, \dots, p$ ,

$$\frac{\partial^2 \ell(\theta)}{\partial \beta_j \partial \phi} = \frac{\partial}{\partial \phi} \left\{ \phi \sum_{i=1}^n (y_i - \mu_i) \frac{1}{V_i} \frac{d\mu_i}{d\eta_i} x_{ij} \right\} = \sum_{i=1}^n (y_i - \mu_i) \frac{1}{V_i} \frac{d\mu_i}{d\eta_i} x_{ij}.$$

Implicando que

$$K_{\beta\phi} = K_{\phi\beta}^\top = -E \left\{ \frac{\partial^2 \ell(\theta)}{\partial \beta \partial \phi} \right\} = \mathbf{0}_{p \times 1}.$$

A matriz de informação de Fisher para  $\theta = (\beta^\top \phi)^\top$  é dada por

$$K_{\theta\theta} = \text{diag}\{K_{\beta\beta}, K_{\phi\phi}\} = \begin{bmatrix} \phi X^\top W X & \mathbf{0} \\ \mathbf{0} & -\sum_{i=1}^n E[c''(Y_i; \phi)] \end{bmatrix}.$$

Como a matriz  $K_{\theta\theta}$  é bloco diagonal, concluímos que os parâmetros  $\beta$  e  $\phi$  são ortogonais.



# Normalidade assintótica do EMV

Para  $n$  grande, pode-se mostrar que

$$\hat{\theta} \sim N_{p+1} \left( \theta, K_{\theta\theta}^{-1} \right),$$

em que

$$K_{\theta\theta}^{-1} = \text{diag}\{K_{\beta\beta}^{-1}, K_{\phi\phi}^{-1}\} = \begin{bmatrix} \phi^{-1}(X^{\top}WX)^{-1} & \mathbf{0} \\ \mathbf{0} & \{-\sum_{i=1}^n E[c''(Y_i; \phi)]\}^{-1} \end{bmatrix}.$$

Particularmente, para  $n$  grande,

$$\hat{\beta} \sim N_p \left( \beta, \phi^{-1}(X^{\top}WX)^{-1} \right),$$

$$\hat{\phi} \sim N \left( \phi, \left\{ -\sum_{i=1}^n E[c''(Y_i; \phi)] \right\}^{-1} \right).$$

# Casos particulares - Distribuição normal

Sabemos que  $\theta_i = \mu_i$ ,  $\phi = 1/\sigma^2$  e  $V_i = 1$ . Daí, os pesos ficam expressos por

$$\omega_i = \frac{(d\mu_i | d\eta_i)^2}{V_i} = \left( \frac{d\mu_i}{d\theta_i} \frac{d\theta_i}{d\eta_i} \right)^2 = \left( \frac{d\theta_i}{d\eta_i} \right)^2.$$

O vetor escore para  $\beta$  fica expresso por

$$U_\beta = \frac{1}{\sigma^2} X^\top W^{1/2} (\mathbf{y} - \boldsymbol{\mu}), \quad K_{\beta\beta} = \frac{1}{\sigma^2} X^\top W X.$$

Se a ligação é canônica ( $\theta_i = \eta_i$ ) obtemos que  $\omega_i = 1, \forall i$ , reduzindo as expressões para

$$U_\beta = \frac{1}{\sigma^2} X^\top (\mathbf{y} - \boldsymbol{\mu}), \quad K_{\beta\beta} = \frac{1}{\sigma^2} X^\top X.$$

# Casos particulares - Distribuição normal

Sabemos que  $\hat{\phi}$  é obtido tal que  $U_{\phi} = 0$ , isto é,

$$-\sum_{i=1}^n [y_i \hat{\theta}_i - b(\hat{\theta}_i)] = \sum_{i=1}^n c'(y_i; \hat{\phi}).$$

Neste caso,

$$c(y_i; \phi) = \frac{1}{2} \left[ \log \left( \frac{\phi}{2\pi} \right) - \phi y_i^2 \right].$$

Daí, obtemos que

$$c'(y_i; \phi) = \frac{1}{2} \left[ \frac{2\pi}{\phi} \frac{1}{2\pi} - y_i^2 \right] = \frac{1}{2\phi} - \frac{y_i^2}{2}.$$

Também,  $\hat{\theta}_i = \hat{\mu}_i$  e  $b(\hat{\theta}_i) = \hat{\mu}_i^2/2$ .

# Casos particulares - Distribuição normal

Assim,  $\hat{\phi}$  é tal que

$$\begin{aligned} -\sum_{i=1}^n \left[ y_i \hat{\mu}_i - \frac{\hat{\mu}_i^2}{2} \right] &= \sum_{i=1}^n \left[ \frac{1}{2\hat{\phi}} - \frac{y_i^2}{2} \right] \Leftrightarrow \\ -\sum_{i=1}^n y_i \hat{\mu}_i + \frac{1}{2} \sum_{i=1}^n \hat{\mu}_i^2 &= \frac{n}{2\hat{\phi}} - \frac{1}{2} \sum_{i=1}^n y_i^2 \Leftrightarrow \\ \frac{n}{\hat{\phi}} &= \sum_{i=1}^n (y_i^2 - 2y_i \hat{\mu}_i + \hat{\mu}_i^2) \Leftrightarrow \\ \hat{\phi} &= \frac{n}{D(\mathbf{y}; \hat{\boldsymbol{\mu}})}, \end{aligned}$$

em que

$$D(\mathbf{y}; \hat{\boldsymbol{\mu}}) = \sum_{i=1}^n (y_i - \hat{\mu}_i)^2.$$

# Casos particulares - Distribuição normal

Também, temos que

$$c''(y_i; \phi) = -\frac{1}{2\phi^2},$$

e portanto, a matriz de informação de Fisher para  $\phi$  fica dada por

$$K_{\phi\phi} = -\sum_{i=1}^n E[c''(Y_i; \phi)] = \sum_{i=1}^n \frac{1}{2\phi^2} = \frac{n}{2\phi^2}.$$

Daí, a variância assintótica de  $\hat{\phi}$  é dada por

$$\text{Var}(\hat{\phi}) = \frac{2\phi^2}{n} \Rightarrow \widehat{\text{Var}}(\hat{\phi}) = \frac{2\hat{\phi}^2}{n}.$$

# Casos particulares - Distribuição Poisson

Sabemos que  $\phi = 1$  (constante),  $\theta_i = \log(\mu_i)$  e  $V_i = \mu_i$ . Daí, temos que

$$\omega_i = \frac{1}{V_i} \left( \frac{d\mu_i}{d\theta_i} \frac{d\theta_i}{d\eta_i} \right)^2 = \frac{1}{\mu_i} \left( \mu_i \frac{d\theta_i}{d\eta_i} \right)^2 = \mu_i \left( \frac{d\theta_i}{d\eta_i} \right)^2.$$

De forma geral,

$$U_{\beta} = X^{\top} W^{1/2} V^{-1/2} (\mathbf{y} - \boldsymbol{\mu}), \quad K_{\beta\beta} = X^{\top} W X.$$

Em particular, se  $g(\cdot)$  é a ligação canônica ( $\theta_i = \eta_i$ ), tem-se que  $\omega_i = V_i = \mu_i, \forall i$ . Neste caso, os pesos são as próprias médias.

# Casos particulares - Distribuição Poisson

Se  $g(\mu_i) = \sqrt{\mu_i}$ , tem-se  $\sqrt{\mu_i} = \eta_i \Rightarrow \mu_i = \eta_i^2$ . Como  $\theta_i = \log(\mu_i) = \log(\eta_i^2)$ . Segue que

$$\frac{d\theta_i}{d\eta_i} = \frac{1}{\eta_i^2} 2\eta_i = \frac{2}{\eta_i} = \frac{2}{\sqrt{\mu_i}}.$$

$$\Rightarrow \omega_i = \mu_i \left( \frac{2}{\sqrt{\mu_i}} \right)^2 = 4, \quad \forall i.$$

Assim, se a ligação é a raiz quadrada, os pesos  $\omega_i$  são constantes.

Nesse caso,

$$U_{\beta} = 2X^{\top} V^{-1/2}(\mathbf{y} - \boldsymbol{\mu}), \quad K_{\beta\beta} = 4X^{\top} X.$$

# Casos particulares - Distribuição binomial

Sabemos que  $\phi = n$  (conhecido),  $\theta_i = \log(\mu_i / (1 - \mu_i))$  e  $V_i = \mu_i(1 - \mu_i)$ .

Daí,

$$\begin{aligned}\omega_i &= \frac{1}{V_i} \left( \frac{d\mu_i}{d\theta_i} \frac{d\theta_i}{d\eta_i} \right)^2 \\ &= \frac{1}{\mu_i(1 - \mu_i)} \left[ \mu_i(1 - \mu_i) \frac{d\theta_i}{d\eta_i} \right]^2 \\ &= \mu_i(1 - \mu_i) \left( \frac{d\theta_i}{d\eta_i} \right)^2.\end{aligned}$$

Se a ligação é canônica, então  $\omega_i = \mu_i(1 - \mu_i)$ .



# Casos particulares - Distribuição binomial

Entretanto, pode-se encontrar na literatura (e nos *softwares*) os pesos definidos através de

$$\omega_i = n\mu_i(1 - \mu_i) \left( \frac{d\theta_i}{d\eta_i} \right)^2.$$

Para ligação canônica,  $\omega_i = n\mu_i(1 - \mu_i)$ .

Isto se deve ao fato que o MLG binomial pode ser definido sem fazer a mudança de escala  $Y^* = Y/n$ .

# Casos particulares - Distribuição gama

Neste caso, tem-se que  $V_i = \mu_i^2$  e  $\theta_i = -1/\mu_i$ . Então,

$$\omega_i = \frac{1}{\mu_i^2} \left[ \mu_i^2 \frac{d\theta_i}{d\eta_i} \right]^2 = \mu_i^2 \left( \frac{d\theta_i}{d\eta_i} \right)^2.$$

Se a ligação é a canônica, então  $\omega_i = \mu_i^2 \quad \forall i$ .

Quando a ligação escolhida é a logarítmica, tem-se

$$\begin{aligned} \log(\mu_i) = \eta_i &\Rightarrow \mu_i = e^{\eta_i} \Rightarrow -\frac{1}{\theta_i} = e^{\eta_i} \Rightarrow \theta_i = -e^{-\eta_i} \\ \Rightarrow \frac{d\theta_i}{d\eta_i} &= -e^{-\eta_i} \times (-1) = e^{-\eta_i} = e^{-\log(\mu_i)} = e^{\log(\mu_i^{-1})} = \frac{1}{\mu_i} \\ \Rightarrow \omega_i &= \mu_i^2 \left( \frac{1}{\mu_i} \right)^2 = 1, \forall i. \end{aligned}$$

# Casos particulares - Distribuição gama

Também, sabemos que  $\hat{\phi}$  é obtido tal que  $U_{\phi} = 0$ , isto é,

$$-\sum_{i=1}^n [y_i \hat{\theta}_i - b(\hat{\theta}_i)] = \sum_{i=1}^n c'(y_i; \hat{\phi}).$$

Neste caso,

$$c(y_i; \phi) = (\phi - 1) \log(y_i) + \phi \log(\phi) - \log(\Gamma(\phi)).$$

Daí,

$$\begin{aligned} c'(y_i; \phi) &= \log(y_i) + \log(\phi) + \frac{\phi}{\phi} - \psi(\phi) \\ &= \log(y_i) + \log(\phi) + 1 - \psi(\phi). \end{aligned}$$

em que  $\psi(\cdot) = \frac{\Gamma'(\cdot)}{\Gamma(\cdot)}$  é a função digama.

# Casos particulares - Distribuição gama

Sabendo que  $\theta_i = -1/\mu_i$  e  $b(\theta_i) = \log(\mu_i)$ , ficamos com

$$\begin{aligned} -\sum_{i=1}^n \left[ -\frac{y_i}{\widehat{\mu}_i} - \log(\widehat{\mu}_i) \right] &= \sum_{i=1}^n [\log(y_i) + \log(\widehat{\phi}) + 1 - \psi(\widehat{\phi})] \\ \sum_{i=1}^n \left[ \frac{y_i}{\widehat{\mu}_i} - \log\left(\frac{y_i}{\widehat{\mu}_i}\right) \right] &= n[\log(\widehat{\phi}) + 1 - \psi(\widehat{\phi})]. \end{aligned}$$

Note que não é possível isolar  $\widehat{\phi}$  na equação acima, e portanto,  $\widehat{\phi}$  não possui forma fechada.

# Casos particulares - Distribuição gama

Também,

$$c''(y_i; \phi) = \frac{1}{\phi} - \psi'(\phi), \quad \psi'(\phi) = \frac{d\psi(\phi)}{d\phi},$$

com  $\psi'(\cdot)$  sendo a função trigama.

Daí, segue que

$$K_{\phi\phi} = - \sum_{i=1}^n \left[ \frac{1}{\phi} - \psi'(\phi) \right] = - \frac{n[1 - \phi\psi'(\phi)]}{\phi} = \frac{n[\phi\psi'(\phi) - 1]}{\phi}.$$

Logo, a variância assintótica de  $\hat{\phi}$  é dada por

$$\text{Var}(\hat{\phi}) = \frac{\phi}{n[\phi\psi'(\phi) - 1]} \Rightarrow \widehat{\text{Var}}(\hat{\phi}) = \frac{\hat{\phi}}{n[\hat{\phi}\psi'(\hat{\phi}) - 1]}.$$

# Casos particulares - Distribuição normal inversa

Neste caso,  $V_i = \mu_i^3$  e  $\theta_i = -1/2\mu_i^2$ . Segue que

$$\omega_i = \frac{1}{\mu_i^3} \left[ \mu_i^3 \frac{d\theta_i}{d\eta_i} \right]^2 = \mu_i^3 \left( \frac{d\theta_i}{d\eta_i} \right)^2.$$

Se a ligação é a canônica, então  $\omega_i = \mu_i^3, \forall i$ .

Se  $g(\mu_i) = \log(\mu_i)$ , tem-se  $\mu_i = e^{\eta_i}$ . Daí, a relação entre  $\theta_i$  e  $\eta_i$  é obtida de

$$\begin{aligned} \mu_i^2 = -\frac{1}{2\theta_i} &\Rightarrow \mu_i = \left( -\frac{1}{2\theta_i} \right)^{1/2} \Rightarrow e^{\eta_i} = \left( -\frac{1}{2\theta_i} \right)^{1/2} \\ e^{2\eta_i} = -\frac{1}{2\theta_i} &\Rightarrow \theta_i = -\frac{1}{2e^{2\eta_i}} \Rightarrow \theta_i = \frac{-e^{-2\eta_i}}{2}. \end{aligned}$$

# Casos particulares - Distribuição normal inversa

Assim, obtemos que

$$\frac{d\theta_i}{d\eta_i} = -\frac{1}{2}e^{-2\eta_i}(-2) = e^{-2\eta_i} = e^{-2\log(\mu_i)} = \mu_i^{-2} = \frac{1}{\mu_i^2}.$$

Portanto, se a ligação é logarítmica, os pesos são dados por

$$\omega_i = \mu_i^3 \left( \frac{1}{\mu_i^2} \right)^2 = \frac{1}{\mu_i}, \forall i.$$

Ainda, sabemos que

$$c(y_i; \phi) = \frac{1}{2} \log \left( \frac{\phi}{2\pi y_i^3} \right) - \frac{\phi}{2y_i}.$$

# Casos particulares - Distribuição normal inversa

Assim, obtemos que

$$c'(y_i; \phi) = \frac{1}{2} \frac{2\pi y_i^3}{\phi} \frac{1}{2\pi y_i^3} - \frac{1}{2y_i} = \frac{1}{2\phi} - \frac{1}{2y_i}.$$

Ainda, sabendo que  $b(\hat{\theta}_i) = -1/\hat{\mu}_i$ , temos  $\hat{\phi}$  é obtido tal que

$$\begin{aligned} -\sum_{i=1}^n [y_i \hat{\theta}_i - b(\hat{\theta}_i)] &= \sum_{i=1}^n c'(y_i; \hat{\phi}) \\ -\sum_{i=1}^n \left[ -\frac{y_i}{2\hat{\mu}_i^2} + \frac{1}{\hat{\mu}_i} \right] &= \sum_{i=1}^n \left[ \frac{1}{2\hat{\phi}} - \frac{1}{2y_i} \right] \Leftrightarrow \\ \sum_{i=1}^n \left[ \frac{(y_i^2 - 2\hat{\mu}_i y_i + \hat{\mu}_i^2)}{2y_i \hat{\mu}_i^2} \right] &= \frac{n}{2\hat{\phi}}. \end{aligned}$$



# Casos particulares - Distribuição normal inversa

Isolando  $\hat{\phi}$ , obtemos que

$$\hat{\phi} = \frac{n}{D(\mathbf{y}; \hat{\mu})},$$

com

$$D(\mathbf{y}; \hat{\mu}) = \sum_{i=1}^n \frac{(y_i - \hat{\mu}_i)^2}{y_i \hat{\mu}_i^2}.$$

Por fim, veja que

$$c''(y_i; \phi) = -\frac{1}{2\phi^2} \Rightarrow K_{\phi\phi} = -\sum_{i=1}^n -\frac{1}{2\phi^2} = \frac{n}{2\phi^2}.$$

Consequentemente,

$$\text{Var}(\hat{\phi}) = \frac{2\phi^2}{n} \Rightarrow \widehat{\text{Var}}(\hat{\phi}) = \frac{2\hat{\phi}^2}{n}.$$

# Processo iterativo para estimar $\beta$

Vimos que o EMV para  $\beta$  é obtido encontrando o valor de  $\beta$  tal que

$$U_{\beta} = \mathbf{0} \Leftrightarrow X^{\top} \widehat{W}^{1/2} \widehat{V}^{-1/2} (\mathbf{y} - \widehat{\mu}) = \mathbf{0}, \quad (2)$$

que não depende de  $\widehat{\phi}$ .

Para encontrar o valor de  $\beta$  que resolve o sistema de equações não linear (2), considere a expansão do vetor escore  $U_{\beta}$  em série de Taylor em torno de  $\beta = \beta^{(0)}$ :

$$U_{\beta} \cong U_{\beta}^{(0)} + J_{\beta\beta}^{(0)} (\beta - \beta^{(0)}), \quad (3)$$

em que  $J_{\beta\beta} = U'_{\beta} = \partial U_{\beta} / \partial \beta^{\top}$  é a matriz hessiana para  $\beta$ ,  $U_{\beta}^{(0)}$  e  $J_{\beta\beta}^{(0)}$  são avaliadas em  $\beta^{(0)}$  que é um valor inicial (“chute”) preestabelecido.

# Processo iterativo para estimar $\beta$

Seja  $\beta^{(1)}$  o valor  $\beta$  atualizado no passo 1 do procedimento iterativo após substituir  $\beta^{(0)}$  em (3) e isolar  $\beta$ . Assim, segue que

$$U_{\beta}^{(0)} + J_{\beta\beta}^{(0)}(\beta^{(1)} - \beta^{(0)}) = \mathbf{0} \Leftrightarrow$$

$$U_{\beta}^{(0)} + J_{\beta\beta}^{(0)}\beta^{(1)} - J_{\beta\beta}^{(0)}\beta^{(0)} = \mathbf{0} \Leftrightarrow$$

$$J_{\beta\beta}^{(0)}\beta^{(1)} = J_{\beta\beta}^{(0)}\beta^{(0)} - U_{\beta}^{(0)} \Leftrightarrow$$

$$\beta^{(1)} = \{J_{\beta\beta}^{-1}\}^{(0)} J_{\beta\beta}^{(0)}\beta^{(0)} - \{J_{\beta\beta}^{-1}\}^{(0)} U_{\beta}^{(0)} \Leftrightarrow$$

$$\beta^{(1)} = \beta^{(0)} - \{J_{\beta\beta}^{-1}\}^{(0)} U_{\beta}^{(0)},$$

desde que  $J_{\beta\beta}^{-1}$  exista.

# Processo iterativo para estimar $\beta$

Repetindo o procedimento  $m$  vezes, obtemos:

$$\beta^{(m+1)} = \beta^{(m)} - \{J_{\beta\beta}^{-1}\}^{(m)} U_{\beta}^{(m)}, \quad m = 0, 1, 2, \dots,$$

em que  $\beta^{(m+1)}$  denota o valor de  $\beta$  no passo  $(m+1)$  do processo iterativo.

Observações:

- ▶ A matriz hessiana  $J_{\beta\beta}$  pode não ser invertível;
- ▶  $\ell(\beta^{(m+1)}) > \ell(\beta^{(m)})$ ,  $\forall m$ , pode não ocorrer.

Estes possíveis problemas podem ser resolvidos substituindo a matriz  $-J_{\beta\beta}$  (Fisher observada) pela matriz  $K_{\beta\beta}$  (Fisher esperada) que sempre será positiva definida.

# Processo iterativo para estimar $\beta$

Ao fazer esta modificação no procedimento iterativo estaremos utilizando o procedimento Escore de Fisher definido por

$$\beta^{(m+1)} = \beta^{(m)} + \left\{ K_{\beta\beta}^{-1} \right\}^{(m)} U_{\beta}^{(m)}, \quad m = 0, 1, 2, \dots, \quad (4)$$

em que

$$U_{\beta}^{(m)} = \phi X^{\top} \left\{ W^{1/2} \right\}^{(m)} \left\{ V^{-1/2} \right\}^{(m)} (\mathbf{y} - \boldsymbol{\mu}^{(m)}),$$

$$\left\{ K_{\beta\beta}^{-1} \right\}^{(m)} = \phi^{-1} \left\{ (X^{\top} W X)^{-1} \right\}^{(m)}.$$

# Processo iterativo para estimar $\beta$

Ainda, observe que

$$\begin{aligned}\beta^{(m)} &= \left\{ (X^\top W X)^{-1} \right\}^{(m)} \left[ X^\top W^{(m)} X \right] \beta^{(m)} \\ &= \left\{ (X^\top W X)^{-1} \right\}^{(m)} X^\top W^{(m)} \eta^{(m)},\end{aligned}$$

em que  $\eta^{(m)} = X\beta^{(m)}$  é preditor linear no passo  $m$  do processo iterativo Escore de Fisher.

Substituindo a expressão acima de  $\beta^{(m)}$  no processo iterativo em (4), ficaremos com

# Processo iterativo para estimar $\beta$

$$\begin{aligned}\beta^{(m+1)} &= \beta^{(m)} + \left\{ K_{\beta\beta}^{-1} \right\}^{(m)} U_{\beta}^{(m)} \\ &= \left\{ (X^{\top} W X)^{-1} \right\}^{(m)} X^{\top} W^{(m)} \eta^{(m)} \\ &+ \phi^{-1} \left\{ (X^{\top} W X)^{-1} \right\}^{(m)} \phi X^{\top} \left\{ W^{1/2} \right\}^{(m)} \left\{ V^{-1/2} \right\}^{(m)} (\mathbf{y} - \mu^{(m)}) \\ &= \left\{ (X^{\top} W X)^{-1} \right\}^{(m)} X^{\top} W^{(m)} \left\{ \eta^{(m)} \right. \\ &+ \left. \left\{ W^{-1/2} \right\}^{(m)} \left\{ V^{-1/2} \right\}^{(m)} (\mathbf{y} - \mu^{(m)}) \right\} \\ &= \left\{ (X^{\top} W X)^{-1} \right\}^{(m)} X^{\top} W^{(m)} \mathbf{z}^{(m)},\end{aligned}$$

em que

$$\mathbf{z}^{(m)} = \eta^{(m)} + \left\{ W^{-1/2} \right\}^{(m)} \left\{ V^{-1/2} \right\}^{(m)} (\mathbf{y} - \mu^{(m)}).$$

# Processo iterativo para estimar $\beta$

O vetor de variáveis  $\mathbf{z}$  é vista como uma variável resposta modificada. As entradas do vetor  $\mathbf{z} = (z_1 \ z_2 \ \cdots \ z_n)^\top$  são dadas por

$$z_i = \eta_i + \frac{y_i - \mu_i}{\sqrt{\omega_i V_i}}, \quad i = 1, 2, \dots, n,$$

com  $\omega_i = (d\mu_i/d\eta_i)^2 / V_i$ .

**Revisão.** O estimador de mínimos quadrados ponderados para  $\beta$  no modelo linear  $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$  com  $E(\varepsilon) = 0$  e  $\text{Var}(\varepsilon) = \sigma^2 V$  com  $V$  conhecida é

$$\hat{\beta}_G = (\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{V}^{-1} \mathbf{Y}.$$



# Processo iterativo para estimar $\beta$

Observe que o processo Escore de Fisher é atualizado por meio da expressão

$$\beta^{(m+1)} = \left\{ (X^\top W X)^{-1} \right\}^{(m)} X^\top W^{(m)} \mathbf{z}^{(m)} \quad (5)$$

que se assemelha com  $\hat{\beta}_G$ .

Por esta razão que o processo iterativo de Escore de Fisher pode ser visto como um processo iterativo de mínimos quadrados reponderados.

Note que a matriz  $W$  possui o papel de reponderar  $\hat{\beta}$ , ou seja,  $W$  é vista como uma matriz de ponderações ou “pesos” que muda a cada passo do processo iterativo.

# Processo iterativo para estimar $\beta$

Para estabelecer um valor inicial para  $\beta^{(0)}$ , considere que

$$\mu^{(0)} = \mathbf{y} \Rightarrow \eta^{(0)} = g(\mathbf{y}).$$

Daí, o  $i$ -ésimo valor da variável transformada  $z_i$  no passo 0 é calculado por meio de

$$z_i^{(0)} = \eta_i^{(0)} + \frac{y_i - \mu_i^{(0)}}{\sqrt{\omega_i^{(0)} V_i^{(0)}}},$$

em que

$$\eta_i^{(0)} = g(y_i), \quad \mu_i^{(0)} = y_i, \quad V_i^{(0)} = V_i(\mu_i^{(0)}), \quad \omega_i^{(0)} = \frac{[1/g'(\mu_i^{(0)})]^2}{V_i^{(0)}}.$$

Calculado  $z_i^{(0)}$ ,  $\forall i$  e  $W^{(0)}$ , obtemos  $\beta^{(1)}$  através de (5).

# Processo iterativo para estimar $\beta$

Consequentemente, com o valor atualizado  $\beta^{(1)}$  calcula-se  $\eta^{(1)}$  e obtém-se  $\beta^{(2)}$ . O procedimento segue até que não há mudanças significativas na estimativa de  $\beta$ .

Quando devemos parar o procedimento iterativo?

Dizemos que há convergência do procedimento iterativo se

$$\left| \frac{\beta_j^{(m+1)} - \beta_j^{(m)}}{\beta_j^{(m)}} \right| < \epsilon, \quad \forall j = 1, 2, \dots, p, \quad (6)$$

em que  $\epsilon > 0$  é um valor pequeno preestabelecido.

# Processo iterativo para estimar $\beta$

Usualmente, fixam-se dois valores de  $\epsilon$ . Sejam  $\epsilon_1$  e  $\epsilon_2$  os valores de  $\epsilon$  fixados tais que  $\epsilon_1 < \epsilon_2$ .

Se a condição em (6) é verificada para  $\epsilon_1$ , dizemos que houve “convergência forte”. Note que se a condição é satisfeita para  $\epsilon_1$ , então é satisfeita para  $\epsilon_2$ .

Se a condição em (6) é verificada apenas para  $\epsilon_2$ , dizemos que houve “convergência fraca”.

Se a condição em (6) não é satisfeita para  $\epsilon_2$ , dizemos que o procedimento iterativo não convergiu.

Para o caso de possível não convergência do procedimento iterativo, deve-se fixar um número máximo de iterações. Usualmente fixa-se 200 iterações.

# Processo iterativo para estimar $\phi$

De forma análoga, o procedimento iterativo para  $\phi$  é

$$\phi^{(m+1)} = \phi^{(m)} - \left\{ J_{\phi\phi}^{-1} \right\}^{(m)} U_{\phi}^{(m)}, \quad m = 0, 1, 2, \dots,$$

em que  $\phi^{(m+1)}$  denota o valor de  $\phi$  no passo  $(m+1)$ .

Também pode-se substituir  $-J_{\phi\phi}$  por  $K_{\phi\phi}$ .

O valor inicial  $\phi^{(0)}$  pode ser definido como sendo o estimador de momentos para  $\phi$ .

Por exemplo, sob o modelo gama, temos que

$$E \left[ \frac{(Y_i - \mu_i)^2}{\mu_i^2} \right] = \phi^{-1}.$$

# Processo iterativo para estimar $\phi$

Daí, segue que um estimador de momentos para  $\phi^{-1}$  sob o modelo gama é

$$\hat{\phi}_M^{-1} = \frac{1}{n-p} \sum_{i=1}^n \frac{(Y_i - \hat{\mu}_i)^2}{\hat{\mu}_i^2}.$$

Mostra-se que  $\hat{\phi}_M$  é um estimador consistente para  $\phi$ .

Assim, no procedimento iterativo utiliza-se  $\phi^{(0)} = \hat{\phi}_M$ .

Perceba que o procedimento iterativo para obtenção da estimativa de  $\phi$  depende da estimativa de  $\beta$ .

Portanto, primeiro encontra-se o valor  $\hat{\beta}$ , em seguida, obtém-se  $\hat{\phi}$ .